

Taller Práctico Regresión Lineal Múltiple (3) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al tercer taller práctico del curso de **Estadística II** para la *Universidad Nacional de Colombia*, Sede Medellín, en el periodo 2026-01. Se brinda una introducción al análisis de regresión. El enfoque de este taller está en la comprensión de los supuestos del modelo, puntos de balanceo, atípicos e influyentes, así como en la respuesta media y en la predicción. **Monitor:** *Tomás Rodríguez Taborda*.

Keywords: regresión múltiple, supuestos, influyentes, balanceo

Información general

Con el propósito de profundizar en los conceptos del modelo de regresión lineal múltiple vistos en clase, se propone abordar este taller en dos partes: una de teoría básica y otra práctica.

La solución para cada uno de los problemas se efectúa a partir del software estadístico R.

Parte teórica

Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación de ser necesario.**

1. Pruebe que en el modelo de regresión lineal múltiple que incluye intercepto, la suma de los residuales es igual a cero.
2. Determine el valor de verdad de las siguientes afirmaciones.
 - (a) Bajo los supuestos del modelo de regresión lineal múltiple, se cumple que **la respuesta media estimada** $\hat{Y}_0 \sim N(E[Y|\mathbf{x}_0], \sigma^2 \mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0)$; donde, además, $\hat{Y}_0$ es un estimador insesgado para Y_0 .
 - (b) El error de predicción $\hat{Y}_0 - Y_0$ tiene una varianza asociada dada por $\sigma^2 \mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0$, al igual que $\hat{Y}_0$. De aquí que, si se sabe que $\mathbf{x}_0 = [1, x_{01}, x_{02}, \dots, x_{0k}]'$ es un punto en que no se comete extrapolación, entonces es correcto afirmar que $\mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0 < 1$.
 - (c) El procedimiento analítico **Shapiro-Wilk**, cuyo juego de hipótesis está dado por: $H_0 : \varepsilon_i \sim N(0, \sigma^2)$ vs $H_1 : \varepsilon_i \not\sim N(0, \sigma^2), i = 1, \dots, n$, permite determinar la normalidad de los residuales del modelo de regresión.

*El material asociado a este taller puede encontrarse en el repositorio del curso, (<https://github.com/torodriguez/Estadistica-II>)

- (d) Si al validar los supuestos del modelo de regresión lineal múltiple se detecta varianza no homogénea, adicionar términos cuadráticos a las variables predictoras permite corregirla, ya que la heterocedasticidad siempre se debe a una especificación funcional incorrecta del modelo.
- (e) Una observación atípica está separada del resto de las observaciones en su valor de respuesta Y , aunque no afecta los resultados del ajuste. **Su evaluación se realiza a través del residual estandarizado** $|d_i| > 3$.
- (f) Se cumple que una observación i es de balanceo si está definida en el espacio de la respuesta Y y si se cumple que $h_{ii} > 2p/n$, afectando estadísticas como el R^2 y los errores estándar de los coeficientes del modelo.
- (g) Se cumple que $D_i > 1$, $|\text{DFBETAS}_{j(i)}| > (2/\sqrt{n})$ y $|\text{DFITS}_i| > (2\sqrt{p/n})$ simultáneamente para toda observación categorizada como influyente en un conjunto de datos.

3. Seleccione las expresiones adecuadas que se muestran a continuación, interprételas y corrija las expresiones incorrectas.

$$\begin{array}{ll} \text{a. } d_i = \frac{e_i}{\sqrt{\text{MSE}}} & \text{b. } r_i = \frac{d_i}{\sqrt{1-h_{ii}}} \\ \text{c. } \text{DFBETAS}_{j(i)} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\sqrt{\text{MSE}_{(i)} c_{jj}}} & \text{d. } \text{DFITS}_i = \frac{\hat{y}_i - y_{i(0)}}{\sqrt{c_{jj} \text{MSE}_{(i)}}} \end{array}$$

Ejercicio con datos reales

Considere el siguiente conjunto de datos que agrupa información sobre el índice multidimensional de calidad de vida de la ciudad de Medellín. **Se incluyen únicamente algunas variables**, cuya descripción puede encontrarse **en el siguiente enlace**: <https://medata.gov.co/dataset/1-002-09-000041>

Table 1: Información en análisis

IMCV	Ingresos	Salud	Trabajo	Capital
32.06	0.780000	2.550000	0.5100000	3.310000
32.88	0.960000	2.620000	0.5200000	3.680000
33.27	1.100000	2.650000	0.5700000	3.830000
32.82	1.121182	2.569105	0.5520319	3.739863
33.53	1.039000	3.041000	0.4850000	3.667000

Considere a $IMCV$ como la variable respuesta. Las covariables consideradas en el análisis se especifican en la tabla anterior. **Dé respuesta a los siguientes planteamientos:**

1. Verifique los supuestos del modelo de regresión, esto es, $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, a partir de los procedimientos apropiados para ello.
2. Identifique puntos atípicos y puntos de balanceo a través de un criterio gráfico y analítico. **¿Podrían ser estos puntos a su vez influyentes?**

3. Identifique puntos influyentes. **Compare los criterios empleados para ello.**
4. Realice inferencia para $\underline{\mathbf{x}}_{01} = [1, 1.6921, 3.3214, 0.6125, 6.1313]'$ y $\underline{\mathbf{x}}_{02} = [1, 3.6534, 4.2594, 0.7646, 12.7477]'$, con su respectivo intervalo de predicción. **Verifique primero si no se trata de un punto de extrapolación.**