

Taller Práctico: Regresión Lineal Múltiple (1) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al primer taller práctico del curso de **Estadística II** de la *Universidad Nacional de Colombia*, Sede Medellín, en el período 2026-01. Se brinda una introducción al análisis de regresión. El enfoque de este taller se centra en la comprensión del modelo de regresión lineal múltiple a nivel matricial. **Monitor:** *Tomás Rodríguez Taborda*.

Keywords: regresión múltiple

Información general

Con el propósito de profundizar en los conceptos del modelo de regresión lineal múltiple vistos en clase, se propone afrontar este taller en dos partes: una de teoría básica y otra práctica.

La solución para cada uno de los problemas se efectúa a partir del software estadístico R.

Parte teórica

Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación cuando sea necesario.**

1. Considere el siguiente modelo de regresión lineal múltiple con k variables regresoras y $p = k + 1$ parámetros asociados:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_k X_{ik} + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2).$$

- (a) Escriba el modelo de forma matricial junto con sus supuestos. **Especifique las dimensiones de cada componente.**
- (b) Demuestre que el estimador $\hat{\beta}$ que se obtiene a través del método de mínimos cuadrados es un estimador insesgado para β .
- (c) Obtenga una expresión para la matriz de varianzas-covarianzas de $\hat{\beta}$.

2. Determine el valor de verdad de las siguientes afirmaciones.

- (a) Considere los siguientes modelos de regresión múltiple:

*El material asociado a este taller puede encontrarse en el repositorio del curso, (<https://github.com/torodriguez/Estadistica-II>)

$$(1) \quad Y_i = \beta_0 + \sum_{j=1}^k \beta_j (X_{ij})^{1/2} + \varepsilon_i$$

$$(2) \quad \ln(Y_i) = \beta_0 + \sum_{j=1}^k \beta_j \ln(X_{ij}) + \varepsilon_i$$

con $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$.

Los modelos anteriores no son modelos lineales, puesto que se altera la forma de la superficie de respuesta.

- (b) Bajo los supuestos del modelo de regresión lineal múltiple, $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, el estimador para los parámetros $\hat{\beta}$ obtenido a través del método de mínimos cuadrados ordinarios es el mismo que el de máxima verosimilitud, así como para la varianza $\hat{\sigma}^2$. **Explique.**
- (c) La matriz de varianzas-covarianzas siempre es simétrica respecto a su diagonal principal, además, siempre tiene unos en su diagonal principal.
- (d) El parámetro β_0 , como la respuesta media de Y , es únicamente interpretable si el conjunto de observaciones $(X_1, X_2, \dots, X_k) = (0, 0, \dots, 0)$ está incluido en el rango experimental.
- (e) Los parámetros $\beta_j, j = 1, \dots, k$ indican el cambio en la respuesta media de Y por unidad de incremento en la respectiva variable X_j .

Ejercicio con datos reales

Considere el siguiente conjunto de datos que agrupa información sobre el índice multidimensional de calidad de vida de la ciudad de Medellín. **Se incluyen únicamente algunas variables** cuya descripción puede encontrarse **en el siguiente enlace:** <https://medata.gov.co/dataset/1-002-09-000041>

Table 1: Información en análisis

IMCV	Ingresos	Salud	Trabajo	Capital
32.06	0.780000	2.550000	0.5100000	3.310000
32.88	0.960000	2.620000	0.5200000	3.680000
33.27	1.100000	2.650000	0.5700000	3.830000
32.82	1.121182	2.569105	0.5520319	3.739863
33.53	1.039000	3.041000	0.4850000	3.667000

Considere a *IMCV* como la variable respuesta. Las covariables consideradas en el análisis se especifican en la tabla anterior. **Dé respuesta a los siguientes planteamientos:**

1. Determine cuál es la matriz de diseño ($\mathbf{X}$) para este problema en específico. Calcule el vector de parámetros estimados $\hat{\beta}$. Brinde una interpretación adecuada.

2. Obtenga una estimación para la varianza ($\hat{\sigma}^2$).
3. Obtenga una estimación de la matriz de varianzas-covarianzas de $\hat{\beta}$.

1. Considere el siguiente modelo de regresión lineal múltiple con k variables regresoras y $p = k + 1$ parámetros asociados:

1.1 for el intercepto $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2).$

- (a) Escriba el modelo de forma matricial junto con sus supuestos. **Especifique las dimensiones de cada componente.**
- (b) Demuestre que el estimador $\hat{\beta}$ que se obtiene a través del método de mínimos cuadrados es un estimador insesgado para β .
- (c) Obtenga una expresión para la matriz de varianzas-covarianzas de $\hat{\beta}$.

$$\text{Cov} = 0 \Rightarrow \text{Ind}$$

$$1- \quad \underline{y} = \underline{X} \underline{\beta} + \underline{\varepsilon} \quad \varepsilon \sim N_n(0, \sigma^2 I)$$

$$\underline{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \quad \underline{y} \in \mathbb{R}^{n \times 1} \quad \sigma^2 I = \begin{pmatrix} \sigma^2 & 0 & 0 \\ 0 & \sigma^2 & 0 \\ 0 & 0 & \sigma^2 \end{pmatrix}$$

$n \rightarrow$ cantidad de datos

$p \rightarrow$ # de β_j $j = 0, \dots, k$

$$\underline{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{bmatrix} \quad \underline{X} \in \mathbb{R}^{n \times (k+1)}$$

$$\underline{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} \quad \underline{\beta} \in \mathbb{R}^{(k+1) \times 1}$$

$$\underline{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

$$\underline{\varepsilon} \in \mathbb{R}^{n \times 1}$$

$$b) E[\hat{\theta}] = \theta \quad \text{Insesgado}$$

$$E[\hat{\theta}] = \frac{\theta}{2} \quad \text{sesgado}$$

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

$$y = X\beta + \varepsilon \quad E[a+b] = E[a] + E[b]$$

$$E[\hat{\beta}] = E[(X^T X)^{-1} X^T y]$$

$$E[\varepsilon] = 0$$

$$= E[(X^T X)^{-1} X^T (X\beta + \varepsilon)]$$

$$A^T A = A A^T = I_n$$

$$= E[\underbrace{(X^T X)^{-1} X^T X}_{I_n} \beta] + E[(X^T X)^{-1} X^T \varepsilon]$$

$$= E[I_n \beta] = E[\beta] = \beta$$

$$\text{Var}[aX] = a^2 \text{Var}[X]$$

$$c) \text{Var}(\hat{\beta}) = \text{Var}\left[\underbrace{(X^T X)^{-1} X^T}_{A} y\right] = \text{Var}[A y]$$

$$= A \text{Var}[y] A^T$$

$$y \stackrel{\text{ind}}{\sim} N(X\beta, \sigma^2)$$

$$= \text{Var}[y] A A^T$$

$$= \sigma^2 \left[\underbrace{(X^T X)^{-1}} \underbrace{X^T X (X^T X)^{-1}} \right]$$

$$\text{Var}(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$$

$$\hat{\text{Var}}(\hat{\beta}) \quad (\text{esto es lo que se calcula})$$

$$= \hat{\sigma}^2 (X^T X)^{-1}$$

$$(1) Y_i = \beta_0 + \sum_{j=1}^k \beta_j (X_{ij})^{1/2} + \varepsilon_i$$

$$(2) \ln(Y_i) = \beta_0 + \sum_{j=1}^k \beta_j \ln(X_{ij}) + \varepsilon_i$$

con $\varepsilon_i \sim N(0, \sigma^2)$.

Los modelos anteriores no son modelos lineales, puesto que se altera la forma de la superficie de respuesta.

- (b) Bajo los supuestos del modelo de regresión lineal múltiple, $\varepsilon_i \sim N(0, \sigma^2)$, el estimador para los parámetros β obtenido a través del método de mínimos cuadrados ordinarios es el mismo que el de máxima verosimilitud, así como para la varianza σ^2 . Explique. *Falsa, pero σ^2 es diferente*
- (c) La matriz de varianzas-covarianzas siempre es simétrica respecto a su diagonal principal, además, siempre tiene unos en su diagonal principal.
- (d) El parámetro β_0 como la respuesta media de Y_i es únicamente interpretable si el conjunto de observaciones $(X_1, X_2, \dots, X_k) = (0, 0, \dots, 0)$ está incluido en el rango experimental.
- (e) Los parámetros $\beta_j, j = 1, \dots, k$ indican el cambio en la respuesta media de Y por unidad de incremento en la respectiva variable X_j .

a) Falsa. Modelo lineal se refiere a la linealidad en β_j no en X_{ij} .

$$y = \beta_0 + \beta_1 x_{12} \quad \text{No es lineal}$$

$$b) f(y_i | \beta, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left\{-\frac{1}{2\sigma^2} (y_i - x_i^T \beta)^2\right\} \quad \text{verosimilitud}$$

1 sola observación

$$L(\beta, \sigma^2) = \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi}\sigma^2} \exp\left\{-\frac{1}{2\sigma^2} (y_i - x_i^T \beta)^2\right\} \right]$$

$$= \left[\left(\frac{1}{\sqrt{2\pi}\sigma^2} \right)^n \exp\left\{-\frac{1}{2\sigma^2} \sum (y_i - x_i^T \beta)^2\right\} \right]$$

$$L(\beta, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma^2} \right)^n \exp\left\{-\frac{1}{2\sigma^2} (y - X\beta)^T (y - X\beta)\right\}$$

$$\phi(\beta, \sigma^2) = \ln(1) - \frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} (y - X\beta)^T (y - X\beta)$$

$$\phi(\beta, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \left[y^T y - 2\beta^T X^T y + \beta^T X^T X \beta \right]$$

Para β :

$$\frac{\partial \phi}{\partial \beta} = \frac{-1}{\sigma^2} \left[-X^T y + X^T X \beta \right]$$

$$= \frac{-1}{\sigma^2} [-X^T y + X^T X \beta] = 0 \quad \frac{\partial}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} S = 0$$

$$\Rightarrow X^T y - X^T X \beta = 0$$

$$X^T y = X^T X \beta$$

$$(X^T X)^{-1} X^T y = \hat{\beta} \quad \text{Estimador ML}$$

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad \text{Estimador MCO}$$

$$\hat{y} = X \hat{\beta}$$

$$(y - X\beta)^T (y - X\beta)$$

$$= y^T y - y^T X \beta - \beta^T X^T y + \beta^T X^T X \beta$$

$$= y^T y - 2\beta^T X^T y + \beta^T X^T X \beta$$

$$y^T X \beta \rightarrow \begin{matrix} (1 \times n) & (n \times p) & (p \times 1) \\ \uparrow & \uparrow & \uparrow \\ (1 \times p) & (p \times 1) & \\ \uparrow & & \\ 1 \times 1 \rightarrow \text{escalar} \end{matrix}$$

$$\beta^T X^T y \rightarrow \begin{matrix} (1 \times p) & (p \times n) & (n \times 1) \\ \uparrow & \uparrow & \uparrow \\ (1 \times n) & (n \times 1) & \\ \uparrow & & \\ 1 \times 1 \end{matrix}$$

$$\frac{\partial}{\partial \beta} (\beta^T X^T X \beta) \quad (X^T X)^T = X^T X$$

$$\frac{\partial}{\partial \beta} (\beta^T A \beta) = (A + A^T) \beta$$

$$= 2A\beta$$

$$= 2X^T X \beta$$

$$\ln(ab) = \ln(a) + \ln(b)$$

$$\frac{1}{\cancel{\sigma^2}} S = \frac{n}{\cancel{\sigma^2}}$$

$$\frac{1}{\sigma^2} S = n$$

$$\frac{S}{n} = \sigma^2$$

$$\frac{(y - X\beta)^T (y - X\beta)}{n} = \sigma^2$$

$$\frac{(y - X\hat{\beta})^T (y - X\hat{\beta})}{n} = \hat{\sigma}^2$$

$$\frac{(y - \hat{y})^T (y - \hat{y})}{n} = \hat{\sigma}^2$$

sesgado $\left\{ \frac{\sum (y - \hat{y})^2}{n} = \hat{\sigma}^2 \right.$

Para σ^2 bajo MCO:

$$\hat{\sigma}^2 = \frac{\sum (y_i - \hat{y}_i)^2}{n - p}$$

Bajo ML y MCO

$\hat{\sigma}^2$ es diferente

c) Falso.


$$\text{Var}(\hat{\beta}) = \begin{pmatrix} \sigma_{11}^2 & \sigma_{12}^2 & \sigma_{13}^2 \\ \sigma_{21}^2 & \sigma_{22}^2 & \sigma_{23}^2 \\ \sigma_{31}^2 & \sigma_{32}^2 & \sigma_{33}^2 \end{pmatrix}$$

Es simétrica

$$\begin{cases} \sigma_{12}^2 = \text{Cov}(\beta_1, \beta_2) \\ \sigma_{21}^2 = \text{Cov}(\beta_2, \beta_1) \end{cases} \quad \text{Cov}(\beta_1, \beta_2) = \text{Cov}(\beta_2, \beta_1)$$

$$\sigma_{11}^2 = \text{Var}(\beta_1) \rightarrow \text{Cualquier valor}$$

d) Variables. Este modelo no sirve para extrapolar



X_1 : Altura $\rightarrow$ No va a ser 0,

β_0 no es interpretable si no

se observa $(0, 0, \dots, 0) = (x_1, x_2, \dots, x_k)$

rango experimental.

- (e) Los parámetros $\beta_j, j = 1, \dots, k$ indican el cambio en la respuesta media de Y por unidad de incremento en la respectiva variable X_j .

e) Falso, esta incompleta. Faltan

"manteniendo las demás predictoras
constante"

$$\underline{y} = \underline{X}\beta + \varepsilon \quad E[y | x_1, x_2, \dots, x_k] = \beta_0 + \beta_1 x_1 + \dots$$

Esto es lo que modelo

$$\hat{y} = \underline{X}\hat{\beta}$$

$$y_i = 0.2 + 5x_{i1} + 10x_{i2}$$

↑
Por un cambio unitario
en x_{i1} el promedio
de la variable respuesta
aumenta en 5 unidades
manteniendo las demás predictoras
constante.