

Taller Práctico Regresión Lineal Múltiple (2) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al segundo taller práctico del curso de **Estadística II** para la *Universidad Nacional de Colombia*, Sede Medellín, en el periodo 2026-1. Se brinda una introducción al análisis de regresión. El enfoque de este taller está en la comprensión del análisis de varianza y la ejecución de pruebas de hipótesis a través de la suma extra de cuadrados y el método lineal general. **Monitor:** *Tomás Rodríguez Taborda*.

Keywords: regresión múltiple, pruebas de hipótesis, ANOVA

Información general

Con el propósito de profundizar en los conceptos del modelo de regresión lineal múltiple vistos en clase, se propone desarrollar este taller en dos partes: una de teoría básica y otra práctica.

La solución para cada uno de los problemas se efectúa a partir del software estadístico R.

Parte teórica

Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación si lo considera necesario.**

1. Determine el valor de verdad de las siguientes afirmaciones.

- (a) Se requiere que la matriz $(\mathbf{X}^t\mathbf{X})$ sea singular para que exista su inversa y, por tanto, pueda calcularse el estimador de mínimos cuadrados ordinarios $\hat{\beta} = (\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t\mathbf{Y}$. Además, la matriz $\mathbf{H}$ es simétrica e idempotente, al igual que $(\mathbf{I}_n - \mathbf{H})$.
- (b) Una suma de cuadrados extra mide la reducción marginal en el SSE cuando una o varias variables predictoras son agregadas al modelo de regresión, dado que las otras predictoras ya fueron agregadas o están en el modelo.
- (c) El estadístico T correspondiente al procedimiento de prueba empleado para probar la significancia marginal del j -ésimo parámetro es:

$$T_{j,0} = \frac{\hat{\beta}_j - 0}{ee(\hat{\beta}_j)} \sim t_{n-p}$$

*El material asociado a este taller puede encontrarse en el repositorio del curso, (<https://github.com/torodriguez/Estadistica-II>)

Con una región de rechazo asociada $R_c = \{|T_0| > t_{1-\alpha/2, n-p}\}$ y p -valor $P(|t_{n-p}| > |T_{j,0}|)$.

- (d) Valores grandes de R^2 implican que la superficie ajustada de respuesta es útil; sin embargo, es menos preferido que R_{adj}^2 como medida de bondad de ajuste.
- (e) Rechazar la hipótesis nula $H_0 : \beta_0 = \beta_1 = \dots = \beta_k = 0$ permite determinar la significancia global de un modelo de regresión lineal múltiple a través de un procedimiento de sumas de cuadrados extra o procedimiento lineal general.
- (f) El estadístico F correspondiente al procedimiento de prueba empleado para probar la significancia global del modelo de regresión lineal múltiple es:

$$F_0 = \frac{SSR/k}{SSE/(n-p)} \sim f_{k, n-p}$$

Con una región de rechazo asociada de $R_c = \{F_0 > f_{1-\alpha, k, n-p}\}$ y p -valor $P(f_{k, n-p} > F_0)$.

- (g) Se puede demostrar que $F_{j,0} = T_{j,0}^2$ únicamente si se pretende determinar la significancia marginal de un coeficiente de regresión, lo que implica que $P(f_{1, n-p} > F_{j,0}) \equiv P(|t_{n-p}| > |T_{j,0}|)$.
- (h) Los grados de libertad del cuadrado medio debido a la hipótesis son iguales al rango de la matriz $\mathbf{L}$, asociada a la prueba lineal general ($H_0 : \mathbf{L}\beta = 0$ vs $H_1 : \mathbf{L}\beta \neq 0$).

Ejercicio con datos reales

Considere el siguiente conjunto de datos que agrupa información sobre el índice multidimensional de calidad de vida de la ciudad de Medellín. **Se incluyen únicamente algunas variables** cuya descripción puede encontrarse **en el siguiente enlace:** <https://medata.gov.co/dataset/1-002-09-000041>

Table 1: Información en análisis

IMCV	Ingresos	Salud	Trabajo	Capital
32.06	0.780000	2.550000	0.510000	3.310000
32.88	0.960000	2.620000	0.520000	3.680000
33.27	1.100000	2.650000	0.570000	3.830000
32.82	1.121182	2.569105	0.5520319	3.739863
33.53	1.039000	3.041000	0.4850000	3.667000

Considere a *IMCV* como la variable respuesta. Las covariables consideradas en el análisis se especifican en la tabla anterior. **Dé respuesta a los siguientes planteamientos:**

1. Determine cuál es el modelo empleado en esta situación, junto con sus supuestos. Además, reporte la recta de regresión ajustada y calcule los residuales del modelo.

1. Determine el valor de verdad de las siguientes afirmaciones.

- (a) Se requiere que la matriz $(X^T X)$ sea invertible para que exista su inversa y, por tanto, pueda calcularse el estimador de mínimos cuadrados ordinarios $\hat{\beta} = (X^T X)^{-1} X^T Y$. Además, la matriz H es simétrica e idempotente, al igual que $(I_n - H)$. **Falso**
- (b) Una suma de cuadrados extra mide la reducción marginal en el SSE cuando una o varias variables predictoras son agregadas al modelo de regresión, dado que las otras predictoras ya fueron agregadas o están en el modelo. **Verdadero**
- (c) El estadístico T correspondiente al procedimiento de prueba empleado para probar la significancia marginal del j -ésimo parámetro es:

$$T_{j0} = \frac{\hat{\beta}_j - 0}{\text{se}(\hat{\beta}_j)} \sim t_{n-p} \quad \text{verdadero}$$

a) singular $\rightarrow \det(X^T X) = 0$
 No es invertible, no
 podrá calcular $\hat{\beta}$

no singular $\rightarrow$ invertible $\rightarrow n \geq p$

$$\hat{y} = X \hat{\beta}$$

$$\hat{y} = \underbrace{X(X^T X)^{-1} X^T}_{\text{Matriz Hat}} y$$

$$\hat{y} = H y$$

$$e = y - \hat{y}$$

$$e = y - H y$$

$$e = (I - H) y \quad \text{Proyección ortogonal de } y \text{ que no es explicada}$$

Lo que ya
ingresó

b) $SSR(X_3 | X_1, X_2) = \underbrace{SSR(X_1, X_2, X_3)}_{MF} - \underbrace{SSR(X_1, X_2)}_{MR}$ $\left\{ \begin{array}{l} \text{¿Cuánto gano en explicar la variabilidad de la variable respuesta por agregar } X_3? \\ SST = SSR + SSE \\ \text{¿Cómo se distribuye entre MF y MR?} \end{array} \right.$

Lo que va a ingresar $= SSE(X_1, X_2) - SSE(X_1, X_2, X_3)$

c) $T_{j0} = \frac{\hat{\beta}_j - 0}{\text{se}(\hat{\beta}_j)} \sim t_{n-p} \quad T_{j0} = \frac{\hat{\beta}_j}{\sqrt{\sigma^2 c_{jj}}} \sim t_{n-p}$ $\left\{ \begin{array}{l} \text{Más covariables aumentan el SSR} \\ \text{Más covariables disminuyen el SSE} \end{array} \right.$

PH: $\begin{cases} H_0: \beta_j = 0 \\ H_a: \beta_j \neq 0 \end{cases}$ $\left\{ \begin{array}{l} \text{significancia individual} \end{array} \right.$


ojo!!

$\sigma^2 c_{jj} \neq \sigma^2 c_{jj}$
 cambia la distribución $\rightarrow$ Distribución t-student
 $\rightarrow$ Distribución normal

$$(X^T X)^{-1} = C$$

$$\text{Var}(\hat{\beta}) = \sigma^2 (X^T X)^{-1} = \sigma^2 C \quad \left[\begin{array}{l} \text{Matriz var-cov} \end{array} \right]$$

$$\text{Var}(\hat{\beta}_j) = \sigma^2 c_{jj}$$



$q_t(\dots)$
 $P(t(T_{j1}, \dots))$ usualmente 0.05
 $\downarrow < \alpha$


- (d) Valores grandes de R^2 implican que la superficie ajustada de respuesta es útil; **Falso**
sin embargo, es menos preferido que R^2_{adj} como medida de bondad de ajuste.
- (e) Rechazar la hipótesis nula $H_0 : \beta_0 = \beta_1 = \dots = \beta_k = 0$ permite determinar la significancia global de un modelo de regresión lineal múltiple a través de un procedimiento de sumas de cuadrados extra o procedimiento lineal general. **Falso**
- (f) El estadístico F correspondiente al procedimiento de prueba empleado para probar la significancia global del modelo de regresión lineal múltiple es: **verdadero**

$$F_0 = \frac{SSR/k}{SSE/(n-p)} \sim f_{k,n-p} \quad \text{¡¡ ojo!! } P = k+1$$

Con una región de rechazo asociada de $R_c = \{F_0 > f_{1-\alpha, k, n-p}\}$ y p -valor $P(f_{k, n-p} > F_0)$.

d) R^2 : Medida de la bondad del ajuste

¿Cuánta variabilidad
de Y logra
explicar mi modelo?



* R^2 alto: No significa que el modelo sea útil

* R^2 bajo: No significa que X y Y no estén correlacionados

R^2_{adj} es preferido: Parsimonia (menos complejo sin perder capacidad de explicación del modelo)
Realiza
ajregar variables

$$R^2_{adj} = 1 - \frac{(n-1)MSE}{SST}$$

$$\downarrow = 1 - \frac{(n-1) \frac{SSE}{n-p}}{SST} \quad \text{Requerido}$$

$\underbrace{\frac{SSE}{n-p}}_{\text{sube poco}} \rightarrow \text{se hace más grande}$

- (g) Se puede demostrar que $F_{j,0} = T_{j,0}^2$ únicamente si se pretende determinar la significancia marginal de un coeficiente de regresión, lo que implica que $P(L_{j,0} > F_{j,0}) \equiv P(|t_{j,0}| > |T_{j,0}|)$. **verdadero**
- (h) Los grados de libertad del cuadrado medio debido a la hipótesis son iguales al rango de la matriz L , asociada a la prueba lineal general ($H_0: L\beta = 0$ vs $H_1: L\beta \neq 0$). **verdadero**

Test Lineal General:

$$\begin{aligned} H_0: L\beta &= c \\ H_a: L\beta &\neq c \end{aligned} \quad \text{restricciones}$$

$$\text{rank}(L) = r \rightarrow \text{cantidad de restricciones}$$

$$\begin{aligned} \hat{\beta} &\sim N(\beta, \sigma^2(X^T X)^{-1}) \\ L\hat{\beta} &\sim N(L\beta, \sigma^2 L(X^T X)^{-1} L^T) \end{aligned}$$

Byo H_0

$$L\hat{\beta} - c \sim N(0, \sigma^2 L(X^T X)^{-1} L^T)$$

$$Z \sim N(0, \Sigma)$$

$$Z^T \Sigma^{-1} Z \sim \chi^2_{\text{rank}(\Sigma)}$$

$$\frac{\chi^2_r}{r} \sim f_{r,k}$$

$$Z = \frac{\epsilon}{\sigma} \sim N(0, I)$$

$$Z \cdot \sigma = \epsilon$$

$$\frac{(L\hat{\beta} - c)^T (L \sigma^2 (X^T X)^{-1} L^T)^{-1} (L\hat{\beta} - c) / r}{\frac{SSE}{\sigma^2} / (n-p)} \quad \text{debido a la hipótesis}$$

$$\frac{(L\hat{\beta} - c)^T (L (X^T X)^{-1} L^T)^{-1} (L\hat{\beta} - c)}{\frac{SSE}{(n-p)}} \Big] \hat{\sigma}^2$$

$$F_0 = \frac{(L\hat{\beta} - c)^T (L (X^T X)^{-1} L^T)^{-1} (L\hat{\beta} - c) / r}{\hat{\sigma}^2} \sim f_{r, n-p}$$

$$\begin{aligned} C &= (X^T X)^{-1} \\ L (X^T X)^{-1} L^T &= C_{jj} \\ L C L^T &= C_{jj} \end{aligned}$$

$$(L\hat{\beta} - c)^T (\sigma^2 L (X^T X)^{-1} L^T)^{-1} (L\hat{\beta} - c) \sim \chi^2_{\text{rank}(L)}$$

$$\begin{aligned} SSE &= \sum (\hat{y}_i - y_i)^2 \quad \epsilon \sim N(0, \sigma^2 I) \\ &= \sum e_i^2 = e^T e \end{aligned}$$

$$SSE = [(I-H)\epsilon]^T (I-H)\epsilon$$

$$SSE = \epsilon^T (I-H)^T (I-H)\epsilon$$

$$SSE = \epsilon^T (I-H) (I-H)\epsilon$$

$$= \epsilon^T (I-H) \epsilon$$

$$= (Z \cdot \sigma)^T (I-H) (Z \cdot \sigma)$$

$$SSE = \sigma^2 Z^T (I-H) Z$$

$$\text{rank}(I-H) = n-p$$

$$\frac{SSE}{\sigma^2} = Z^T (I-H) Z \sim \chi^2_{\text{rank}(I-H)}$$

$$\sim \chi^2_{n-p}$$

$$e = y - \hat{y}$$

$$e = (I-H)y$$

$$e = (I-H)(X\beta + \epsilon)$$

$$e = (I-H)X\beta + (I-H)\epsilon$$

$$e = (I-H)\epsilon$$

$$HX = X(X^T X)^{-1} X^T X = I_n$$

$$HX = X$$

$$0 = X - HX$$

$$0 = (I-H)X$$

Para la P.H de significancia individual.

$$\begin{aligned} H_0: \beta_j &= 0 \\ H_a: \beta_j &\neq 0 \end{aligned} \quad \begin{aligned} &[0 \dots 0 \quad \textcircled{1} \quad 0 \dots 0] \\ &\quad \quad \quad \text{d-ésimo} \\ &\quad \quad \quad \text{posición} \end{aligned} \quad \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_j \\ \vdots \\ \beta_p \end{bmatrix} = \beta_j$$

$$F_0 = \frac{(\hat{\beta}_j - 0)^T (C_{jj})^{-1} (\hat{\beta}_j - 0) / 1}{\hat{\sigma}^2} \sim f_{1, n-p}$$

$$= \frac{\hat{\beta}_j^T \hat{\beta}_j}{\hat{\sigma}^2 C_{jj}} = \frac{\hat{\beta}_j^2}{\hat{\sigma}^2 C_{jj}} \sim f_{1, n-p}$$

$$T_{j,0} = \frac{\hat{\beta}_j}{\sqrt{\hat{\sigma}^2 C_{jj}}}$$

$$T_{j,0}^2 = \frac{\hat{\beta}_j^2}{\hat{\sigma}^2 C_{jj}} \sim t_{n-p}$$

1. Determine cuál es el modelo empleado en esta situación, junto con sus supuestos. Además, reporte la recta de regresión ajustada y calcule los residuales del modelo.

- Determine la significancia de la regresión global a través del método de sumas de cuadrados extra. ¿Cree usted que puede realizarse esta prueba empleando otro método? De ser así, pruébelo.
- Determine la significancia de los parámetros individuales β_j , junto con el intervalo de confianza. Brinde una interpretación apropiada.
- Realice una prueba de hipótesis para determinar si los efectos de las tres primeras covariables son estadísticamente iguales.

1- $y = X\beta + \epsilon \quad \epsilon \sim N(0, \sigma^2 I)$

$\hat{y} = X\hat{\beta} \quad \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \hat{\beta}_3 x_{i3} + \hat{\beta}_4 x_{i4}$

$e = y - \hat{y}$

```
> head(model$coefficients)
(Intercept) Ingresos Salud Trabajo Capital
11.5446037 -0.2252440 2.0673610 0.7985207 4.5861238
> head(model$residuals)
1 2 3 4 5 6
-0.1679993 -1.1570217 -1.5253530 -1.3756175 -1.2720186 -1.3799806
```

$\hat{y}_i = 11.54 - 0.22x_{i1} + 2.067x_{i2} + 0.798x_{i3} + 4.586x_{i4}$

2-

$\epsilon_i \sim N(0, \sigma^2)$


MF: $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \epsilon_i$

MR: $y_i = \beta_0 + \epsilon_i$

$F_0 = \frac{SSR/k}{SSE/(n-p)} \sim f_{k,n-p}$

Dos colas: $1 - \frac{\alpha}{2}$ (Bilateral)
Una cola: $1 - \alpha$ (Unilateral)

$SSR = SSE_{MF} - SSE_{MR}$




$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$

H_a : Al menos algún β_j es diferente de 0

$F = \frac{(L\hat{\beta})^T (L(X^T X)^{-1} L^T)^{-1} (L\hat{\beta})}{r \hat{\sigma}^2}$

3-

P.H: $\begin{cases} H_0: \beta_{ij} = 0 \\ H_a: \beta_{ij} \neq 0 \end{cases}$



$\hat{\beta}_{ij} \pm t_{\frac{\alpha}{2}, n-p} \sqrt{\hat{\sigma}^2 c_{ij}}$

con una confianza del 95% se puede establecer que el efecto promedio del ingreso está entre -1.74 y 1.29 unidades, es decir, que por unidad de cambio en el ingreso, el IMCV promedio varía entre -1.74 y 1.29 unidades

4- Bajo $H_0: \beta_1 = \beta_2 = \beta_3$

$y_i = \beta_0 + (x_{i1} + x_{i2} + x_{i3})\beta_1 + x_{i4}\beta_4 + \epsilon_i$

$\epsilon_i \sim N(0, \sigma^2)$

Bajo H_a :

$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \epsilon_i$

P.H = $\begin{cases} H_0: \beta_1 = \beta_2 = 0 \\ \beta_1 = \beta_3 = 0 \\ H_a: \text{Algun } \beta_j \neq 0 \quad j=1,2,3 \end{cases}$