

P. 1 En el modelo de RLM, ¿cuál de las siguientes afirmaciones sobre la matriz $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ es correcta?


- ~~×~~a. Es simétrica y no cumple que $\mathbf{H} \cdot \mathbf{H} = \mathbf{H}^2 = \mathbf{H}^T$. (idempotente)
 $\checkmark$ b. Es simétrica e idempotente, y proyecta el vector $\mathbf{y}$ sobre el espacio columna de $\mathbf{X}$.
~~×~~c. Es simétrica e idempotente, y se cumple que $(\mathbf{I} - \mathbf{H})$ no es idempotente.
~~×~~d. La traza de $\mathbf{H}$ es igual a p , donde $p = (k) + 1$. k : # de predictores

$\mathbf{H} \rightarrow$ simétrica $n \times n$ $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$

$\mathbf{H}^2 = \mathbf{X} \underbrace{(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}}_{\mathbf{I}_p} (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$

$\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$
 $= \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$
 $\hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$

$\mathbf{H}^2 = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \mathbf{H}$



$\mathbf{X} = \begin{bmatrix} 1 & x_{12} & \dots & x_{1p} \\ 1 & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n2} & \dots & x_{np} \end{bmatrix} \in \mathbb{R}^{n \times p}$

$\mathbf{H}^2 = \mathbf{H} \quad \mathbf{I}^2 = \mathbf{I}$

$(\mathbf{I} - \mathbf{H})^2 = \mathbf{I}^2 - 2\mathbf{I}\mathbf{H} + \mathbf{H}^2$

$= \mathbf{I} - 2\mathbf{H} + \mathbf{H} = (\mathbf{I} - \mathbf{H})$

$\text{rango}(\mathbf{H}) = p$
 $= \dim \text{espacio columna } \mathbf{X}$

$\text{tr}(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') = \text{tr}(\underbrace{\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}}_{\mathbf{I}})$

$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{CAB}) = \text{tr}(\mathbf{I}_p) = p$

P. 2 En el modelo de RLM, el estimador de mínimos cuadrados $\hat{\beta} = (X'X)^{-1}X'y$ satisface:

✓ a. $\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2(\mathbf{X}'\mathbf{X}))$, ya que es combinación lineal de observaciones normales.

✓b. $\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$, y coincide con el estimador de máxima verosimilitud bajo el modelo lineal normal.

X c. $\hat{\beta} \sim \mathcal{N}(0, \sigma^2(\mathbf{X}'\mathbf{X})^{-1})$, pues su media es cero por la definición de mínimos cuadrados.

$\times^d$. $\hat{\beta} \sim t_{n-p}$, con $p = k + 1$ parámetros en el modelo.

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad (MCO) \quad y = X\beta + \varepsilon \quad \varepsilon \sim N(0, \sigma^2 I)$$

$$= (X^T X)^{-1} X^T (X\beta + \varepsilon)$$

$$= \underbrace{(X^T X)^{-1} X^T X}_{\text{fija}} \beta + \underbrace{(X^T X)^{-1} X^T}_{N} \varepsilon$$

observado y fijo fijo pero desconocido si es v.a

$$\hat{\beta} \sim N(\beta, \sigma^2 (X^T X)^{-1})$$

$$\begin{aligned}\mathbb{E}[\hat{\beta}] &= \mathbb{E}\left[(X^T X)^{-1} X^T X \beta + \cancel{(X^T X)^{-1} X^T \epsilon}\right] \\ &= \mathbb{E}\left[(X^T X)^{-1} X^T X \beta\right] + \cancel{\mathbb{E}\left[(X^T X)^{-1} X^T \epsilon\right]} \\ &= \underbrace{(X^T X)^{-1} X^T X}_{I_p} \beta = \beta\end{aligned}$$

$$\text{Var}[\hat{\beta}] = \text{Var}\left[\underbrace{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T}_{\mathbf{A}} \mathbf{y}\right] = \text{Var}[\mathbf{A} \mathbf{y}]$$

$$\begin{aligned} \text{Var}[aX] &= a^2 \text{Var}[X] \\ &= A \text{Var}[y] A^T \\ &= (X^T X)^{-1} X^T \text{Var}[y] X (X^T X)^{-1} \\ &= \text{Var}[y] \underbrace{(X^T X)^{-1} X^T X (X^T X)^{-1}}_{I_p} \\ &= \text{Var}[y] (X^T X)^{-1} \\ &= \sigma^2 (X^T X)^{-1} \end{aligned}$$

Para β : $\hat{\beta}_{MCO} = \hat{\beta}_{ML}$

Para σ^2 : $\hat{\sigma}_{MCO}^2 \neq \underbrace{\hat{\sigma}_{ML}^2}_{\text{segunda}}$

P. 3 Sobre el estadístico de prueba para la significancia general del modelo de RLM, ¿cuál de las siguientes opciones es correcta?

✓ a. $F_0 = \frac{MSR}{MSE} \sim F_{k, n-p}$, y se rechaza $H_0 : \beta_1 = \dots = \beta_k = 0$ para valores grandes de F_0 .

✗ b. $F_0 = \frac{MSE}{MSR} \sim F_{k, n-p}$, y se rechaza H_0 para valores pequeños de F_0 .

✗ c. $F_0 = \frac{MSR}{MSE} \sim F_{n-p, k}$, y se rechaza H_0 si $F_0 > f_{\alpha; n-p, k}$.


✗ d. $F_0 = \frac{SSR}{SSE} \sim F_{k, n-p}$, pues los grados de libertad se cancelan en el cociente.

ojo, cuidado si
Pore P esta malo

$$H_0: \beta_1 = \dots = \beta_k = 0$$

$$H_a: \text{Algun } \beta_j \neq 0 \quad j=1, \dots, k$$

$$F = \frac{SSR/k}{SSE/(n-p)} = \frac{MSR}{MSE} \sim f_{k, n-p}$$



$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \varepsilon_i$$

$$\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$

$$\varepsilon \sim N(0, \sigma^2 I)$$

P. 4 En el contexto de las sumas de cuadrados extra, para el modelo $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$, ¿cuál de las siguientes expresiones es correcta para $SSR(\beta_2 | \beta_0, \beta_1)$?

✓ a. $SSR(\beta_2 | \beta_0, \beta_1) = SSR(\beta_0, \beta_1, \beta_2) - SSR(\beta_0, \beta_1) = SSE(\beta_0, \beta_1) - SSE(\beta_0, \beta_1, \beta_2)$.

✗ b. $SSR(\beta_2 | \beta_0, \beta_1) = SSR(\beta_0, \beta_1, \beta_2) - SSR(\beta_0, \beta_1)$, ya que se fija el intercepto

✗ c. $SSR(\beta_2 | \beta_0, \beta_1) = SSE(\beta_0, \beta_1, \beta_2) - SSE(\beta_0, \beta_1)$, pues la SSextra mide el incremento *disminuye* en el error.

✗ d. $SSR(\beta_2 | \beta_0, \beta_1) = SST - SSE(\beta_0, \beta_1, \beta_2)$, que es la reducción total explicada por β_2 .

$$\underbrace{SST}_{\text{cantidad fija}} = \underbrace{SSR + SSE}_{\substack{\text{al ingresar} \\ \beta_j \text{ aumenta}}} \quad \left. \begin{array}{l} \text{Al ingresar } \beta_j \\ \text{disminuye} \end{array} \right\}$$

Parsimonia $\rightarrow$ Preferimos el modelo más simple posible

$$\begin{aligned} SSR(\beta_2 | \beta_0, \beta_1) &= SSR(MF) - SSR(MR) \\ &= SSR(\beta_0, \beta_1, \beta_2) - SSR(\beta_0, \beta_1) \\ &= SSE(\beta_0, \beta_1) - SSE(\beta_0, \beta_1, \beta_2) \end{aligned}$$

P. 5 En el modelo de RLM, un intervalo de confianza del $(1 - \alpha)\%$ para el parámetro β_j está dado por:


- ✓ a. $\hat{\beta}_j \pm t_{1-\alpha/2, n-p} \cdot ee(\hat{\beta}_j)$, con $p = k + 1$ y $ee(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 c_{jj}}$.
- ✗ b. $\hat{\beta}_j \pm z_{1-\alpha/2} \cdot ee(\hat{\beta}_j)$, pues por el TLC los estimadores son asintóticamente normales.
- ✗ c. $\hat{\beta}_j \pm t_{1-\alpha/2, n-\overset{p}{k}} \cdot ee(\hat{\beta}_j)$, ya que los grados de libertad corresponden a $n - k$.
- ✗ d. $\hat{\beta}_j \pm t_{\alpha/2, n-p} \cdot ee(\hat{\beta}_j)$, ya que se usa el cuantil inferior de la distribución t .

$$T_{j10} = \frac{\beta_j - \hat{\beta}_j}{ee(\hat{\beta}_j)} \sim t_{n-p} \quad \text{dos colas} \quad ee(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 c_{jj}}$$

$$\hat{\beta}_j \pm t_{1-\frac{\alpha}{2}, n-p} ee(\hat{\beta}_j)$$

$$H_0: \beta_j = 0$$

$$H_a: \beta_j \neq 0$$



P. 6 Sobre el coeficiente de determinación R^2 y el R^2 ajustado en RLM, ¿cuál de las siguientes afirmaciones es correcta?



- ✓a. El R^2 ajustado se define como $R^2_{adj} = 1 - \frac{(n-1)MSE}{SST}$ y puede disminuir al agregar predictoras no informativas.
- ✗b. El R^2 ajustado siempre es mayor o igual al R^2 ordinario, pues penaliza modelos sobreparametrizados.
 siempre crece
- ✗c. El R^2 ordinario puede disminuir al agregar más variables predictoras al modelo.
- ✗d. Un $R^2 \approx 1$ garantiza que el modelo es útil para predicción en toda la región del espacio de predictoras.
 No dice nada sobre extrapolación

$R^2 \longrightarrow$ * No significa que el modelo sea útil para predicción o inferencia

* $R^2 \approx 1$ no significa que el modelo sea útil

* $R^2 \approx 0$ no significa que no haya relación entre X y Y

Lineal en β_0



$$Y = \beta_0 + \beta_2 X_2 + \beta_1 X_3 + \epsilon$$

$$MR: Y = \beta_0 + \beta_1 (X_1 + X_3) + \epsilon$$

$$L = \begin{pmatrix} \beta_0 & 0 & 1 & 0 & -1 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \end{pmatrix}$$

P. 7 Para probar simultáneamente $H_0: \beta_1 = \beta_3, \beta_2 = 0$ en el modelo:

Test lineal general

$$Y = (\beta_0) + (\beta_1)X_1 + (\beta_2)X_2 + (\beta_3)X_3 + \epsilon \quad MF$$

el estadístico de prueba es:

a. $F_0 = \frac{SC_{Extra}/2}{MSE(FM)} \sim F_{2, n-4}$, donde $SC_{Extra} = SSE(RM) - SSE(FM)$ es la suma de cuadrados extra debida a la hipótesis, con un modelo reducido:

$$Y = \beta_0 + \beta_1(X_1 + X_3) + \epsilon$$

b. $F_0 = \frac{SC_{Extra}/3}{MSE(FM)} \sim F_{3, n-4}$, pues la hipótesis nula impone tres restricciones independientes sobre los parámetros del modelo original.

$$F_0 = \frac{MR}{MF}$$

c. $F_0 = \frac{SC_{Extra}/2}{MSE(FM)} \sim F_{2, n-3}$, donde el modelo reducido se define únicamente por la omisión de la variable X_2 :

$$Y = \beta_0 + \beta_1 X_1 + \beta_3 X_3 + \epsilon$$

d. No es posible formular esta hipótesis dentro del marco de una hipótesis lineal general de la forma $L\beta = 0$.

$$F_0 = \frac{SC_{extra}/r}{MSE(FM)} \rightarrow \# \text{ de restricciones } L.I$$

$$= \frac{SC_{extra}/2}{SSE/n-p} = \frac{SC_{extra}/2}{SSE/n-4} \sim F_{2, n-4}$$

P. 8 En la tabla ANOVA del modelo de RLM con k predictoras y n observaciones, la identidad de sumas de cuadrados y grados de libertad es:

- ✓ a. $SST = SSR + SSE$, con grados de libertad $(n - 1) = k + (n - p)$, donde $p = k + 1$.
- ✗ b. $SST = SSR + SSE$, con grados de libertad $n = k + (n - k)$, ya que SST no pierde grados de libertad.
- ✗ c. $SST = SSR + SSE$, con grados de libertad $(n - 1) = (k + 1) + (n - k - 2)$.
- ✗ d. $SSR = SST - SSE$, con $MSR = SSR/k$ y $MSE = SSE/(n - p)$.

$$SST = SSR + SSE$$

$$g|(SST) = g|(SSR) + g|(SSE)$$

$$n - 1 = k + (n - p)$$

$$SST = \sum_{i=1}^n (\hat{y}_i - \underbrace{\bar{y}}_{1 \text{ promedio}})^2$$

P. 9 La prueba de significancia individual de β_j basada en SS_{extra} y la prueba t individual son:

a. Equivalentes, ya que $F_{j,0} = T_{j,0}^2$ y los valores- P de ambas pruebas coinciden.

☒ Diferentes, porque la prueba F es siempre de cola derecha mientras que la prueba t es de dos colas.

☒ Equivalentes solo cuando $n > 30$, pues para muestras pequeñas la distribución F y la t^2 difieren.

☒ Diferentes, ya que la prueba F usa como denominador el MSE del modelo ~~reducido~~ y no del modelo completo.

P. 10 En el modelo de RLM, el estimador insesgado de σ^2 es:

✓ $\hat{\sigma}^2 = \frac{\sum e_i^2}{n-p} = \frac{\mathbf{y}'(\mathbf{I}-\mathbf{H})\mathbf{y}}{n-p}$, con $p = k+1$.

✗ $\hat{\sigma}^2 = \frac{\sum e_i^2}{n}$, el promedio de los cuadrados de los residuales.

✗ $\hat{\sigma}^2 = \frac{\sum e_i^2}{n-k}$, pues se pierden k grados de libertad por las k predictoras.

✗ $\hat{\sigma}^2 = \frac{\sum e_i^2}{n-1}$, en analogía con la varianza muestral clásica.

$$\hat{\sigma}^2 = MSE = \frac{\sum (y_i - \hat{y})^2}{n-p} = \frac{\vec{e}^2}{n-p} = \frac{\mathbf{y}'(\mathbf{I}-\mathbf{H})\mathbf{y}}{n-p}$$

$$e = \sum (y_i - \hat{y})^2$$

$$= (\underline{y} - \hat{\underline{y}})^2$$

$$= (\underline{y} - \mathbf{H}\underline{y})^2 = ((\mathbf{I}-\mathbf{H})\underline{y})^2$$

$$\underbrace{(\mathbf{I}-\mathbf{H})}_{\text{idempotente}} = \underline{y}'(\mathbf{I}-\mathbf{H})^2 \underline{y} = \underline{y}'(\mathbf{I}-\mathbf{H})\underline{y}$$

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	70.80225	2.45665	28.82	<2e-16 ***
X1	0.88463	0.02848	31.06	<2e-16 ***
X2	1.87368	0.02073	90.41	<2e-16 ***
X3	3.04502	0.02789	109.19	<2e-16 ***

$T_{\beta_0,0}$

$\alpha = 0.05$

$H_0: \beta_0 = 0$

$H_a: \beta_0 \neq 0$

```
data <- read.csv(
  )
mod <- glm(y ~ X1 + X2, data = data)
```

Summary(mod)

$$\hat{y} = 70.80 + 0.884 X_1 + 1.87 X_2 + 3.045 X_3$$

```
> anova(modelo_reducido) solo  $\beta_0$ 
```

Analysis of Variance Table

Response: Y

Df Sum Sq Mean Sq F value Pr(>F)

Residuals 499 2183751 4376.3

$n-1$

SST

modelo = reducido

$\downarrow$

$\varphi_m(y \sim 1, data = data)$

```
> anova(modelo)
```

Analysis of Variance Table

Response: Y

Df Sum Sq Mean Sq F value Pr(>F)

X1 1 78308 78308 755.26 < 2.2e-16 ***

X2 1 817773 817773 7887.27 < 2.2e-16 ***

X3 1 1236243 1236243 11923.33 < 2.2e-16 ***

Residuals 496 51427 104

F → significancia individual

$n-500$

$$M_R: \hat{y} = \hat{\beta}_0$$

$$M_F: \hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3$$

Model 1: Y ~ 1

Model 2: Y ~ X1 + X2 + X3

Res.Df RSS Df Sum of Sq F Pr(>F)

1 499 2183751

2 496 51427 3 2132324 6855.3 < 2.2e-16 ***

Test de significancia general

$\text{anova}(\text{modelo}, \text{modelo_reducido})$

$$H_0: \beta_1 = \beta_2 = \beta_3 = 0$$

$$H_a: \text{Algun } \beta_j \neq 0 \rightarrow \text{Rechazar } H_0$$

```
> confint(modelo)
```

	2.5 %	97.5 %
(Intercept)	65.9755369	75.6289713
X1	0.8286681	0.9405966
X2	1.8329626	1.9144035
X3	2.9902333	3.0998132

`modelo <- lm( ... )`

$$E[Y|X] = \beta_0 + \beta_1 X_1 + \dots$$

`confint(modelo)`

con un 95% de confianza, un aumento unitario en X_1 aumenta entre 0.82 y 0.94 el

promedio de la respuesta