

Este documento corresponde al taller de repaso del curso de **Estadística II** de la *Universidad Nacional de Colombia, Sede Medellín*, en el periodo 2026-01. Se brinda un repaso al análisis de regresión lineal múltiple. El enfoque de este taller se centra en la comprensión del modelo de regresión lineal múltiple a nivel matricial, la comprensión del análisis de varianza y la ejecución de pruebas de hipótesis a través de la suma extra de cuadrados y el método lineal general. **Monitor:** Tomás Rodríguez Taborda.

Keywords: regresión múltiple, sumas de cuadrados extra, hipótesis lineal general

Información general

Con el propósito de repasar los conceptos del modelo de regresión lineal múltiple vistos en clase, se propone desarrollar este taller en dos partes: una de teoría básica y otra práctica.

La solución para cada uno de los problemas se efectúa a partir del software estadístico R.

Parte teórica


Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación o justificación si lo considera necesario.**

1. Determine el valor de verdad de las siguientes afirmaciones.

- La matriz $\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$ es una matriz de proyección ortogonal, por lo cual satisface $\mathbf{H}\mathbf{X} = \mathbf{X}$ y $\text{tr}(\mathbf{H}) = p$, donde $p = k + 1$. En consecuencia, el vector de residuales $\mathbf{e} = (\mathbf{I}_n - \mathbf{H})\mathbf{y}$ es ortogonal a las columnas de $\mathbf{X}$, es decir, $\mathbf{X}^T\mathbf{e} = \mathbf{0}$.
- Demuestre que para probar la significancia marginal del j -ésimo parámetro en un modelo de RLM, los estadísticos $F_{j|0}$ y $T_{j|0}$ satisfacen $F_{j|0} = T_{j|0}^2$.
- El coeficiente de determinación múltiple R^2 nunca decrece al agregar variables predictoras al modelo, mientras que el R_{adj}^2 puede disminuir si la variable agregada no reduce suficientemente la SSE como para compensar la pérdida de un grado de libertad. Por tanto, entre dos modelos ajustados se prefiere el de menor MSE, o equivalentemente, el de mayor R_{adj}^2 .
- Considere el contraste lineal general $H_0: \mathbf{L}\beta = \mathbf{c}$ vs. $H_1: \mathbf{L}\beta \neq \mathbf{c}$, donde $\mathbf{L}$ es una matriz $m \times p$ con $r \leq m$ filas linealmente independientes y $\mathbf{c}$ es un vector de constantes arbitrario de dimensión $m \times 1$. Los grados de libertad asociados a

*El material asociado a este taller puede encontrarse en el repositorio del curso, (<https://github.com/torodriguez/Estadistica-II>)

$$\text{tr}(\mathbf{ABC}) = \text{tr}(\mathbf{CAB})$$



$$y = \mathbf{X}\beta + \varepsilon \quad \varepsilon \sim N(0, \sigma^2)$$

$$\hat{y} = \mathbf{X}\hat{\beta} \quad \hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

$$\hat{y} = \underbrace{\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T}_{\mathbf{H}}\mathbf{y} \quad \text{tr}(\underbrace{\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T}_{\mathbf{H}})$$

$$\hat{y} = \mathbf{H}\mathbf{y} \quad = \text{tr}(\mathbf{X}^T\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1})$$

$$\mathbf{H}\mathbf{X} = \mathbf{X} \quad = \text{tr}(\mathbf{I}_p) = p$$

$$\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{X} = \mathbf{X}$$

$$\mathbf{X}\mathbf{I}_p = \mathbf{X}$$

$$\mathbf{X} = \mathbf{X}$$

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} \quad \mathbf{X}^T\mathbf{e} = ?$$

$$= \mathbf{y} - \mathbf{H}\mathbf{y} = \mathbf{X}^T(\mathbf{I} - \mathbf{H})\mathbf{y}$$

$$= (\mathbf{I} - \mathbf{H})\mathbf{y} = (\mathbf{X}^T - \mathbf{X}^T\mathbf{H})\mathbf{y}$$

$$= (\mathbf{X}^T - \mathbf{X}^T\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T)\mathbf{y}$$

$$\mathbf{X}^T\mathbf{e} = (\mathbf{X}^T - \mathbf{X}^T)\mathbf{y} = 0$$

(b) Demuestre que para probar la significancia marginal del j -ésimo parámetro en un modelo de RLM, los estadísticos $F_{j,0}$ y $T_{j,0}$ satisfacen $F_{j,0} = T_{j,0}^2$.

$$\hat{y} = X\hat{\beta} \quad \begin{pmatrix} 1 & 1 & \dots & 1 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

$$1\hat{y} = 1X\hat{\beta}$$

$$\sum \hat{y}_i = \begin{pmatrix} \sum_{i=1}^n 1 & \sum x_i \end{pmatrix} \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{pmatrix} X = \begin{pmatrix} 1 & x_{12} \\ 1 & x_{22} \\ \vdots & \vdots \\ 1 & x_{n2} \end{pmatrix}$$

$$\sum_{i=1}^n 1 = n$$

$$\sum \hat{y}_i = n\hat{\beta}_0 + \sum x_i \hat{\beta}_1 \quad (\text{Ecuación normal})$$

$$\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$$

$$\hat{y}_i - \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 x_i - \hat{\beta}_0 - \hat{\beta}_1 \bar{x}$$

$$\hat{y}_i - \bar{y} = \hat{\beta}_1 (x_i - \bar{x}) \quad \sum (\hat{y}_i - \bar{y})^2 = \hat{\beta}_1^2 \sum (x_i - \bar{x})^2$$

$$SSR = \hat{\beta}_1^2 \sum (x_i - \bar{x})^2$$

$$SSR = (\hat{y}_i - \bar{y})^2$$

$j=0, 1, \dots, P$

$$SSR = \hat{\beta}_1^2 S_{xx}$$

$$Var(\hat{\beta}_1) = \sigma^2 (X^T X)^{-1}_{1,1} = \sigma^2 \cdot \frac{n}{n \sum x_i^2 - (\sum x_i)^2}$$

$$\sum (x_i - \bar{x})^2$$

$$= \sum x_i^2 - 2 \sum x_i \bar{x} + n \bar{x}^2$$

$$(X^T X) = \begin{pmatrix} \sum 1 & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix}$$

$$= \frac{\sigma^2 n}{\sum (x_i - \bar{x})^2}$$

$$= \sum x_i^2 - 2 \cdot \frac{n}{n} \sum x_i \bar{x} + n \bar{x}^2$$

$$= \sum x_i^2 - 2n \bar{x}^2 + n \bar{x}^2$$

$$S_{xx} \sum (x_i - \bar{x})^2 = \sum x_i^2 - n \bar{x}^2$$

$$X^T = \begin{pmatrix} 1 & 1 & \dots & 1 \\ x_{11} & x_{12} & \dots & x_{1n} \\ \vdots & \vdots & \ddots & \vdots \end{pmatrix}$$

$$= \frac{1}{\det(X^T X)} \begin{pmatrix} \sum x_i^2 & \sum x_i \\ \sum x_i & n \end{pmatrix}$$

$$= \frac{\sigma^2}{S_{xx}}$$

$$n \sum (x_i - \bar{x})^2 = n \sum x_i^2 - n^2 \left(\frac{\sum x_i}{n} \right)^2$$

$$= n \sum x_i^2 - (\sum x_i)^2$$

$$X = \begin{pmatrix} 1 & x_{11} \\ 1 & x_{12} \\ \vdots & \vdots \\ 1 & x_{1n} \end{pmatrix}$$

$$\det(X^T X) = n \sum x_i^2 - (\sum x_i)^2$$

$k=1$

sin el intercepto

$$F = \frac{SSR / k}{\frac{SSE / \sigma^2}{n-P}} = \frac{SSR}{\frac{1}{\frac{SSE}{n-2}}} = \frac{SSR}{MSE} = \frac{\hat{\beta}_1^2 S_{xx}}{\hat{\sigma}^2}$$

con el intercepto

$$MSE = \hat{\sigma}^2 = \frac{\sum (y_i - \hat{y})^2}{n - (k+1)}$$

$$P = k+1$$

$$H_0: \beta_j = 0$$

$$H_a: \beta_j \neq 0$$

$$T_{j,0} = \frac{\hat{\beta}_j - \beta_j}{\sqrt{Var(\hat{\beta}_j)}}$$

$$(T_{j,0})^2 = \frac{\hat{\beta}_j^2}{Var(\hat{\beta}_j)} = \frac{\hat{\beta}_1^2 S_{xx}}{\hat{\sigma}^2}$$

- (c) El coeficiente de determinación múltiple R^2 nunca decrece al agregar variables predictoras al modelo, mientras que el R^2_{adj} puede disminuir si la variable agregada no reduce suficientemente la SSE como para compensar la pérdida de un grado de libertad. Por tanto, entre dos modelos ajustados se prefiere el de menor MSE, o equivalentemente, el de mayor R^2_{adj} .

Capacidad
fija
↓

$$SST = SSR + SSE$$

c) Verdadero

Parsimonia

$$SSE(\text{Full}) \leq SSE(\text{reducido})$$

$$R^2 = 1 - \frac{SSE}{SST}$$

$$R^2_{adj} = 1 - \frac{(n-1)MSE}{SST}$$

$\swarrow$ $n-p$
 $\frac{SSE}{n-p} = MSE \uparrow$
 $\uparrow$

la suma de cuadrados debida a la hipótesis son iguales a r , y pueden calcularse como la diferencia entre los grados de libertad de la SSE del modelo reducido y la del modelo completo.

- (e) Bajo los supuestos del modelo de RLM, el intervalo de confianza del $(1 - \alpha)\%$ para el parámetro β_j ($j = 0, 1, \dots, k$) está dado por

$$\hat{\beta}_j \pm t_{1-\alpha/2, n-p} ee(\hat{\beta}_j),$$

donde $ee(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 c_{jj}}$, siendo c_{jj} el j -ésimo elemento de la diagonal principal de $(\mathbf{X}^t \mathbf{X})^{-1}$.

2. Considere el modelo de regresión lineal múltiple con $k = 4$ variables predictoras:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \varepsilon, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2).$$

Se desea probar la siguiente hipótesis:

$$H_0 : \beta_1 = \beta_2 \text{ y } \beta_3 + \beta_4 = 1 \quad \text{vs.} \quad H_1 : \text{alguna igualdad no se cumple.}$$

- (a) Reescriba H_0 en la forma $\mathbf{L}\boldsymbol{\beta} = \mathbf{c}$, especificando explícitamente las matrices $\mathbf{L}$ y $\mathbf{c}$ junto con sus dimensiones.
 - (b) Determine el número r de filas linealmente independientes de $\mathbf{L}$ y justifique su respuesta.
 - (c) Escriba el modelo reducido que se obtiene al aplicar H_0 al modelo completo.
 - (d) Escriba el estadístico de prueba F_0 y su distribución bajo H_0 , especificando los grados de libertad en el numerador y en el denominador.
3. En un modelo de RLM con k predictoras, demuestre que la prueba de significancia global de la regresión

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$$

puede formularse como un caso particular del procedimiento de sumas de cuadrados extra, con $A = \{\beta_1, \dots, \beta_k\}$ y $B = \{\beta_0\}$. Muestre que el estadístico resultante coincide con $F_0 = \text{MSR}/\text{MSE}$.

Ejercicio con datos reales

Considere el siguiente conjunto de datos que agrupa información sobre el índice multidimensional de calidad de vida de la ciudad de Medellín. **Se incluyen únicamente algunas variables** cuya descripción puede encontrarse **en el siguiente enlace:** <https://medata.gov.co/dataset/1-002-09-000041>

→ se basa en la F

(d) Considere el contraste lineal general $H_0 : \mathbf{L}\beta = \mathbf{c}$ vs. $H_1 : \mathbf{L}\beta \neq \mathbf{c}$, donde $\mathbf{L}$ es una matriz $m \times p$ con $r \leq m$ filas linealmente independientes y $\mathbf{c}$ es un vector de constantes arbitrario de dimensión $m \times 1$. Los grados de libertad asociados a

la suma de cuadrados debida a la hipótesis son iguales a r y pueden calcularse como la diferencia entre los grados de libertad de la SSE del modelo reducido y la del modelo completo.

$$H_0: \beta_1 - \beta_2 = 0$$

$$\beta_3 + \beta_4 = 1$$

$$L = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \end{pmatrix}$$

¿Cuántas son L.I.?

$$L \in \mathbb{R}^{2 \times 5}$$

$$MSE = \frac{SSE}{n-p}$$

H_a : Alg una desigualdad no se cumple

$$\dim(L) = 2 = r$$

$$\beta_1 = \beta_2$$

$$MF: y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$

$$g/(SSE(MR)) = n - (p-r) = n+r-p \quad (1)$$

$$MR \quad y_i = \beta_0 + \beta_1 (x_1 + x_2) + \beta_3 x_3$$

$$g/(SSE(MF)) = n - p \quad (2)$$

$$(1) - (2) = \cancel{n+r-p} - \cancel{n+p} = r$$

(e) Bajo los supuestos del modelo de RLM, el intervalo de confianza del $(1 - \alpha)\%$ para el parámetro β_j ($j = 0, 1, \dots, k$) está dado por

$$\hat{\beta}_j \pm t_{1-\alpha/2, n-p} ee(\hat{\beta}_j),$$


donde $ee(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 c_{jj}}$, siendo c_{jj} el j -ésimo elemento de la diagonal principal de $(\mathbf{X}^T \mathbf{X})^{-1}$.

$$\hat{\beta} \sim N_n(\beta, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$$

$$\hat{\beta}_j \sim N(\beta_j, \sigma^2 c_{jj})$$

$$\frac{\hat{\beta}_j - \beta_j}{\sqrt{\sigma^2 c_{jj}}} \sim N(0, 1)$$

$$t_j = \frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2 c_{jj}}} \sim t_{n-p}$$



$$P\left(-t_{\frac{\alpha}{2}, n-p} \leq \frac{\hat{\beta}_j - \beta_j}{\sqrt{\hat{\sigma}^2 c_{jj}}} \leq t_{1-\frac{\alpha}{2}, n-p}\right) = 1 - \alpha$$

$$P\left(\hat{\beta}_j - t_{\frac{\alpha}{2}, n-p} \sqrt{MSE \cdot c_{jj}} \leq \beta_j \leq \hat{\beta}_j + t_{1-\frac{\alpha}{2}, n-p} \sqrt{MSE \cdot c_{jj}}\right) = 1 - \alpha$$

$$\hat{\beta}_j \pm t_{1-\frac{\alpha}{2}, n-p} \sqrt{\underbrace{MSE \cdot c_{jj}}_{\text{Fuentes de variabilidad}}} \rightarrow (\mathbf{X}^T \mathbf{X})^{-1}$$

Fórmula = $1 - \alpha$

2. Considere el modelo de regresión lineal múltiple con $k = 4$ variables predictoras:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \varepsilon, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2).$$

Se desea probar la siguiente hipótesis:

$$H_0: \beta_1 = \beta_2 \text{ y } \beta_3 + \beta_4 = 1 \quad \text{vs.} \quad H_1: \text{alguna igualdad no se cumple.}$$

(a) Reescriba H_0 en la forma $L\beta = c$ especificando explícitamente las matrices L y c junto con sus dimensiones.

(b) Determine el número r de filas linealmente independientes de L y justifique su respuesta.

(c) Escriba el modelo reducido que se obtiene al aplicar H_0 al modelo completo.

(d) Escriba el estadístico de prueba F_0 y su distribución bajo H_0 , especificando los grados de libertad en el numerador y en el denominador.

$$H_0: \begin{cases} \beta_1 - \beta_2 = 0 \\ \beta_3 + \beta_4 = 1 \end{cases} \quad H_a: \text{Alguna desig. no se cumple}$$

$$L = \begin{pmatrix} 0 & 1 & -1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \end{pmatrix} \quad 2 \times 5$$

b) $r = 2$, las coordenadas son disyuntas

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix} \quad 5 \times 1 \quad c = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \quad 2 \times 1$$

$$H_0: L\beta = c \quad H_a: L\beta \neq c$$

$$\begin{pmatrix} 0 & 1 & -1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

$$\beta_1 = \beta_2 = \gamma_1$$

$$\text{By } H_0: \beta_4 = 1 - \beta_3 = 1 - \gamma_2$$

$$\begin{aligned} Y &= \beta_0 + \gamma_1 (X_1 + X_2) + \gamma_2 X_3 + (1 - \gamma_2) X_4 + \varepsilon \\ &= \beta_0 + \gamma_1 (X_1 + X_2) + \gamma_2 X_3 + X_4 - \gamma_2 X_4 + \varepsilon \\ &= \beta_0 + \gamma_1 \underbrace{(X_1 + X_2)}_{Z_1} + \gamma_2 \underbrace{(X_3 - X_4)}_{Z_2} + X_4 + \varepsilon \end{aligned}$$

$$Y = \beta_0 + \gamma_1 Z_1 + \gamma_2 Z_2 + X_4 + \varepsilon$$

$$Y - X_4 = \beta_0 + \gamma_1 Z_1 + \gamma_2 Z_2 + \varepsilon$$

$$Y^* = \beta_0 + \gamma_1 Z_1 + \gamma_2 Z_2 + \varepsilon$$

By H_0 (MR)

$$\begin{aligned} g.l(MR) &= 5 - 2 = 3 \\ g.l(SSE) &= n - 3 \\ F_0 &= \frac{\frac{SSR/\cancel{K}}{K}}{\frac{SSE/\cancel{n-p}}{n-p}} = \frac{SSR/K}{MSE} = \frac{SSR/\textcircled{2}}{SSE/\textcircled{n-p}} \stackrel{H_0}{\sim} f_{2, n-5} \end{aligned}$$

↑
para MF

3. En un modelo de RLM con k predictoras, demuestre que la prueba de significancia global de la regresión

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

puede formularse como un caso particular del procedimiento de sumas de cuadrados extra, con $A = \{\beta_1, \dots, \beta_k\}$ y $B = \{\beta_0\}$. Muestre que el estadístico resultante coincide con $F_0 = \text{MSR}/\text{MSE}$.

$$F = \frac{\text{SS extra}/r}{\text{MSE(MF)}} \rightarrow \frac{\boxed{\text{SSR}}/k}{\text{MSE}} = \frac{\text{MSR}}{\text{MSE}}$$

$$\text{SSR}(\text{A}|\text{B}) = \text{SSR(MF)} - \cancel{\text{SSR(MR)}} = \boxed{\text{SSR(MF)}}$$

$$= \text{SSE(MR)} - \text{SSE(MF)}$$

$$F_0 = \frac{\text{SSR}/k}{\text{MSE}} \stackrel{H_0}{\sim} f_{k, n-p}$$

Table 1: Información en análisis

IMCV	Ingresos	Salud	Trabajo	Capital
32.06	0.780000	2.550000	0.5100000	3.310000
32.88	0.960000	2.620000	0.5200000	3.680000
33.27	1.100000	2.650000	0.5700000	3.830000
32.82	1.121182	2.569105	0.5520319	3.739863
33.53	1.039000	3.041000	0.4850000	3.667000

Considere a *IMCV* como la variable respuesta. Las covariables consideradas en el análisis se especifican en la tabla anterior. **Dé respuesta a los siguientes planteamientos:**

1. Ajuste el modelo completo y construya intervalos de confianza del 95% para cada parámetro β_j , $j = 1, 2, 3, 4$. Brinde una interpretación del intervalo asociado a la covariable *Ingresos* en el contexto del problema. Justifique porque no se calculo el intervalo para β_0
2. Para la covariable *Salud*, verifique numéricamente la identidad $F_{j,0} = T_{j,0}^2$ calculando ambos estadísticos:
 - (a) $T_{j,0}$ a partir de $\hat{\beta}_{\text{Salud}}$ y $ee(\hat{\beta}_{\text{Salud}})$.
 - (b) $F_{j,0}$ usando sumas de cuadrados extra:

$$F_{j,0} = \frac{\text{SSR}(\beta_{\text{Salud}} \mid \beta_0, \beta_{\text{Ingresos}}, \beta_{\text{Trabajo}}, \beta_{\text{Capital}})}{\text{MSE}}.$$

Compare los p -valores de ambos procedimientos y concluya.

3. Usando el método de sumas de cuadrados extra, pruebe si el subconjunto $\{\beta_{\text{Trabajo}}, \beta_{\text{Capital}}\}$ aporta información significativa al modelo, dado que $\{\beta_0, \beta_{\text{Ingresos}}, \beta_{\text{Salud}}\}$ ya están presentes. Plantee las hipótesis, calcule F_0 y concluya con nivel de significancia $\alpha = 0.05$.
4. Usando el método lineal general, pruebe la hipótesis

$$H_0 : \beta_{\text{Ingresos}} = \beta_{\text{Salud}} \text{ y } \beta_{\text{Trabajo}} + \beta_{\text{Capital}} = 1,$$

contra la alternativa de que al menos una igualdad no se cumple. Siga los pasos:

- (a) Especifique explícitamente $\mathbf{L}$ y $\mathbf{c}$.
 - (b) Plantee el modelo reducido correspondiente.
 - (c) Calcule la reducción en la suma de cuadrados del error al pasar del modelo reducido al modelo completo, es decir, $\text{SSE}(\text{RM}) - \text{SSE}(\text{FM})$.
 - (d) Reporte F_0 , su p -valor y concluya con $\alpha = 0.05$.
5. Ajuste un modelo reducido excluyendo la covariable con mayor p -valor marginal en el modelo completo. Compare R^2 y R_{adj}^2 de ambos modelos.