

Taller Práctico Regresión Lineal Múltiple (4) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al cuarto taller práctico del curso de **Estadística II** para la *Universidad Nacional de Colombia*, Sede Medellín, en el periodo 2025 - 1. Se brinda una introducción al análisis de regresión. El enfoque de este taller está en la comprensión del problema de multicolinealidad (efectos y diagnósticos), así como el método de todas las regresiones posibles para la selección de variables. **Monitor:** *Tomás Rodríguez Taborda*.

Keywords: regresión múltiple, multicolinealidad, selección

Información general

Con el propósito de profundizar en los conceptos del modelo de regresión lineal múltiple vistos en clase, se propone afrontar este taller en dos partes, una de teoría básica y otra práctica.

La solución para cada uno de los problemas se efectúa a partir del software estadístico R.

Parte teórica

Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación de ser necesario.**

1. Determine el valor de verdad de las siguientes afirmaciones.

- (a) Bajo el modelo de regresión lineal múltiple $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \varepsilon_i; \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, la comparación de los efectos parciales de las variables debe realizarse a través del **escalamiento normal unitario de las covariables**.
- (b) La multicolinealidad refiere a la dependencia lineal casi perfecta entre covariables, afectando la matriz $\mathbf{X}'\mathbf{X}$. Esta puede descartarse si la correlación entre un par de variables $X_i \neq X_j$ es pequeña.
- (c) La multicolinealidad puede causar la inflación de las varianzas de los estimadores, además de estimadores $\hat{\beta}_j$ muy grandes en términos absolutos y valores de los coeficientes estimados con signo contrario a lo esperado.
- (d) Una forma en la que se manifiesta la multicolinealidad grave es cuando el modelo de regresión ajustado es significativo (globalmente), pero los parámetros individuales no lo son.

*El material asociado a este taller puede encontrarse en el repositorio del curso, (<https://github.com/torodrigueztoro/Estadistica-II>)

- (e) Dado que el estadístico C_p es una medida del sesgo del modelo, se prefiere el estadístico más bajo, puesto que a mayor sesgo mayor C_p .
- (f) La suma de cuadrados de los errores de predicción $e_{(i)} = Y_i - \hat{Y}_{i(i)}$ mide qué tan bien los valores ajustados por un submodelo predicen las respuestas observadas. **Mejor se considerará el modelo entre mayor sea esta métrica.**

Ejercicio con datos reales

Considere el siguiente conjunto de datos que agrupa información sobre el índice multidimensional de calidad de vida de la ciudad de Medellín. **Se incluyen únicamente algunas variables** cuya descripción puede encontrarse **en el siguiente enlace:** <https://medata.gov.co/dataset/1-002-09-000041>

Table 1: Información en análisis

IMCV	Ingresos	Salud	Trabajo	Capital
32.06	0.780000	2.550000	0.5100000	3.310000
32.88	0.960000	2.620000	0.5200000	3.680000
33.27	1.100000	2.650000	0.5700000	3.830000
32.82	1.121182	2.569105	0.5520319	3.739863
33.53	1.039000	3.041000	0.4850000	3.667000

Considere a *IMCV* como la variable respuesta. Las covariables consideradas en el análisis se especifican en la tabla anterior. **Dé respuesta a los siguientes planteamientos:**

1. Escriba el modelo de regresión lineal múltiple, junto con sus supuestos. Deduzca a partir del modelo ajustado si podría haber problemas de multicolinealidad.
2. Realice un análisis de multicolinealidad a través del criterio del factor de inflación de varianza, número de condición, índice de condición y proporción de descomposición de varianza.
3. Use el método de todas las regresiones posibles para seleccionar los mejores submodelos en función de los criterios R_p^2 , $R_{adj(p)}^2$ (o bien MSE_p) y C_p . **Posteriormente seleccione el mejor modelo.**

Observación: Es idóneo recordar que los criterios R_p^2 , MSE_p permiten escoger modelos que ajusten bien a los datos, mientras que, por su parte, C_p de Mallows permite escoger el mejor modelo para predecir.