

Determine el valor de verdad de las siguientes afirmaciones.

- ✓ (a) Bajo el modelo de regresión lineal múltiple $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \varepsilon_i$; $\varepsilon_i \sim N(0, \sigma^2)$, la comparación de los efectos parciales de las variables debe realizarse a través del escalamiento normal unitario de las covariables.
- ✗ (b) La multicolinealidad refiere a la dependencia lineal casi perfecta entre covariables, afectando la matriz ~~X'X~~. Esta puede descartarse si la correlación entre un par de variables $X_i \neq X_j$ es pequeña. ~~F~~
- ✓ (c) La multicolinealidad puede causar la inflación de las varianzas de los estimadores, además de estimadores $\hat{\beta}_j$ muy grandes en términos absolutos y valores de los coeficientes estimados con signo contrario a lo esperado.
- ✓ (d) Una forma en la que se manifiesta la multicolinealidad grave es cuando el modelo de regresión ajustado es significativo (globalmente), pero los parámetros individuales no lo son.
- ✗ (e) Dado que el estadístico C_p es una medida del sesgo del modelo, se prefiere el estadístico más bajo, puesto que a mayor sesgo mayor C_p . $|C_p - p|$
- ✗ (f) La suma de cuadrados de los errores de predicción $e_{(i)} = Y_i - \hat{Y}_{(i)}$ mide qué tan bien los valores ajustados por un submodelo predicen las respuestas observadas. Mejor se considerará el modelo entre ~~mayor~~ sea esta métrica.

t-student: t den no significativas
 F : El modelo global es significativo.

$$T_j = \frac{\beta_0}{se(\beta_j)} \leftarrow \text{Muy grande, el 0 está en el intervalo}$$

a) Verdadero

X_1 : Edad X_2 : Salario
 β_1 β_2 } Refleja las unidades de X_j

$$Y_i^* = \beta_1^* X_{i1}^* + \beta_2^* X_{i2}^* \dots + \beta_k^* X_{ik}^* + \varepsilon_i \quad \text{con } \varepsilon_i \sim N(0, \sigma^2)$$

$$Y_i^* = \frac{Y_i - \bar{Y}}{\sqrt{\sum_{h=1}^n (Y_h - \bar{Y})^2}} = \frac{Y_i - \bar{Y}}{\sqrt{S_y y}} \quad X_{ij}^* = \frac{X_{ij} - \bar{X}_j}{\sqrt{\sum_{h=1}^n (X_{hj} - \bar{X}_j)^2}} = \frac{X_{ij} - \bar{X}_j}{\sqrt{S_{xx}}}$$

β_j^* mide el efecto de X_j^* dado que las demás V.P. están en el modelo. Son adimensionales y son comparables.

b) $\text{Corr}(X_i, X_j)$ pequeña no implica la ausencia de multicolinealidad. Matriz de correlación, es algo descriptivo.

VIF $\left\{ \begin{array}{l} \text{Número de condición} \\ \text{Índices de condición} \end{array} \right.$

$$R_u^2 \quad X_4 \sim X_1 + X_2 + X_3$$

c) Verdadero.

* Efecto 1: Inflación de las varianzas

$$\text{Var}(\beta_j^*) = \sigma^2 c_{jj}^* \quad c_{jj}^* = \frac{1}{1 - R_j^2}$$

s.e. van a ser gigantes

R_j^2 : Variable respuesta X_j y las demás X_i son predictoras

* Efecto 2: Estimadores grandes en términos de valor absoluto.

$$\text{tr}(X'X)^{-1} = \sum \frac{1}{\lambda_j}$$

si $\lambda_j \rightarrow 0$ la traza se vuelve gigante.

Estimadores muy grandes, matriz es mal condicionada, estimadores inestables

* Efecto 3: Signos contrarios.

Punkye Preba Subar M : M
Estimado : X_j
 En regalo

d) Verdadero.

↑ sube


$$e) C_p = \underbrace{\frac{SSE_p}{MSE_{Full}}}_{\text{sube}} - (n - 2p) \quad \text{Parsimoniosos}$$

$|C_p - p| \times$

f) PRESS_p : ¿Qué tan bien el uso de valores ajustados por un submodelo puede predecir las respuestas observadas?

$$e_{(i)} = y_i - \hat{y}_{(i)} \quad PRESS_p = \sum_{i=1}^n e_{(i)}^2$$

Leave-one out



	IMCV	Ingresos	Salud	Trabajo	Capital
	32.06	0.780000	2.550000	0.5100000	3.310000
	32.88	0.960000	2.620000	0.5200000	3.680000
	33.27	1.100000	2.650000	0.5700000	3.830000
	32.82	1.121182	2.569105	0.5520319	3.739863
	33.53	1.039000	3.041000	0.4850000	3.667000

Considere a *IMCV* como la variable respuesta. Las covariables consideradas en el análisis se especifican en la tabla anterior. **Dé respuesta a los siguientes planteamientos:**

- ✓ Escriba el modelo de regresión lineal múltiple, junto con sus supuestos. Deduzca a partir del modelo ajustado si podría haber problemas de multicolinealidad.
- ✓ Realice un análisis de multicolinealidad a través del número de condición e índice de condición.
3. Use el método de todas las regresiones posibles para seleccionar los mejores submodelos en función de los criterios R^2 , R^2_{adj} (o bien MSE_p) y C_p . **Posteriormente seleccione el mejor modelo.**

$$\epsilon_i \sim N(0, \sigma^2)$$

$$1- IMCV_i = \beta_0 + \beta_1 Ingresos_i + \beta_2 Salud_i + \beta_3 Trabajo_i + \beta_4 Capital_i + \epsilon_i$$

```

Coefficients:
(Intercept) 11.5446 1.3315 8.671 4.13e-15 ***
X1          -0.02252 0.7715 -0.292 0.0721 Ingresos
X2           2.0674 0.4641 4.454 1.56e-05 ***
X3           0.7985 1.3151 0.607 0.0549 Trabajo
X4           4.5861 0.2321 19.759 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.376 on 163 degrees of freedom
Multiple R-squared:  0.9857,    Adjusted R-squared:  0.9854 
F-statistic: 2814 on 4 and 163 DF,  p-value: < 0.000000e+00
> |

```

```

> cor(datos[, -1])
#Ingresos  Salud  Trabajo  Capital
Ingresos  1.0000000 0.8660741 0.4288694 0.9773126
Salud     0.8660741 1.0000000 0.3179704 0.8776053
Trabajo   0.4288694 0.3179704 1.0000000 0.4400835
Capital   0.9773126 0.8776053 0.4400835 1.0000000
> |

```

Corr (Ingresos, Salud) Corr (Capital, Ingresos)
y Corr (Capital, Salud) son altas $\rightarrow$ sospecha de multicolinealidad

2- Para diagnosticar:

$$* VIF = \frac{1}{1 - R_i^2}$$

$VIF > 10$ Multicolinealidad grave
 $5 \leq VIF \leq 10$ Multicolinealidad moderada
 $VIF < 5$ No hay problemas de multicolinealidad

* Número de condición $k = \frac{\lambda_{max}}{\lambda_{min}}$

$\sqrt{k} \leq 10$ no hay problema
 $10 < \sqrt{k} \leq 31.62$ moderada
 $\bullet \sqrt{k} > 31.62$ grave

* Índices de condición y proporciones de varianzas

$$k_j = \frac{\lambda_{max}}{\lambda_j}$$

¿Cuáles son?

```

> myCollinDiag(modelo)
Collinearity Diagnostics

Variance Decomposition Proportions
Eigen_Value Condition_Index Intercept Ingresos  Salud  Trabajo  Capital
1  4.8666914      1.000000  0.000259 0.000234 0.000195 0.000699 0.000200
2  0.1143842      6.522796  0.014932 0.015021 0.000919 0.022038 0.011168
3  0.0133262      39.110100  0.065516 0.000559 0.082752 0.793343 0.000488
4  0.0031551      39.274361  0.372568 0.680856 0.348575 0.060712 0.299449
5  0.0024430      44.632972  0.546725 0.383330 0.567559 0.123208 0.688694

```

Intercepto $\rightarrow$ 0.5
 Salud y el Capital

$$PRESS = \frac{e_i}{(1 - h_{ii})}$$

3- $2^k - 1$ regresiones posibles

R_p^2 : Bondad del ajuste, busca maximizarlo, pero no depende con con variables

R_{adj}^2

C_p de Mallows. Buscamos el menor posible, y que se minimice $|C_p - p|$

Incluyendo el intercepto

k	R ²	adj R ²	CP	Variables.in.model
1	0.984	0.984	346.807	Capital
2	0.940	0.940	1293.539	Ingresos
3	0.793	0.791	4488.689	Salud
4	0.190	0.185	27587.257	Trabajo
5	0.986	0.986	389.386	Salud Capital
6	0.984	0.984	346.807	Trabajo Capital
7	0.984	0.984	346.816	Ingresos Capital
8	0.950	0.950	1072.589	Ingresos Salud
9	0.941	0.940	1283.091	Salud Trabajo
10	0.819	0.816	3928.752	Ingresos Trabajo
11	0.986	0.985	388.613	Salud Trabajo Capital
12	0.986	0.985	389.158	Ingresos Salud Capital
13	0.984	0.984	345.996	Ingresos Trabajo Capital
14	0.952	0.951	1047.232	Ingresos Salud Trabajo
15	0.986	0.985	388.452	5.000 Ingresos Salud Trabajo Capital

> myR2_criterion(modelo)

Models are Indexed in rows

k	p	R ²	Variables.in.model
1	2	0.9839873	Capital
2	3	0.9856865	Salud Capital
3	4	0.9857186	Salud Trabajo Capital
4	5	0.9857261	Ingresos Salud Trabajo Capital

> |

1- C_p

2- R_{adj}^2

3- Supuestos y residuos

4- Calidad de ajuste

Salud + Trabajo + Capital] Para predecir