

Corrección!! Vamos a elegir el modelo con el menor Cp. Es decir, la e es verdadero.

1. Determine el valor de verdad de las siguientes afirmaciones.

- ✓ (a) Bajo el modelo de regresión lineal múltiple $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \varepsilon_i$, $\varepsilon_i \sim N(0, \sigma^2)$, la comparación de los efectos parciales de las variables debe realizarse a través del **escalamiento normal unitario de las covariables**.
- ✗ (b) La multicolinealidad refiere a la dependencia lineal casi perfecta entre covariables, afectando la matriz ~~X'X~~. Esta puede descartarse si la correlación entre un par de variables $X_i \neq X_j$ es pequeña. F
- ✓ (c) La multicolinealidad puede causar la inflación de las varianzas de los estimadores, además de estimadores $\hat{\beta}_j$ muy grandes en términos absolutos y valores de los coeficientes estimados con signo contrario a lo esperado.
- ✓ (d) Una forma en la que se manifiesta la multicolinealidad grave es cuando el modelo de regresión ajustado es significativo (globalmente), pero los parámetros individuales no lo son.
- ✗ (e) Dado que el estadístico C_p es una medida del sesgo del modelo, se prefiere el estadístico más bajo, puesto que a mayor sesgo mayor $C_p - p$
- ✗ (f) La suma de cuadrados de los errores de predicción $e_{(i)} = Y_i - \hat{Y}_{i(i)}$ mide qué tan bien los valores ajustados por un submodelo predicen las respuestas observadas. Mejor se considerará el modelo entre ~~mayor~~ ^{menor} sea esta métrica.

t-student: t son no significativas
 F: El modelo global es significativo.

$$T_j = \frac{\beta_j}{se(\beta_j)} \leftarrow \text{Muy grande, el 0 está en el intervalo}$$

a) Verdadero
 X_1 : Edad X_2 : Salario
 β_1 β_2 } Rediga las unidades de X_j

$$Y_i^* = \beta_1^* X_{i1}^* + \beta_2^* X_{i2}^* + \dots + \beta_k^* X_{ik}^* + \varepsilon_i \quad \text{con } \varepsilon_i \sim N(0, \sigma^2)$$

$$Y_i^* = \frac{Y_i - \bar{Y}}{\sqrt{\frac{1}{n-1} \sum_{h=1}^n (Y_h - \bar{Y})^2}} = \frac{Y_i - \bar{Y}}{\sqrt{S_y y}} \quad X_{ij}^* = \frac{X_{ij} - \bar{X}_j}{\sqrt{\frac{1}{n} \sum_{h=1}^n (X_{hj} - \bar{X}_j)^2}} = \frac{X_{ij} - \bar{X}_j}{\sqrt{S_{xx}}}$$

β_j^* mide el efecto de X_j^* dado que las demás v.p. están en el modelo. Son adimensionales y son comparables.

b) $\text{Corr}(X_i, X_j)$ pequeña no implica la ausencia de multicolinealidad. Matriz de correlación, es algo descriptivo.

VIF $\begin{cases} \text{--- Número de condición} \\ \text{--- Índices de condición} \end{cases}$

$$R_4^2 \quad X_4 \sim X_1 + X_2 + X_3$$

c) Verdadero.

* Efecto 1: Inflación de las varianzas

$$\text{Var}(\beta_j^*) = \sigma^2 C_{jj}^* \quad C_{jj}^* = \frac{1}{1 - R_j^2}$$

s.e. van a ser gigantes

R_j^2 : Variable Respuesta X_j y las demás X_i son predictoras

* Efecto 2: Estimadores grandes en términos de valor absoluto.

$$\text{tr}(X^T X)^{-1} = \sum \frac{1}{\lambda_j}$$

λ valores propio de la matriz

si $\lambda_j \rightarrow 0$ la matriz se vuelve gigante. $\rightarrow$ Estimadores muy grandes, matriz es mal condicionada, estimadores inestables

* Efecto 3: Signos contrarios.

Ponkye Preba Subar 11 : 11
Estimado: X_j
 En regalo

d) Verdadero.

↑ sube

$$e) C_p = \underbrace{\frac{SSE_p}{MSE_{Full}}}_{\text{sube}} - (n - 2p) \quad \text{Parsimoniosos}$$

$|C_p - p| \times$

f) PRESS_p : ¿Qué tan bien el uso de valores ajustados por un submodelo puede predecir las respuestas observadas?

$$e_{(i)} = y_i - \hat{y}_{(i)} \quad PRESS_p = \sum_{i=1}^n e_{(i)}^2$$

Leave-one out




Table 1: Información en análisis				
IMCV	Ingresos	Salud	Trabajo	Capital
32.06	0.780000	2.550000	0.5100000	3.310000
32.88	0.960000	2.620000	0.5200000	3.680000
33.27	1.100000	2.650000	0.5700000	3.830000
32.82	1.121182	2.569105	0.5520319	3.739863
33.53	1.039000	3.041000	0.4850000	3.667000

Considere a *IMCV* como la variable respuesta. Las covariables consideradas en el análisis se especifican en la tabla anterior. **Dé respuesta a los siguientes planteamientos:**

- ✓ Escriba el modelo de regresión lineal múltiple, junto con sus supuestos. Deduzca a partir del modelo ajustado si podría haber problemas de multicolinealidad.
- ✓ Realice un análisis de multicolinealidad a través del número de condición e índice de condición.
3. Use el método de todas las regresiones posibles para seleccionar los mejores submodelos en función de los criterios R^2 , R^2_{adj} (o bien MSE_p) y C_p . **Posteriormente seleccione el mejor modelo.**

$$\epsilon_i \sim N(0, \sigma^2)$$

$$1- IMCV_i = \beta_0 + \beta_1 Ingresos_i + \beta_2 Salud_i + \beta_3 Trabajo_i + \beta_4 Capital_i + \epsilon_i$$

```

Coefficients:
(Intercept) 11.5446  1.3315  8.671  4.13e-15 ***
X1          -0.02252  0.7715  -0.292  0.0721 Ingresos
X2           2.0674   0.4641  4.454  1.56e-05 ***
X3           0.7985   1.3151  0.607  0.5457 Trabajo
X4           4.5861   0.2321  19.759  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.376 on 163 degrees of freedom
Multiple R-squared:  0.9857,    Adjusted R-squared:  0.9854 
F-statistic: 2814 on 4 and 163 DF,  p-value: < 2.2e-16
> |

```

```

> cor(datos[, -1])
      Ingresos  Salud Trabajo Capital
Ingresos 1.0000000 0.8660741 0.4288694 0.9773126
Salud    0.8660741 1.0000000 0.3179704 0.8776053
Trabajo  0.4288694 0.3179704 1.0000000 0.4400835
Capital  0.9773126 0.8776053 0.4400835 1.0000000
> |

```

Corr (Ingresos, Salud) Corr (Capital, Ingresos)
y Corr (Capital, Salud) son altas $\rightarrow$ sospecha de multicolinealidad

2- Para diagnosticar:

* VIF: $\frac{1}{1-R_i^2}$

VIF > 10 Multicolinealidad grave
 $S \leq VIF \leq 10$ Multicolinealidad moderada
VIF < S No hay problemas de multicolinealidad

* Número de condición $k = \frac{\lambda_{max}}{\lambda_{min}}$

$\sqrt{k} \leq 10$ no hay problema
 $10 < \sqrt{k} \leq 31.62$ moderada
 $\bullet \sqrt{k} > 31.62$ grave

* Índices de condición y proporciones de varianzas

$k_j = \frac{\lambda_{max}}{\lambda_j}$

¿Cuáles son?

```

> vif(modelo)
Ingresos  Salud Trabajo Capital
22.445411  4.494270  1.272229 24.986091
> |

```

GRUPO $\rightarrow$ Eliminar el intercepto
Escalar $\rightarrow$ Resjados a las unidades

> myCollinDiag(modelo)
Collinearity Diagnostics

Variance Decomposition Proportions

	Eigen_Value	Condition_Index	Intercept	Ingresos	Salud	Trabajo	Capital
1	4.8666914	1.000000	0.000259	0.000234	0.000195	0.000699	0.000200
2	0.1143842	6.522796	0.014932	0.015021	0.000919	0.022038	0.011168
3	0.0133262	19.110100	0.065516	0.000559	0.082752	0.793343	0.000488
4	0.0031551	39.274361	0.372568	0.680856	0.348575	0.060712	0.299449
5	0.0024430	44.632972	0.546725	0.383330	0.567559	0.123208	0.688694

Declaración control $\rightarrow$ Salud y el Capital

$$PRESS = \frac{e_i}{(1-h_{ii})}$$

3- $2^k - 1$ regresiones posibles

R_p^2 : Bondad del ajuste, busca maximizarla, pero no depende con con variables

R_{adj}^2

C_p de Mallows: Buscamos el menor posible, y que se minimice $|C_p - p|$

Incluyendo el intercepto

	R	Rsq	adj.Rsq	lambda_1	lambda_2	variables.in.model
1	1	0.984	0.984	346.807	18.856	Capital
2	1	0.940	0.940	1293.539	519.565	Ingresos
3	1	0.793	0.791	4488.689	2283.758	Salud
4	1	0.190	0.185	27587.257	9807.633	Trabajo
5	2	0.986	0.986	389.386	1.452	Salud Capital
6	2	0.984	0.984	346.807	20.846	Trabajo Capital
7	2	0.984	0.984	346.816	20.858	Ingresos Capital
8	2	0.950	0.950	1072.589	404.763	Ingresos Salud
9	2	0.941	0.940	1283.091	516.044	Trabajo Salud
10	2	0.819	0.816	3928.752	1989.904	Ingresos Trabajo
11	3	0.986	0.985	388.613	3.085	Salud Trabajo Capital
12	3	0.986	0.985	389.158	3.369	Ingresos Salud Capital
13	3	0.984	0.984	345.996	22.840	Ingresos Trabajo Capital
14	3	0.952	0.951	1047.232	393.405	Ingresos Salud Trabajo
15	4	0.986	0.985	388.452	5.000	Ingresos Salud Trabajo Capital

> myR2_criterion(modelo)

Models are Indexed in rows

k	p	R2	Variables.in.model
1	2	0.9839873	Capital
2	3	0.9856865	Salud Capital
3	4	0.9857186	Salud Trabajo Capital
4	5	0.9857261	Ingresos Salud Trabajo Capital

> |

1- C_p

2- R_{adj}^2

3- Supuestos y residuos

4- Calidad de ajuste

Salud + Trabajo + Capital] Para predecir