

En un ejercicio de fisiología, una medición objetiva del ajuste aeróbico es el consumo de oxígeno en volumen por unidad de peso corporal por unidad de tiempo. Se utilizan 31 individuos en un experimento a fin de poder modelar el consumo de oxígeno (Y) en función de la edad en años (X_1); el peso en Kg. (X_2); el tiempo para correr 1.5 millas (X_3); el ritmo del pulso en descanso (X_4); el ritmo del pulso al final de la carrera (X_5); y el ritmo máximo del pulso durante la carrera (X_6). Los datos están disponibles en el archivo `fisio.csv`. Responda la siguientes preguntas:

- Seleccione el mejor modelo de acuerdo al método de todas las regresiones posibles.
- Aplique un paso del algoritmo forward y backward.

$\rightarrow 2^k - 1$

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \beta_4 X_{i4} + \beta_5 X_{i5} + \beta_6 X_{i6} + \epsilon_i \quad \epsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$

`myAllRegTable()` $\rightarrow$ Función de R

$$R^2 = 1 - \frac{SSE}{SST} \quad * \text{Menos m.a uno}$$

$$R^2_{adj} = 1 - \frac{SSE/(n-p)}{SST/(n-1)} \quad * \text{Primer } Cp$$

$$Cp = \frac{SSE(M_p)}{MSE(M_{full})} - (n - 2p) \quad * \text{Segundo } R^2_{adj}$$

leave-one out



`> myCp_criterion(modelo)`

Models are Indexed in rows

k	p	Cp	Variables.in.model
1	2	10.525913	X3
2	3	9.887354	X3 X5
3	4	4.785675	X3 X5 X6
4	5	4.077423	X2 X3 X5 X6
5	6	5.621172	X2 X3 X4 X5 X6
6	7	7.000000	X1 X2 X3 X4 X5 X6

`> |`

`> myR2_criterion(modelo)`

Models are Indexed in rows

k	p	R2	Variables.in.model
1	2	0.7433801	X3
2	3	0.7614238	X3 X5
3	4	0.8099884	X3 X5 X6
4	5	0.8285088	X2 X3 X5 X6
5	6	0.8316288	X2 X3 X4 X5 X6
6	7	0.8358767	X1 X2 X3 X4 X5 X6

`> myAdj_R2_criterion(modelo)`

Models are Indexed in rows

k	p	adjR2	Variables.in.model
1	2	0.7345311	X3
2	3	0.7443827	X3 X5
3	4	0.7888760	X3 X5 X6
4	5	0.8021255	X2 X3 X5 X6
5	6	0.7979546	X2 X3 X4 X5 X6
6	7	0.7948458	X1 X2 X3 X4 X5 X6

`> |`

$$e_{(i)} = \frac{e_i}{1 - h_{ii}}$$

← residuals sin observación i

$$PRESS_p = \sum e_{(i)}^2$$

↑ Matriz Hat

Por criterio de Cp y R^2_{adj} el modelo elegido es:

$$Y = \beta_0 + \beta_2 X_2 + \beta_3 X_3 + \beta_5 X_5 + \beta_6 X_6$$

Forward: $Y = \beta_0 + \epsilon$

Variable	F	P-value
X_1	1000	< 0.05
X_2	20	> 0.05
X_3	3000	< 0.05
X_4	200	< 0.05
X_5	100	< 0.05
X_6	150	< 0.05

Paso 1: X_3 entra

$$Y = \beta_0 + \beta_3 X_3 + \epsilon$$

se debe cuando ya ninguna covariable entre

Paso 2: X_4 entra $Y = \beta_0 + \beta_3 X_3 + \epsilon$

Paso 3: Ninguna da significatividad. $Y = \beta_0 + \beta_3 X_3 + \beta_4 X_4 + \epsilon$

Stepwise: $Y = \beta_0 + \epsilon$

1- Backward

2- Forward

1ª Iteración:

Backward: No hay candidatos a salir

Forward: ¿Cuál variable ingreso? Ingresen X_2

2ª Iteración: $Y = \beta_0 + \beta_2 X_2 + \epsilon$

Backward: ¿ X_2 sale?

Forward: ¿Cuál es la siguiente en entrar? Ingresen X_3

3ª Iteración: $Y = \beta_0 + \beta_2 X_2 + \beta_3 X_3 + \epsilon$

Backward: ¿Sale X_2 ? ¿Sale X_3 ?

Forward: ¿Cuál es la siguiente entrar?

⋮

Ninguna entra y ninguna sale

Backward:

$$Y = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \beta_4 X_{i4} + \beta_5 X_{i5} + \beta_6 X_{i6}$$

Variable	F	P-value
X_1	1116	< 0.05
X_2	25	> 0.05
X_3	40	> 0.05
X_4	70	> 0.05
X_5	800	< 0.05
X_6	900	< 0.05

$$Y = \beta_0 + \beta_1 X_{i1} + \beta_3 X_{i3} + \beta_4 X_{i4} + \beta_5 X_{i5} + \beta_6 X_{i6} + \epsilon$$

se debe cuando ninguna variable sale

$$F = \frac{SSE(M_{red}) - SSE(M_{full})}{MSE(M_{full})}$$

$$\text{Forward: } F_j^* = \frac{SSE(M_{sin X_j}) - SSE(M_{con X_j})}{MSE(M_{con X_j})}$$

$$\text{Backward: } F_j^* = \frac{SSE(M_{sin X_j}) - SSE(M_{actual})}{MSE(M_{actual})}$$

$$A = \begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \lambda_3 \end{bmatrix}$$

$X_1 \rightarrow \text{Altra}$

$X_2 \rightarrow (\text{Altra})^2$

$(X^T X)^{-1} \rightarrow \text{Traza muy grande}$

$$\|\beta_0 - \hat{\beta}_0\| \rightarrow 0 \quad \hookrightarrow \frac{1}{n} \sum x_{ij}$$

1- Varianzas infladas $\rightarrow \beta$ significativos, serían concluidos como no significativos

2- β_0 sea muy grande

3- Coeficientes con signo contrario al esperado.

4- Regresión globalmente significativa pero variables individualmente no significativas
 Estadístico F Estadístico T

$$(X^T X)^{-1}$$

Diagnósticos de Multicolinealidad,

$$1- VIF = C_{jj}^* = \frac{1}{1 - R_j^2}$$

R_j^2 : Regresión sobre X_j

$$X_1 \sim X_2 + X_3 + X_4 \dots$$

R_1^2

$VIF \leq 5$ No hay multicolinealidad

$5 < VIF \leq 10$ Problema moderado

$VIF > 10$ Multicolinealidad grave

$$X_2 \sim X_1 + X_3 + X_4 \dots$$

R_2^2

2- Matriz de Correlación

$$\begin{matrix} X_1 \\ X_2 \\ X_3 \end{matrix} \begin{bmatrix} 1 & 0.9 & 0.7 \\ 0.9 & 1 & 0.2 \\ 0.75 & 0.2 & 1 \end{bmatrix}$$

$X_1 \quad X_2 \quad X_3$

X_1 y X_2 : candidatos

X_1 y X_3 : candidatos

Correlación grande $\rightarrow$ No indica multicolinealidad

Correlación pequeña $\rightarrow$ No indica ausencia de multicolinealidad

3- Número de condición: $\kappa = \frac{\lambda_{\max}}{\lambda_{\min}}$ } Indica ausencia o presencia de multicolinealidad

Índice de condición: $\frac{\lambda_{\max}}{\lambda_j}$

$\rightarrow$ Me dice que si la ver

$\sqrt{\kappa} \leq 10$ No hay multicolinealidad

$10 < \sqrt{\kappa} \leq 31.62$ Moderada

$\sqrt{\kappa} > 31.62$ grave

Valores propios	condición	Propiedades de varianzas						
índice		β_0	β_1	β_2	β_3	β_4	β_5	β_6
300	0.2	0.5	0.7	0.1	0.1	0.1	0.1	0.1

Multicolinealidad entre

β_1 y β_2

```
> vif(modelo)
```

	X1	X2	X3	X4	X5	X6
	1.427444	1.184769	1.311050	1.331685	9.432527	10.223924

> |

Motruda Grave

```
> myCollinDiag(modelo)
```

Collinearity Diagnostics

		Variance Decomposition Proportions							
	Eigen_Value	Condition_Index	Intercept	X1	X2	X3	X4	X5	X6
1	6.93149130	1.00000	0.000028	0.000245	0.000464	0.000257	0.000347	0.000008	0.000005
2	0.02493888	16.67151	0.000119	0.099157	0.646254	0.012424	0.037402	0.000000	0.000028
3	0.01751888	19.89116	0.001910	0.333184	0.036438	0.060588	0.351728	0.000135	0.000035
4	0.01416770	22.11891	0.008192	0.102663	0.178845	0.016294	0.391386	0.004423	0.003077
5	0.01044022	25.76668	0.004692	0.002721	0.022094	0.869103	0.173872	0.001877	0.001599
6	0.00128826	73.35188	0.698916	0.332575	0.007476	0.007099	0.044381	0.071698	0.008072
7	0.00015476	211.63041	0.286143	0.129455	0.108429	0.034236	0.000883	0.921858	0.987184

> |

↕
Multicolinealidad entre X5 y X6

$$\text{Número de condición} = \frac{\lambda_{\max}}{\lambda_{\min}} = \frac{6.9314}{0.00015476} = 44.788 = K$$

$$\sqrt{K} = 211 \rightarrow \text{Multicolinealidad grave}$$

```
> cor(data[, -1])
```

	X1	X2	X3	X4	X5	X6
X1	1.00000000	-0.06803174	0.1144893	0.1625454	-0.2888032	-0.4138019
X2	-0.06803174	1.00000000	0.1358403	0.1515643	0.1386447	0.2436486
X3	0.11448931	0.13584031	1.00000000	0.4005360	0.3136478	0.2261030
X4	0.16254543	0.15156427	0.4005360	1.00000000	0.3179732	0.2575034
X5	-0.28880321	0.13864469	0.3136478	0.3179732	1.00000000	0.9297538
X6	-0.41380191	0.24364857	0.2261030	0.2575034	0.9297538	1.00000000

> |