

Parte teórica
 Dé respuesta a las preguntas formuladas a continuación en base a la teoría tratada en clase.
 Provea una interpretación de ser necesario.

- Determine el valor de verdad de las siguientes afirmaciones.

Falso

Verdades

Verdades

Verdades

Falso

(a) El modelo de regresión logística $\text{logit}(\theta_i) = \psi(x_i)$ clasifica directamente como éxito o fracaso cada observación provista.


(b) La tasa de falsos positivos se calcula como $[n_{01}/(n_{00} + n_{01})]$, e indica las observaciones que fueron clasificadas como positivas cuando eran realmente verdaderas.

(c) La curva ROC muestra cómo cambian la sensibilidad y las especificidad a medida que varía el punto de corte θ^* . De aquí se deriva una métrica importante, que es el AUC.

(d) La selección del punto de corte θ^* impacta directamente el desempeño del modelo logístico como clasificador, -incluso la matriz de confusión se ve afectada-.

(e) Un modelo con un AUC igual a 0.5 indica que clasifica las observaciones de manera aleatoria.

(d) El estadístico de prueba $\chi_c = D_0^2 - D^2$, con una región de rechazo asociada $R_c = \{\chi_c > \chi_{p,a}\}$ se emplea para probar la significancia global del modelo, mientras que se prefiere la prueba ~~Normal~~ para la significancia individual.



a) $\psi(x_i) = \frac{\theta_i}{1 - \theta_i}$ Razón de Probabilidades (RP)
 Odds Ratio (OR)

1. No devuelve una etiqueta, sino una probabilidad.

Devuelve el modelo

$$\hat{\theta}_i = P(Y_i = 1 | X_i)$$

$$\hat{y}_i = \mathbb{1}\{\hat{\theta}_i \geq \theta^*\}$$

Punto de corte

$$\mathbb{1}\{\hat{\theta}_i \geq \theta^*\} = \begin{cases} \text{si se cumple} = 1 \\ \text{no se cumple} = 0 \end{cases}$$

2. Uno modelo en realidad.

$$\text{logit}(\theta_i) = \log\left(\frac{\theta_i}{1 - \theta_i}\right) = \ln(\psi(x_i)) = \beta_0 + x_{i1}\beta_1 + \dots + x_{ik}\beta_k$$

b) Falso.

		Pred 0	Pred 1	
Real 0	n_{00} (VN)	n_{01} (FP)		Err Tipo I
Real 1	n_{10} (FN)	n_{11} (VP)		Err Tipo II

$$TFP = \frac{n_{01}}{n_{00} + n_{01}} = \frac{FP}{VN + FP}$$

¿En cuántos me equivoqué?

Todos los que realmente son 0

0 → 0 0 → 1

¿En cuántos acerte?


$$TPR = \frac{VP}{VN + FP} \text{ (Precision)}$$

0 → 0 0 → 1

1 → 1

$$\frac{VP}{VP + FN} \text{ (Sensibilidad)}$$

1 → 1 1 → 0



d) θ^* reasigna observaciones n_{00} n_{01} n_{10} n_{11}

Mayor θ^* : Aumenta Positivos

Menor θ^* : Hace lo contrario

→ Más VP y FP

→ Menos FN

d) significancia global: $\chi_c = D_0^2 - D^2 \sim \chi_p^2$ bajo H_0

significancia individual: Se evalúa con un estadístico tipo Wald

$$Z_c = \frac{|\hat{\beta}_j|}{\hat{ee}(\hat{\beta}_j)} \stackrel{H_0}{\sim} N(0,1)$$

Considere el siguiente conjunto de datos, una muestra de los nacidos vivos registrados en el Hospital Manuel Uribe Ángel (Envigado, Antioquia). Las variables son las mismas descritas en el taller anterior: **BAJO_PESO**, **EDAD_MADRE**, **CONSULTAS**, **GEMELAR** y **REGIMEN**. Retome el modelo ajustado en el primer taller como punto de partida para este análisis de rendimiento.

Table 1: Información en análisis

BAJO_PESO	EDAD_MADRE	CONSULTAS	GEMELAR	REGIMEN
0	23	5	0	Contributivo
0	38	12	0	Contributivo
0	31	9	0	Contributivo
0	22	9	0	Contributivo
0	34	4	0	Contributivo

Considere a 'BAJO_PESO' como la variable respuesta. Las covariables en análisis se especifican en la tabla mostrada con anterioridad. Dé respuesta a los siguientes planteamientos:

1. Realice una prueba de significancia de los parámetros individuales. Provea una interpretación directa de los parámetros del modelo de regresión logística, así como una interpretación en términos de la razón de probabilidades. $\log\text{-odds}$
2. Realice una predicción de futuras observaciones. Utilice las probabilidades obtenidas para la construcción un clasificador logístico con etiquetas.
3. Analice el rendimiento del modelo a través de la curva ROC y AUC. Interprete.
4. Halle un valor de corte θ^* óptimo que permita mantener una **tasa de clasificación acertada alta**, minimizando el número de falsos negativos.
5. Reporte la matriz de confusión y la tasa de clasificación correcta. ¿Cómo cambian estas matrices con diferentes valores de θ^* ?



Entrenamiento $\rightarrow$ Estimar parámetros 70% / 80%

Test $\rightarrow$ Evaluar el modelo (generalización del modelo) 20% / 20%

Si utilizo todos los datos $\rightarrow$ Las métricas son engañosas.

$$\log\left(\frac{\theta_i}{1-\theta_i}\right)$$

$$2: \hat{y}_i = \begin{cases} 1 & (\text{bajo peso}) \quad \hat{\theta}_i \geq \theta^* \\ 0 & (\text{peso normal}) \quad \hat{\theta}_i < \theta^* \end{cases}$$

Coefficients:


	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.194470	0.492865	-2.424	0.0154 *
EDAD_MADRE	0.006918	0.015547	0.445	0.6563 x
CONSULTAS	-0.189398	0.036478	-5.192	2.08e-07 ***
GEMELAR	4.289845	0.550712	7.790	6.72e-15 ***
REGIMENNoAsegurado	0.089519	0.310754	0.288	0.7733 x
REGIMENSubsidiado	0.236447	0.212479	1.113	0.2658 x

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$\begin{aligned} H_0: \beta_j &= 0 \\ H_1: \beta_j &\neq 0 \end{aligned} \quad Z_c = \frac{|\hat{\beta}_j|}{\hat{se}(\hat{\beta}_j)} \stackrel{H_0}{\sim} N(0,1)$$

$$|Z_c| > 1.96$$

3-



Un AUC de 0.68 se interpreta como:

* Tomo al azar un recién nacido con bajo peso y otro sin bajo peso, el modelo le asigna mayor probabilidad al primo el 68% de las veces.

```
> exp(-0.189398) -19/
[1] 0.8274571
> exp(GEMELAR
4.289845)
```

Error: unexpected numeric constant in "exp(GEMELAR 4.289845" Show Traceback Rerun with Debug

```
> exp(4.289845)
[1] 72.95516
> |
```

Consultas ($\exp=0.827$): Cada consulta prenatal adicional disminuye el $\log\text{-odds}$ de bajo peso en 0.189; las odds se multiplican por 0.827

Gemelar ($\exp=57.3$): Un embarazo múltiple eleva el $\log\text{-odds}$ en 4.29, las odds se multiplican por 57.

0: Peso Normal $\psi_i = \frac{\theta_i}{1-\theta_i}$
1: Bajo Peso

$\log\text{-odds}$ (aditivos) suma o disminuye
odds (multiplicativos)

4- $\theta^* = 0.103$

$$d(\theta^*) = (1 - \text{Sensibilidad})^2 + (1 - \text{Especificidad})^2 \approx \begin{matrix} TFP = 0 \\ TVP = 1 \end{matrix}$$

5- El θ^* óptimo: sube VP a costa de más FN, pero me da lo que yo prefiero.

óptimo

	FALSE	TRUE	Maximiza: VP	Maximiza: FN
0	370	161	Minimiza: VN	Minimiza: FP
1	30	39		

```
> table(test$BAJO_PESO, predict_test > 0.25)
```

	FALSE	TRUE	Aumentan FP
0	522	9	
1	57	12	

```
> table(test$BAJO_PESO, predict_test > 0.5)
```

	FALSE	TRUE	Aumentan FP
0	529	2	
1	60	9	

```
>
```