

Tengo 3 clases $\begin{cases} \rightarrow 1 \text{ Referencia} \\ \rightarrow 2 \text{ en el Modelo} \end{cases}$

(baja, riesgo, zona de riesgo, fracasos)
 clase 0 $\uparrow$ clase 1 (Peso normal, zona segura, éxitos)
 0, 0, 1, 1, 0

De respuesta a las preguntas formuladas a continuación en base a la teoría tratada en clase.
Provea una interpretación de ser necesario.

1. Determine el valor de verdad de las siguientes afirmaciones.

- V • (a) En un modelo de regresión logística, la variable respuesta es de naturaleza binaria, tal que $Y_i \sim \text{Ber}(\theta_i)$; donde θ es la probabilidad de éxito en el i -ésimo ensayo.
- F • (b) Los coeficientes β de un modelo de ~~regresión logística~~ ^{regresión logística} se estiman numéricamente el método de ~~mínimos cuadrados ordinarios~~ ^{Newton-Raphson}, ya que la función de verosimilitud es no-lineal.
- V • (c) Al incluir variables categóricas al modelo, es necesario definir una categoría de referencia, y la interpretación de tales coeficientes se realiza en comparación con tal referencia.
- F • (d) El valor $\exp(\beta_j)$ se interpreta como el cambio en ~~odds~~ ^{odds} de los 'odds' por cada incremento unitario en la variable predictora X_{ij} .

a) ¿Qué es θ ?

Distribución Bernoulli: Para variables binarias

$$y_i = \begin{cases} 1 & \text{éxito} \\ 0 & \text{fracaso} \end{cases} \quad y_i \sim \text{Ber}(\theta_i) \quad \text{P=0.5}$$

$$f(y_i | \theta_i) = \theta_i^{y_i} (1 - \theta_i)^{1 - y_i} \quad \text{función de masa}$$

b) $\hat{\beta}_{\text{reg lineal}} = (X^T X)^{-1} X^T y$ MCO solución cerrada $\rightarrow$ únicamente para distribución normal

$$\psi(x_{ij}) = \frac{\theta_i}{1 - \theta_i} \quad \text{odds evaluados en } x_{ij}$$

Para regresión logística.

$$\hat{\beta} = \arg \max_{\beta \in \mathbb{R}^p} L(\beta) \rightarrow \text{Newton-Raphson} \quad \text{IRLS (Iteratively Reweighted Least Squares)}$$

$$L(\beta) = \prod_{i=1}^n \left[\left(\frac{e^{\beta_0 + x_{i1}\beta_1 + \dots + x_{ik}\beta_k}}{1 + e^{\beta_0 + x_{i1}\beta_1 + \dots + x_{ik}\beta_k}} \right)^{y_i} \left(\frac{1}{1 + e^{\beta_0 + x_{i1}\beta_1 + \dots + x_{ik}\beta_k}} \right)^{1 - y_i} \right]$$

d) β_j : Es el cambio ~~aditivo~~ en el logaritmo de los odds (log-odds) por incremento unitario en x_j

$$(1) \log(\psi(x_{ij} + 1)) - \log(\psi(x_{ij})) = \beta_j$$

$$\log \psi(x_{ij}) = \log \left(\frac{\theta_i}{1 - \theta_i} \right) = \beta_0 + \beta_j x_{ij}$$

$$\log(\psi(x_{ij} + 1)) = \beta_0 + \beta_j(x_{ij} + 1) = \beta_0 + \beta_j x_{ij} + \beta_j$$

(1) lo podemos reescribir como:

$$\log \left(\frac{\psi(x_{ij} + 1)}{\psi(x_{ij})} \right) = \beta_j \quad \log(a) - \log(b) = \log\left(\frac{a}{b}\right)$$

Razón de odds $\rightarrow \frac{\psi(x_{ij} + 1)}{\psi(x_{ij})} = \exp(\beta_j)$ factor multiplicativo de los odds

$\exp(\beta_j)$ multiplica los odds, no modifica el log de odds.

¿Por qué regresión logística?

* La regresión lineal da valores en todo $\mathbb{R}$

* Se queda corta, para datos binarios (logística) o datos de conteo (Poisson)

• Funciones de enlace (link):

* Ajusto regresión, y me da cualquier valor

* Aplica función de enlace, ya está en el rango que necesito.

$$\beta_0 + \beta_j x_{ij} \rightarrow \frac{a}{\log(\cdot)} \rightarrow \text{Estimación con la forma que necesito}$$

$$\text{logit}(\cdot) = \log \left(\frac{\theta_i}{1 - \theta_i} \right) = \beta_0 + \beta_j x_{ij}$$

odds $\rightarrow$ P(éxito)
 chances $\rightarrow$ P(No éxito)

$$\psi(x_{ij}) = \frac{\theta_i}{1 - \theta_i} \quad \text{odds evaluados en } x_{ij}$$

$$\psi(x_i) = \frac{\theta_i}{1 - \theta_i} = \frac{P(\text{éxito})}{P(\text{fracaso})} \quad \text{No es una probabilidad!! } (0, \infty)$$

¿Cuántas veces es más probable el éxito que el fracaso?

$\psi = 1$ Fracaso y éxito son iguales $\theta = 0.5$ Cantidad más interpretable

$\psi > 1$ Éxito más probable que el fracaso

$\psi = 3$, es 3 veces más probable el éxito que el fracaso. (chances 3 a 1) chances de 1 a 4

$\psi < 1$ Fracaso más probable que éxito $\psi = 0.25$ (por cada éxito espero 4 fracasos)

log-odds (logit)

$$\text{logit}(\theta_i) = \log(\psi_i) = \log\left(\frac{\theta_i}{1-\theta_i}\right)$$

Cantidad expresada
con las covariables,

$$\text{logit}(\theta_i) = \beta_0 + \beta^T x_i$$

* Multiplicando (odds) pasa a ser
aditivo (log-odds).

β_j es escala aditiva del log-odds (signo interpretable)

$\exp(\beta_j)$ es escala multiplicativa del odds (interpretable en términos
de ¿cuántas veces cambian
las chances?)

→ Forma de S

Regresión Logística — Curva sigmoide

$\text{logit}(\theta_i) = \beta_0 + \beta_1 x$ (datos simulados)

● $y = 0$ (fracaso) ● $y = 1$ (éxito)




Table 1: Información en análisis

BAJO_PESO	EDAD_MADRE	CONSULTAS	GEMELAR	REGIMEN
0	23	5	0	Contributivo
0	38	12	0	Contributivo
0	31	9	0	Contributivo
0	22	9	0	Contributivo
0	34	4	0	Contributivo

Considere a 'BAJO_PESO' como la variable respuesta. Las covariables en análisis se especifican en la tabla mostrada con anterioridad. De respuesta a los siguientes planteamientos:

1. Ajuste un modelo de regresión logístico. Analice los componentes θ_i , $g(\theta_i)$, $\psi(\mathbf{x}_i)$. ¿Por qué se emplea la función 'logit' como función de enlace?
2. Provea una interpretación directa de los parámetros del modelo de regresión logística ajustado, así como una interpretación en términos de la razón de probabilidades. Incluya coeficientes asociados a covariables cuantitativas (por ejemplo EDAD_MADRE, CONSULTAS), binarias (GEMELAR) y categóricas (REGIMEN, respecto al nivel de referencia *Contributivo*).

$$\theta_i = \frac{\exp(\beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik})}{1 + \exp(\beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik})}$$

$$\theta_i = P(Y_i = 1 | X_i) = P(\text{bajo peso} | \text{características de la madre}) \in [0, 1]$$

→ Cada individuo tiene su propio $\hat{\theta}_i$

$$\psi(x_i) = \frac{\theta_i}{1 - \theta_i} > 1 \quad \text{Hay mayores chances de éxito (bajo peso)}$$

predicador real

$$g(\theta_i) = \text{logit}(\theta_i) = \log(\psi(x_i)) = \eta_i$$

Recibe datos de 0s y 1

< 1 Hay mayores chance de encontrar niño con peso normal (éxito)

= 1 Iguales probabilidades

El $\log(\cdot)$ lo manda a todo $\mathbb{R}$

¿Por qué logit?

1- Gama $\theta_i \in [0, 1]$ $\eta_i = \beta_0 + \beta^T x_i$
 $(-\infty, \infty)$

$$\theta_i = \eta_i$$

→ Contando negativas

→ Mayores 1

2- Interpretabilidad: Le da lecha a β_j y a $\exp(\beta_j)$

3- logit tiene propiedades de convergencia y de suficiencia

Biyección: logit
 $(0, 1) \rightarrow \mathbb{R}$

```
glm(formula = BAJO_PESO ~ EDAD_MADRE + CONSULTAS + GEMELAR +  
    REGIMEN, family = binomial(link = "logit"), data = data)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.24351	0.40311	-3.085	0.00204 **
EDAD_MADRE	0.01102	0.01282	0.860	0.39006
CONSULTAS	-0.18764	0.02989	-6.277	3.45e-10 ***
GEMELAR	4.12647	0.45843	9.001	< 2e-16 ***
REGIMENNoAsegurado	-0.06674	0.26772	-0.249	0.80315
REGIMENSubsidiado	0.16307	0.17588	0.927	0.35386

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Ajustamos con glm: generalized linear model

$glm(\cdot) \rightarrow$ Función de R

$$\logit(\hat{\theta}_i) = -1.24351 + 0.011 Edad + 0.1876 Consultas + 4.12647 Gemelar - 0.0667 I_{i1} \text{ No Asegurado} + 0.16307 I_{i2} \text{ Subsidiado}$$

$$\underbrace{\beta_j = \log\left(\frac{\psi(x_{ij}+1)}{\psi(x_{ij})}\right)}_{\substack{\text{escala} \\ \text{log-odds} \\ \text{(aditiva)}}} \quad \underbrace{\exp(\beta_j) = \frac{\psi(x_{ij}+1)}{\psi(x_{ij})}}_{\substack{\text{escala odds} \\ \text{(multiplicativa)}}}$$

```
> exp(model$coefficients)
      (Intercept)      EDAD_MADRE      CONSULTAS      GEMELAR
      0.2883699      1.0110834      0.8289109      61.9585995
REGIMENNoAsegurado REGIMENSubsidiado
      0.9354422      1.1771156
> |
```

Consultas: $(\hat{\beta}_2 = -0.1876)$

Por cada consulta el log-odds de bajo peso disminuye en 0.1876 unidades con las demás fijas.

Consultas $(\exp(-0.1876)) = 0.829$

Por cada consulta, el odds de bajo peso se multiplica por 0.829 es decir disminuye.

$\approx 17\%$

Régimen subsidiado: $(\hat{\beta} = 0.1631)$

Respecto al nivel de referencia, el régimen subsidiado aumenta el log-odds 0.1631

Régimen subsidiado $(\exp(0.1631)) = 1.177$

Pasar de contributivo a subsidiado multiplica las odds por 1.177, un incremento del 17.7% en las chances de bajo peso

Nota: El porcentaje miramos cuanto falta o por cuanto nos excedemos respecto a 1.