

$$\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$


1. Pruebe que en el modelo de regresión lineal múltiple que incluye intercepto, la suma de los residuales es igual a cero.

$$S(\beta) = (y - X\hat{\beta})^T (y - X\hat{\beta}) \quad e = y - \hat{y} \quad \beta = [\beta_0, \beta_1, \dots]$$

$$S(\beta) = e^T e$$

$$S(\beta) = \sum_{i=1}^n (e_i)^2$$

$$S(\beta) = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \dots)^2$$



$$\frac{\partial S(\beta)}{\partial \beta_0} = 2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \dots) (-1)$$

$$= -2 \sum (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \dots) = 0$$

$$\sum \underbrace{(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \dots)}_{\hat{y}} = 0$$

$$\sum (y_i - \hat{y}) = 0$$

$$\sum e_i = 0$$

2. Determine el valor de verdad de las siguientes afirmaciones.

- (a) Bajo los supuestos del modelo de regresión lineal múltiple, se cumple que la **respuesta media estimada** $\hat{Y}_0 \sim N(E[Y|\mathbf{x}_0], \sigma^2 \mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0)$; donde, además, $\hat{Y}_0$ es un estimador insesgado para Y_0 .
- (b) El error de predicción $\hat{Y}_0 - Y_0$ tiene una varianza asociada dada por $\sigma^2 \mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0$, al igual que $\hat{Y}_0$. De aquí que, si se sabe que $\mathbf{x}_0 = [1, x_{01}, x_{02}, \dots, x_{0k}]'$ es un punto en que no se comete extrapolación, entonces es correcto afirmar que $\mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0 < 1$.
- (c) El procedimiento analítico **Shapiro-Wilk**, cuyo juego de hipótesis está dado por: $H_0: \varepsilon_i \sim N(0, \sigma^2)$ vs $H_1: \varepsilon_i \not\sim N(0, \sigma^2), i = 1, \dots, n$, permite determinar la normalidad de los residuos del modelo de regresión.

$$\mathbf{x}_0 = [175, 85]$$

a) $E[Y | \mathbf{x}_0] = \underbrace{\mathbf{x}_0^T \boldsymbol{\beta}}_{\mathbf{x}_0^T \hat{\boldsymbol{\beta}}} \leftarrow \text{Para una sola observación}$

$$E[\underbrace{\mathbf{x}_0^T \hat{\boldsymbol{\beta}}}_{\text{sin constantes}}] = \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

$$= \mathbf{x}_0^T \underbrace{(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{X}}_{\text{IP}} \hat{\boldsymbol{\beta}} = \mathbf{x}_0^T \hat{\boldsymbol{\beta}}$$

$$\hat{\boldsymbol{\beta}} \sim N(\boldsymbol{\beta}, \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1})$$

$$\text{Var}[\mathbf{x}_0^T \hat{\boldsymbol{\beta}}] = \mathbf{x}_0 \text{Var}[\hat{\boldsymbol{\beta}}] \mathbf{x}_0^T$$

$$= \mathbf{x}_0 \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0^T$$

$$\text{b) } \text{Var}[Y_0 - \hat{Y}_0] = \text{Var}[Y_0] + \text{Var}[\hat{Y}_0]$$

$$Y \sim N(\mathbf{x}\boldsymbol{\beta}, \sigma^2 (\mathbf{x}^T \mathbf{x})^{-1}) = \text{Var}[\underbrace{\mathbf{x}_0 \boldsymbol{\beta}}_{\text{constante}} + \varepsilon_0] + \text{Var}[\mathbf{x}_0^T \hat{\boldsymbol{\beta}}]$$

$$\boxed{E \sim N(0, \sigma^2 \mathbf{I})}$$


$$= \sigma^2 + \mathbf{x}_0 \underbrace{\sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}}_{\text{escolar}} \mathbf{x}_0^T$$

$$= \sigma^2 + \sigma^2 \mathbf{x}_0 (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0^T$$

$$= \sigma^2 (1 + \mathbf{x}_0 (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0^T)$$

Intervalos de predicción sumas
anchos que los de confianza

c) Normalidad $\left\{ \begin{array}{l} \rightarrow \text{Shapiro-Wilk} \\ \rightarrow \text{Pruebas gráficas} \end{array} \right.$



$$H_0: \varepsilon_i \sim N$$

$$H_a: \varepsilon_i \not\sim N$$

- F(d) Si al validar los supuestos del modelo de regresión lineal múltiple se detecta varianza no homogénea, adicionar términos cuadráticos a las variables predictoras permite corregirla, ya que la heterocedasticidad siempre se debe a una especificación funcional incorrecta del modelo.

F. (e) Una observación atípica está separada del resto de las observaciones en su valor de respuesta Y , ~~aunque no afecta los resultados del ajuste~~. Su evaluación se realiza a través del residual estandarizado $|d_i| > 3$.


F. (f) Se cumple que una observación i es de balanceo si está definida en el espacio de la respuesta Y y si se cumple que $h_{ii} > 2p/n$, afectando estadísticas como el R^2 y los errores estándar de los coeficientes del modelo.

F. (g) Se cumple que $|D_i| > 1$, $|DFBETAS_{j(i)}| > (2/\sqrt{n})$ y $|DFITS_i| > (2\sqrt{p/n})$ simultáneamente para toda observación categorizada como influyente en un conjunto de datos.


→ ¿Cuánto cambia β_j por quitar la observación (i) ?

Sin $pahony$


Para concluir necesitamos los estandarizado



Patrones de Diagnóstico en Gráficos de Residuales
Análisis de Residuales Ordinarios vs. Valores Ajustados



• ← atípico



f) atípicas → sobre y afecta estimaciones

balanceo → sobre x afecta R^2 y errores estándar


influyentes → En x y/o y
→ Jalon la recta de regresión

$c_{jj} \rightarrow (X^T X)^{-1}$ su elemento

3. Seleccione las expresiones adecuadas que se muestran a continuación, interprételas y corrija las expresiones incorrectas.

a. $d_i = \frac{e_i}{\sqrt{MSE}}$ b. $r_i = \frac{d_i}{\sqrt{1-h_{ii}}}$

c. $DFBETAS_{j(i)} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\sqrt{MSE_{(i)} c_{jj}}}$ d. $DFFITS_i = \frac{\hat{y}_i - y_{i(0)}}{\sqrt{h_{ii} MSE_{(i)}}}$



$d_i \rightarrow$ residual estandarizado

$$d_i = \frac{e_i}{\sqrt{\hat{\sigma}^2}}$$

$$\underbrace{r_i}_{\text{estandarizado}} = \frac{\frac{e_i}{\sqrt{MSE}}}{\frac{\sqrt{1-h_{ii}}}{1}} = \frac{e_i}{\underbrace{\sqrt{MSE(1-h_{ii})}}_{\text{la matriz hat}}}$$

1. Verifique los supuestos del modelo de regresión, esto es, $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, a partir de los procedimientos apropiados para ello.
2. Identifique puntos atípicos y puntos de balanceo a través de un criterio gráfico y analítico. ¿Podrían ser estos puntos a su vez influyentes?
3. Identifique puntos influyentes. Compare los criterios empleados para ello.
4. Realice inferencia para $\mathbf{x}_{01} = [1, 1.6921, 3.3214, 0.6125, 6.1313]'$ y $\mathbf{x}_{02} = [1, 3.6534, 4.2594, 0.7646, 12.7477]'$, con su respectivo intervalo de predicción. Verifique primero si no se trata de un punto de extrapolación.

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.5446	1.3315	8.671	4.13e-15 ***
Ingresos	-0.2252	0.7715	-0.292	0.771
Salud	2.0674	0.4641	4.454	1.56e-05 ***
Trabajo	0.7985	1.3151	0.607	0.545
Capital	4.5861	0.2321	19.759	< 2e-16 ***

$$\hat{y}_i = 11.5446 - 0.2252x_{i1} + 2.0674x_{i2} + 0.7985x_{i3} + 4.5861x_{i4}$$

$$y_i = \beta_0 + \beta_1 x_{i1} + \varepsilon_i \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$


$$\varepsilon \sim N(0, \sigma^2 I)$$

$$\text{plot(modelo, 2) \quad Shapiro.test(modelo$residuals)}$$

$$rstandard \rightarrow \overset{\text{residuals}}{\text{estándar de residuos}}$$

$$rstudent \rightarrow \text{estudentizados}$$

$$\text{Para las influyentes} \left\{ \begin{array}{l} \rightarrow \text{cooks.distance(modelo)} > 1 \\ \rightarrow \text{dfbetas(modelo)} > \frac{2}{\sqrt{n}} \quad 2\sqrt{\frac{1}{n}} \\ \rightarrow \text{dffits(modelo)} > 2\sqrt{\frac{p}{n}} \end{array} \right.$$



$$t() \rightarrow \text{Transpuesta}$$

$$%, * \% \rightarrow \text{Producto matricial} \quad \text{model.matrix}() \rightarrow \text{Matriz de dise\~{n}o}$$

$$\text{solve}() \rightarrow \text{Inversa } (X)^{-1}$$

La interpretaci3n en t6rminos del promedio de la respuesta y de los dem1s variables fijas/constantes