

Regresión Logística:

$[0, 1] \rightarrow$ ¿Cómo utilizar una regresión para esto?

Bernoulli: $f(y_i | \theta) = \theta^{y_i} (1-\theta)^{1-y_i}$ $\hat{\theta} = \bar{y}$ $0.5 = \theta$
(Aditivo)

log: multiplicativo $\rightarrow$ aditivo

Funciones de enlace: $g(\cdot)$

valor entre 0 y 1

$$\log\left(\frac{\theta_i}{1-\theta_i}\right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}$$

El cambio de β_1 unidades en el log-odds por un aumento unitario en x_{i1}

$$\exp(\beta_1) = 2$$

un aumento unitario en x_{i1} duplica las chances del éxito.

$2.06 - 1 = 1.06$
 $\exp(\beta_j) = 2.06 \rightarrow 106\%$ la probabilidad de éxito

éxito $\rightarrow \theta_i$
fracaso $\rightarrow 1 - \theta_i$
: Razón de Probabilidad

$$\theta_i = \frac{\exp(\beta_0 + \beta_1 x_{i1} + \dots)}{1 + \exp(\beta_0 + \beta_1 x_{i1} + \dots)}$$

RP > 1 : Más chances de éxito

RP = 1 : Igual éxito y fracaso

RP < 1 : Más chances de fracaso

$\hat{\beta}$ no tiene forma cerrada. Newton-Raphson

$$\hat{\beta} \sim N_p(\beta, V) \quad V = I^{-1}$$

Pruebas de Hipótesis:

Significancia general $H_0: \beta_1 = \dots = \beta_k = 0$ $\chi^2_c = D_0^2 - D^2$ χ^2_k
Denancia

significancia individual $H_0: \beta_j = 0$ $Z_c = \frac{|\hat{\beta}_j|}{\text{ee}(\hat{\beta}_j)}$ $\hat{\beta}_j \pm Z_{\frac{\alpha}{2}} \text{ee}(\hat{\beta}_j)$

Sumo: 0 un falso negativo es mucho
 enfermo: 1 más caro que un falso positivo

Sumo $\rightarrow$ enfermo
 enfermo $\rightarrow$ Sumo



$[0, 1]$

¿Cuándo clasico con etiqueta 1
 cuando clasico con etiqueta 0?

$$\hat{y}_i = \begin{cases} 1 & \text{si } \hat{\theta}_i > \theta^* \\ 0 & \text{si } \hat{\theta}_i \leq \theta^* \end{cases}$$

modelo corte
tipo

	Predicho Negativo	Predicho Positivo
Real Negativa	n_{00}	n_{01}
Real Positivo	n_{10}	n_{11}

¿Cuánto se equivoca?

$$TFP = \frac{n_{01}}{n_{00} + n_{01}} \quad \text{Precisión} = 1 - TFP = \frac{n_{00}}{n_{00} + n_{01}}$$

correcto error


¿Cuánto acerto?

$$TFN = \frac{n_{10}}{n_{10} + n_{11}} \quad \text{Sensibilidad} = 1 - TFN = \frac{n_{11}}{n_{10} + n_{11}}$$

$$TCC = \frac{n_{00} + n_{11}}{n_{00} + n_{01} + n_{10} + n_{11}} \quad TCC \geq 0.6$$

Curva ROC y AUC: Eje Y: Sensibilidad
 Eje X: TFP

$\theta^* = 1$ Todo es negativo (origen)
 $\theta^* = 0$ Todo es Positivo (esquina superior derecha)
 $\theta^* \in [0, 1]$



Regression Poisson:

* Logística $\rightarrow [0, 1]$

* Poisson $\rightarrow$ Datos conteo

$$f(y_i) = \frac{\lambda^{y_i} \exp(-\lambda)}{y_i!} \quad \mathbb{E}[y_i] = \text{Var}[y_i] = \lambda$$

1- Respuesta tipo conteo

2- Independencia entre observaciones

3- Varianza = Media

$$\log(\lambda_i) = \beta_0 + \beta_1 X_{i1} + \beta_2 I_{i2}$$

Forma no cerrada para β utilizamos

Newton-Raphson

β_j : Cambio en el log de la media por incremento unitario en x_j

Poisson $\rightarrow \log(\lambda_i)$

Logística $\rightarrow \log\text{-odds}$

Mismas pruebas de la logística

$$\chi^2_c = D_0^2 - D^2$$

$\exp(\beta_j)$: Factor multiplicativo sobre la media esperada

$\exp(\hat{\beta}_1) = 1.12$ aumento del 12%
se multiplica por 1.12

$\exp(\hat{\beta}_2) = 1.30$ Pasar del nivel de referencia a el nivel X, multiplica la media esperada por 1.30

Problema práctico 1: Una entidad financiera desea modelar la probabilidad de que un cliente **incumpla** el pago de un crédito ($y_i = 1$ incumple, $y_i = 0$ no incumple) en función de su **ingreso mensual** (*Ingreso*, continua) y de su **segmento comercial** (*Segmento*, categórica con 4 niveles: A —referencia—, B, C, D). En el archivo **P1Logistica.csv** se encuentra la información de una muestra de $n = 600$ clientes. Con base en esto responda las preguntas 1 a 5. El modelo ajustado con `glm(..., family = binomial(link = "logit"))` es:

$$\text{logit}(\theta_i) = \ln\left(\frac{\theta_i}{1-\theta_i}\right) = \beta_0 + \beta_1 \text{Ingreso}_i + \beta_2 I_{iB} + \beta_3 I_{iC} + \beta_4 I_{iD},$$

No θ_i
 $\log(\psi(x_i, z))$

Predictor lineal

1. Tomando el segmento A como nivel de referencia, ¿cuál de las siguientes opciones es **falsa**?

✓ a. El modelo puede escribirse como $\text{logit}(\theta_i) = \ln\left(\frac{\theta_i}{1-\theta_i}\right) = \beta_0 + \beta_1 \text{Ingreso}_i + \beta_2 I_{iB} + \beta_3 I_{iC} + \beta_4 I_{iD}$.

✓ b. Despejando θ_i , la probabilidad estimada de incumplimiento es $\theta_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$, con η_i el predictor lineal.

Falso X c. El modelo asume la relación $\theta_i = \beta_0 + \beta_1 \text{Ingreso}_i + \beta_2 I_{iB} + \beta_3 I_{iC} + \beta_4 I_{iD}$, es decir, la probabilidad es una función lineal del predictor.

d. Una de las opciones anteriores es falsa.

2. A partir de la interpretación **directa** del coeficiente de *Ingreso*, ¿cuál opción es correcta?

- a. Por un incremento unitario en el ingreso, el logaritmo de la razón de probabilidades (log-odds) de incumplir disminuye en 0,30 unidades.
- b. Por un incremento unitario en el ingreso, la probabilidad de incumplir disminuye exactamente en 0,30.

☒ Como $\beta_1 < 0$, un incremento unitario en el ingreso **aumenta** las chances de incumplir.

d. Ninguna de las anteriores es correcta.

chances:

$$\frac{\theta_i}{1-\theta_i}$$

$$\exp(\beta_2) \quad \psi(x_{i2}) = \frac{\theta_i}{1-\theta_i}$$

¿Qué pasa con un aumento unitario?

$$\frac{\psi(x_{i2}+1)}{\psi(x_{i2})}$$

$$\begin{aligned} \log\left(\frac{\psi(x_{i2}+1)}{\psi(x_{i2})}\right) &= \log(\psi(x_{i2}+1)) - \log(\psi(x_{i2})) = [\beta_0 + \beta_2(x_{i2}+1)] - [\beta_0 + \beta_2 x_{i2}] \\ &= \cancel{\beta_2 x_{i2}} + \beta_2 - \cancel{\beta_2 x_{i2}} = \beta_2 \end{aligned}$$

$$\begin{aligned} \log(\psi(x_{i2}+1)) &= \beta_0 + \beta_2(x_{i2}+1) \\ \log(\psi(x_{i2})) &= \beta_0 + \beta_2 x_{i2} \end{aligned}$$

$$\log\left(\frac{\psi(x_{i2}+1)}{\psi(x_{i2})}\right) = \underbrace{\beta_2}$$

$$\frac{\psi(x_{i2}+1)}{\psi(x_{i2})} = \exp(\beta_2)$$

3. En términos de razones de odds (OR), ¿cuál opción es correcta?

- ✓ a. $\exp(\hat{\beta}_{Ingreso}) = \exp(-0,30) \approx 0,74$: por cada unidad adicional de ingreso, la chance de incumplir se reduce aproximadamente en un 26 %.
- ✓ b. $\exp(\hat{\beta}_{SegmentoC}) = \exp(0,69) \approx 2,0$: al pasar del segmento A al segmento C, la chance de incumplir aumenta aproximadamente en un 100 %.
- ✗ c. $\exp(\hat{\beta}_{SegmentoB}) = \exp(0,10) \approx 1,11$ es un cambio significativo en la OR ($p < 0,05$).
- ✓ d. Dos de las opciones anteriores son correctas.

$$2.06 \rightarrow 1 \rightarrow 1.06 \rightarrow 106\%$$

> 1 Aumento

$$0.74 \rightarrow 1 \rightarrow 0.26 \rightarrow 26\%$$

< 1 Disminución
en las chances

$$k = 4 = g.$$

Para la prueba de **significancia general** del modelo ($H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$), ¿cuál opción es correcta?

☒ El estadístico es $\chi_c^2 = D_0^2 - D^2$ (deviancia nula menos deviancia residual), con $\chi_c^2 \sim \chi_4^2$; se rechaza H_0 si $\chi_c^2 > \chi_{4,\alpha}^2$.

☐ El estadístico es $\chi_c^2 = D_0^2 - D^2$, con $\chi_c^2 \sim \chi_5^2$; se rechaza H_0 si $\chi_c^2 > \chi_{5,\alpha}^2$.

☐ Se emplea el estadístico $F_0 = \frac{SSR/k}{MSE}$ con región de rechazo $F_0 > F_{\alpha,4,n-5}$.

☐ Ninguna de las anteriores es correcta.

Porque hay 3 indicadores.

Para probar la significancia **conjunta** de la variable categórica *Segmento* ¿cuál opción es correcta?

- ☒ a. Se compara vía deviancia: $\chi_c^2 = D^2(\beta_0, \beta_1) - D^2(FM)$, con $\chi_c^2 \sim \chi_3^2$; región de rechazo $\chi_c^2 > \chi_{3,\alpha}^2$.
- b. Se compara vía deviancia: $\chi_c^2 = D^2(\beta_0, \beta_1) - D^2(FM)$, con $\chi_c^2 \sim \chi_4^2$; región de rechazo $\chi_c^2 > \chi_{4,\alpha}^2$.
- c. Basta con revisar el p -valor individual de cada nivel (*SegmentoB*, *SegmentoC*, *SegmentoD*) con la prueba $Z_c = |\hat{\beta}_j|/\hat{e}(\hat{\beta}_j)$; si al menos uno es significativo, la variable lo es.
- d. Ninguna de las anteriores es correcta.

Problema práctico 2: Con el modelo del problema anterior se evalúa el desempeño sobre una base de prueba de 400 clientes, usando un corte $\theta^* = 0,5$. La matriz de confusión obtenida es:

	Predicho Negativo	Predicho Positivo
Real Negativo	$n_{00} = 280$	$n_{01} = 20$
Real Positivo	$n_{10} = 40$	$n_{11} = 60$

A partir de esta información responda las preguntas 6 a 8.

a) A partir de la matriz de confusión, ¿cuál opción es correcta?

✓ a. La tasa de clasificación correcta es $TCC = \frac{280 + 60}{400} = 0,85$ y la tasa de falsos

negativos es $TFN = \frac{40}{40 + 60} = 0,40$.

✓ b. La sensibilidad es $\frac{60}{40 + 60} = 0,60$ y la precisión es $\frac{280}{280 + 20} \approx 0,933$.

✗ La tasa de falsos positivos es $TFP = \frac{40}{40 + 60} = 0,40$.

✗ Dos de las opciones anteriores son correctas.

$$TCC = \frac{280 + 60}{280 + 20 + 40 + 60}$$

(Proporción global de aciertos)

$$TFP = \frac{n_{01}}{n_{00} + n_{01}} = \frac{20}{280 + 20}$$

(Err Tipo I)

De los verdaderos negativos
cuantos se clasifican como positivos

$$TFN = \frac{n_{10}}{n_{10} + n_{11}} = \frac{40}{40 + 60}$$

De los verdaderos positivos
cuantos se clasifican como
negativos. (Err Tipo II)

$$\text{Sensibilidad} = 1 - TFN = 1 - \frac{40}{40 + 60}$$

Cuantos positivos reales detectamos

$$= \frac{n_{11}}{n_{10} + n_{11}} = \frac{60}{60 + 40}$$

$$\text{Especificidad} = 1 - TFP = \frac{n_{00}}{n_{00} + n_{01}} = \frac{280}{280 + 20}$$

Cuantos negativos reales
detectamos

↑

b) Respecto a la curva ROC y al área bajo la curva (AUC), ¿cuál opción es correcta?

✓ a. Un $AUC = 0,5$ corresponde a un clasificador sin capacidad de discriminación (equivalente al azar).

b. La curva ROC se construye graficando la sensibilidad frente a la tasa de falsos positivos (~~TFF~~) para el rango completo $[0, 1]$ de cortes θ^* .

✗ c. Un $AUC = 0,45$ indica un desempeño excelente como clasificador. → Pero que el azar

d. Dos de las opciones anteriores son correctas.

c) Sobre el efecto del valor de corte θ^* , ¿cuál opción es correcta?


✓ a. Al disminuir θ^* de 0,5 a 0,3 tienden a aumentar los verdaderos positivos (mayor sensibilidad), pero también aumenta la tasa de falsos positivos.

✗ b. La TCC siempre aumenta a medida que θ^* disminuye.

✓ c. Para una condición **rara** en la población (prevalencia $< 1\%$), conviene fijar θ^* considerablemente **menor** a 0,5.

✓ d. Dos de las opciones anteriores son correctas.

Verdadero → Porque más cosas cumplen el corte



Problema práctico 3: Una empresa quiere modelar el **número de accidentes laborales** por planta en un mes (Y , conteo) en función de las **horas de capacitación** impartidas ($HorasCap$, continua) y del **turno** ($I_{turno} = 1$ nocturno, $I_{turno} = 0$ diurno —referencia—). Con `glm(..., family = poisson(link = "log"))` se ajusta:

$$\ln(\lambda_i) = \beta_0 + \beta_1 HorasCap_i + \beta_2 I_{turno,i},$$

- 1) Sobre la interpretación de los parámetros, ¿cuál opción es correcta?
- a. $\exp(\hat{\beta}_2) = \exp(0,40) \approx 1,49$: al pasar del turno diurno (referencia) al nocturno, la **media** de accidentes se multiplica por 1,49 (aumenta $\approx 49\%$), manteniendo lo demás constante. ✓
 - b. $\exp(\hat{\beta}_1) = \exp(-0,05) \approx 0,95$: por cada hora adicional de capacitación, la media de accidentes se reduce $\approx 5\%$, manteniendo lo demás constante. ✓
 - ~~c.~~ β_0 tiene interpretación práctica directa en cualquier caso, pues representa la media de accidentes cuando las predictoras valen cero.
 - d. Dos de las opciones anteriores son correctas.

Sobre supuestos y pruebas del modelo Poisson, ¿cuál opción es correcta?

- a. El modelo asume $E(y_i) = \text{Var}(y_i) = \lambda$; si este supuesto no se cumple (sobredispersión), ~~se considera un modelo cuasi Poisson o binomial negativo.~~
- b. La significancia general se prueba con $\chi_c^2 = D_0^2 - D^2 \sim \chi_k^2$, con k el número de predictoras.
- c. La significancia individual del j -ésimo coeficiente se prueba con $Z_c = \frac{|\hat{\beta}_j|}{\hat{ee}(\hat{\beta}_j)} > Z_{\alpha/2}$.
- d. Todas las anteriores son correctas.