

Trabajo Práctico Modelos de Regresión (1) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al primer trabajo práctico del curso de **Estadística II** para la *Universidad Nacional de Colombia*, Sede Medellín, en el periodo 2026-1. Diferentes técnicas relacionadas al análisis de regresión son aplicadas. **Monitor:** *Tomás Rodríguez Taborda*.

Información general

Este documento corresponde al primer trabajo práctico del curso de **Estadística II** de la Universidad Nacional de Colombia, Sede Medellín, en el periodo 2026-1. Diferentes técnicas relacionadas al análisis de regresión son aplicadas.

La solución de cada uno de los problemas se efectúa a partir del software estadístico R.

Generación del conjunto de datos

Cada equipo trabaja con **su propio conjunto de datos**, el cual se genera de forma automática a partir de las cédulas de sus integrantes. Para ello se emplea el script `data_generator.R` disponible en el repositorio del curso. Siga estos pasos:

1. Abra el archivo `data_generator.R` en RStudio.
2. En la **primera línea editable**, reemplace las cédulas de ejemplo por las de los integrantes de su equipo (**sin puntos ni comas**, separadas por comas dentro de `c(...)`). Funciona para equipos de cualquier tamaño:

```
cedulas <- c(1000111222, 1000333444, 1000555666)    # <-- EDITE AQUI
```

3. Ejecute **todo** el script (botón **Source** o **Ctrl+Shift+S**). Esto:
 - Crea el archivo `datos.csv` en la carpeta de trabajo (es el conjunto de datos de su equipo).
 - Imprime en consola la **semilla** asociada a su equipo y un **código de verificación**.
4. Anote la semilla reportada: **debe usarla** para la partición entrenamiento/prueba del Punto 2. Reporte la **semilla** y el **código de verificación** en la portada del trabajo.

La salida del script se ve así (los valores dependen de sus cédulas):

*El material asociado a este trabajo puede encontrarse en el repositorio del curso, (<https://github.com/torodriguez/Estadistica-II>)

```
=====
Base generada correctamente (datos / datos.csv)
TU SEMILLA ES: 78220
Para la particion train/test usa: set.seed(78220)
CODIGO DE VERIFICACION (reportalo en la portada): 624328
=====
```

Importante: trabaje únicamente con el `datos.csv` generado por su equipo. Cada equipo recibe una base con características particulares, por lo que **no comparta ni reutilice** la base de otro equipo.

Sobre el conjunto de datos

Realice una división del conjunto de datos en entrenamiento y prueba para el desarrollo del segundo punto (modelo de regresión logística). Emplee la siguiente instrucción, donde `semilla` es el valor reportado por el script de su equipo. Es importante realizarlo de esta manera para garantizar respuestas acertadas por equipo.

```
datos    <- read.csv("datos.csv")
semilla  <- 78220                                # <-- reemplace por SU semilla

set.seed(semilla)
n <- nrow(datos)
index_train <- sample(1:n, size = 0.7 * n)
data_train  <- datos[index_train, ]
data_test   <- datos[-index_train, ]
```

Información del problema

Una entidad encargada de la gestión de una reserva ecológica desea evaluar el comportamiento de los ejemplares de una especie que habita en ella, con la intención de predecir tanto su nivel de consumo energético mensual como la probabilidad de que presenten un evento de enfermedad, y analizar si estas conductas varían en función del perfil de cada ejemplar. Para la primera situación, el nivel de consumo energético mensual de un ejemplar (que denotaremos Y_i), un biólogo desarrolla un modelo estadístico que le permita realizar la predicción en función de:

- X_1 : Alimento disponible en el territorio del ejemplar (en toneladas por mes).
- X_2 : Edad del ejemplar (en años).
- X_3 : Índice de calidad del hábitat (escala del 0 a 100).
- X_4 : Índice de cobertura vegetal del territorio (escala del 0 a 100).

- W : Patrón de comportamiento del ejemplar (*sedentario*, para ejemplares de baja movilidad que permanecen en un territorio reducido; *mixto*, para ejemplares con un comportamiento de desplazamiento balanceado; *migratorio*, para ejemplares de alta movilidad y amplios desplazamientos).

Así, el modelo propuesto por el biólogo es

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \beta_4 X_{i4} + \beta_5 \text{Mix}_i + \beta_6 \text{Mig}_i + \varepsilon_i; \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2),$$

donde Mix_i y Mig_i son las variables indicadoras de los patrones *mixto* y *migratorio*, respectivamente (categoría de referencia: *sedentario*).

Punto 1. Modelo de regresión lineal múltiple

En función de la información proporcionada, debe establecerse si el modelo propuesto es adecuado. De lo contrario, debe proponerse un modelo de regresión lineal múltiple alternativo que mejore el modelo inicial y que, de ser posible, sea más parsimonioso. Con esta finalidad, asumiendo que los supuestos del modelo se cumplen:

- (a) Realice un análisis de la multicolinealidad del modelo inicial a través del criterio del factor de inflación de varianza, número de condición e índice de condición. ¿Puede ser acertado considerar todas las covariables en este modelo? Puede emplear el método de selección automática *backward* para encontrar un modelo reducido de ser necesario. Reporte el nuevo modelo encontrado.
- (b) Realice la prueba de significancia global. Reporte los estadísticos, hipótesis asociadas y criterio de decisión. Concluya.
- (c) Realice la prueba de significancia individual. Reporte los estadísticos, hipótesis asociadas y criterio de decisión. Concluya.
- (d) Realice una predicción futura de los valores $x_{01} = 5$; $x_{02} = 43$; $x_{03} = 10$; $x_{04} = 100$; $W = \text{"Mixto"}$. Para ello, utilice únicamente las covariables que hacen parte del modelo seleccionado en el literal (a). Verifique previamente que no existe extrapolación oculta. Interprete.

Punto 2. Modelo de regresión logística

Considere ahora la segunda situación: la ocurrencia de un evento de enfermedad, representada por la variable Y_i , tal que $Y_i = 1$ si el ejemplar ha presentado un evento de enfermedad en los últimos 12 meses y $Y_i = 0$ en caso contrario, con probabilidad de éxito asociada θ_i . Se propone el modelo $\text{logit}(\theta_i) = \psi(\mathbf{x}_i)$, donde $\psi(\mathbf{x}_i)$ corresponde al mismo predictor lineal del modelo seleccionado en el literal 1-(a), pero sin el término de error ε_i . Considere que la respuesta binaria no está balanceada.

- (a) Obtenga un intervalo de confianza para los parámetros del modelo. Evalúe si son significativos. Provea una interpretación directa y una interpretación en términos de la razón de probabilidades para uno de los parámetros del modelo de regresión logística.
- (b) Reporte la curva ROC y la métrica AUC. Interprete. Halle un valor de corte θ^* óptimo que permita mantener una tasa de clasificación acertada alta, minimizando el número de falsos negativos (reporte únicamente el valor de θ^* escogido).
- (c) Reporte la matriz de confusión y la tasa de clasificación correcta. Interprete.
- (d) Realice una predicción futura de los valores $x_{01} = 5$; $x_{02} = 43$; $x_{03} = 10$; $x_{04} = 100$; $W = \text{“Mixto”}$. Para ello, utilice únicamente las covariables que hacen parte del modelo seleccionado en el literal 1-(a). Provea la probabilidad y la etiqueta obtenida (con el valor de θ^* escogido).

Aclaración: los puntos (b), (c) y (d) del Punto 2 se realizan con el conjunto de prueba (`data_test`).

Instrucciones de envío

1. La fecha límite de envío es el **17 de julio de 2026**. Entregar en formato PDF, nombrando el archivo con el **primer apellido completo** de cada integrante del equipo (por ejemplo, para los integrantes *Rodríguez, Gómez y Torres*, el archivo se llamaría `Rodriguez_Gomez_Torres.pdf`).
2. Se puede emplear ‘Overleaf’ o ‘Rmarkdown’ para la creación del trabajo, los cuales facilitan la creación de reportes en $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$. También se puede usar ‘Word’.
3. Reportar las tablas de las salidas correspondientes (multicolinealidad, significancia), con sus valores exactos. Realizar análisis breves y claros.
4. La inclusión de índice de contenidos, índice de tablas e índice de figuras es optativo, al igual que la portada. Sin embargo, es **obligatorio** reportar, ya sea en la portada o al inicio del documento, el **grupo del curso (1 o 2)** al que pertenecen, los **nombres de los integrantes**, sus **cédulas**, la **semilla** y el **código de verificación** reportados por el script. Identifique de forma clara y separada la respuesta a cada literal.
5. El conjunto de datos de cada equipo se genera con el script `data_generator.R`, disponible en el repositorio del curso de Estadística II, siguiendo las indicaciones de la sección *Generación del conjunto de datos*.