

Taller Práctico: Regresión Lineal Múltiple (2) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al segundo taller práctico del curso de **Estadística II** de la *Universidad Nacional de Colombia*, Sede Medellín, en el período 2026-02. El enfoque de este taller se centra en la comprensión del análisis de varianza (ANOVA), el coeficiente de determinación múltiple y la ejecución de pruebas de hipótesis sobre los parámetros del modelo de regresión lineal múltiple, tanto de forma individual como para subconjuntos de coeficientes a través de las sumas extra de cuadrados. **Monitor:** *Tomás Rodríguez Taborda*.

Keywords: regresión múltiple, ANOVA, pruebas de hipótesis, sumas extra de cuadrados

Información general

Con el propósito de profundizar en los conceptos del modelo de regresión lineal múltiple vistos en clase, se propone afrontar este taller en dos partes: una de teoría básica y otra práctica.

La parte computacional puede resolverse indistintamente en R o en Python. Ambos lenguajes son válidos y se publicará la solución en los dos; use el que le resulte más cómodo.

Parte teórica

Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación cuando sea necesario.**

1. Considere el siguiente modelo de regresión lineal múltiple con tres variables regresoras:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2).$$

- (a) A partir de la identidad de suma de cuadrados $SST = SSR + SSE$, indique los grados de libertad asociados a cada componente y defina los cuadrados medios MSR y MSE.
- (b) Defina la suma de cuadrados extra $SSR(\beta_2 | \beta_0, \beta_1)$ en términos de las sumas de cuadrados del error de dos modelos e indique sus grados de libertad. Interprete qué mide esta cantidad.
- (c) Para la hipótesis $H_0 : \beta_2 = \beta_3 = 0$ vs $H_1 : \text{algún } \beta_j \neq 0, j = 2, 3$, escriba el modelo completo y el modelo reducido, y especifique el estadístico de prueba F_0 junto con su distribución bajo H_0 .

*El material asociado a este taller puede encontrarse en el repositorio del curso, (<https://github.com/torodriguez/Estadistica-II>)

2. Determine el valor de verdad de las siguientes afirmaciones. **Justifique.**

- (a) La matriz $\mathbf{H} = \mathbf{X}(\mathbf{X}^t\mathbf{X})^{-1}\mathbf{X}^t$ es simétrica e idempotente, al igual que $(\mathbf{I}_n - \mathbf{H})$, y el vector de residuales puede escribirse como $\mathbf{e} = (\mathbf{I}_n - \mathbf{H})\mathbf{Y}$.
- (b) Una suma de cuadrados extra mide la reducción marginal en el SSE (equivalentemente, el incremento marginal en el SSR) cuando una o varias variables predictoras son agregadas al modelo de regresión, dado que las otras predictoras ya están en el modelo.
- (c) El estadístico T correspondiente al procedimiento empleado para probar la significancia marginal del j -ésimo parámetro es

$$T_{j,0} = \frac{\hat{\beta}_j - 0}{ee(\hat{\beta}_j)} \sim t_{n-p},$$

con región de rechazo $R_c = \{|T_{j,0}| > t_{1-\alpha/2, n-p}\}$ y p -valor $P(|t_{n-p}| > |T_{j,0}|)$.

- (d) Valores grandes de R^2 implican necesariamente que la superficie de respuesta ajustada es útil para hacer predicciones; por ello se prefiere siempre R^2 sobre R_{adj}^2 como medida de bondad de ajuste.
- (e) El R_{adj}^2 disminuye cuando se agregan al modelo variables predictoras que no logran reducir el SSE lo suficiente como para compensar la pérdida de grados de libertad; entre dos modelos ajustados se considera mejor el de mayor R_{adj}^2 (equivalentemente, el de menor MSE).
- (f) El estadístico F empleado para probar la significancia global del modelo es

$$F_0 = \frac{SSR/k}{SSE/(n-p)} = \frac{MSR}{MSE} \sim f_{k, n-p},$$

con región de rechazo $R_c = \{F_0 > f_{1-\alpha, k, n-p}\}$ y p -valor $P(f_{k, n-p} > F_0)$.

- (g) Cuando el subconjunto A consta de un único coeficiente β_j , la prueba basada en la suma de cuadrados extra es equivalente a la prueba t para la significancia marginal de β_j ; en particular $F_{j,0} = T_{j,0}^2$ y $P(f_{1, n-p} > F_{j,0}) = P(|t_{n-p}| > |T_{j,0}|)$.

Ejercicio con datos reales

Considere el siguiente conjunto de datos que agrupa información sobre el índice multidimensional de calidad de vida de la ciudad de Medellín. **Se incluyen únicamente algunas variables** cuya descripción puede encontrarse **en el siguiente enlace:** <https://medata.gov.co/dataset/1-002-09-000041>

Table 1: Información en análisis

IMCV	Ingresos	Salud	Trabajo	Capital
32.06	0.780000	2.550000	0.5100000	3.310000
32.88	0.960000	2.620000	0.5200000	3.680000
33.27	1.100000	2.650000	0.5700000	3.830000
32.82	1.121182	2.569105	0.5520319	3.739863
33.53	1.039000	3.041000	0.4850000	3.667000

Considere a *IMCV* como la variable respuesta. Las covariables consideradas en el análisis se especifican en la tabla anterior. **Dé respuesta a los siguientes planteamientos:**

1. Determine cuál es el modelo empleado en esta situación, junto con sus supuestos. Reporte la recta de regresión ajustada, calcule el vector de valores ajustados y los residuales del modelo, y obtenga una estimación de la varianza $\hat{\sigma}^2$.
2. Construya la tabla de análisis de varianza (ANOVA) y determine la significancia de la regresión global. Verifique además que esta misma prueba puede obtenerse mediante el método de sumas de cuadrados extra tomando $A = \{\beta_1, \beta_2, \beta_3, \beta_4\}$ y $B = \{\beta_0\}$, y compruebe que el estadístico F_0 coincide con el de la tabla ANOVA.
3. Determine la significancia de los parámetros individuales β_j mediante la prueba t , junto con sus intervalos de confianza del 95%. Brinde una interpretación apropiada.
4. Reporte el coeficiente de determinación múltiple R^2 y el R_{adj}^2 , e interprételos. Ajuste el modelo reducido que excluye la covariable menos significativa del punto anterior y compare ambos modelos usando R_{adj}^2 y MSE.
5. Mediante el método de sumas de cuadrados extra, realice una prueba de hipótesis para determinar si el subconjunto de covariables *Salud* y *Trabajo* aporta significativamente al modelo, dado que *Ingresos* y *Capital* ya se encuentran en él. Reporte la suma de cuadrados extra, sus grados de libertad y el estadístico F_0 . Repita el procedimiento para un único coeficiente y verifique que el resultado coincide con la prueba t correspondiente del punto 3.