

1. Considere el siguiente modelo de regresión lineal múltiple con tres variables regresoras:


$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2).$$

- (a) A partir de la identidad de suma de cuadrados $SST = SSR + SSE$, indique los grados de libertad asociados a cada componente y defina los cuadrados medios MSR y MSE.
- (b) Defina la suma de cuadrados extra $SSR(\beta_2 | \beta_0, \beta_1)$ en términos de las sumas de cuadrados del error de dos modelos e indique sus grados de libertad. Interprete qué mide esta cantidad.
- (c) Para la hipótesis $H_0: \beta_2 = \beta_3 = 0$ vs H_1 : algún $\beta_j \neq 0$, $j = 2, 3$, escriba el modelo completo y el modelo reducido, y especifique el estadístico de prueba F_0 junto con su distribución bajo H_0 .

1.

$$a) SST = \underbrace{SSR}_{\text{lo explicado}} + \underbrace{SSE}_{\text{lo no explicado}}$$

Salarios $\left\{ \begin{array}{l} \rightarrow 10 \text{ covariables } (SSR + alta, SSE - baja) \\ \rightarrow 3 \text{ covariables } (SSR - alta, SSE + alta) \end{array} \right\} \left\{ \begin{array}{l} \text{No se cual de las} \\ \text{dos no es significativa} \end{array} \right\}$



$$SST = SSR + SSE$$

$$(n-1) = \underbrace{(k)}_{\text{El vector de } \beta} + (n-p)$$

$$MSR = \frac{SSR}{k}$$

$$MSE = \frac{SSE}{n-p} = \hat{\sigma}^2 = \frac{\sum (y_i - \hat{y})^2}{n-p}$$

$$SST = \sum (y_i - \bar{y})^2$$

$$SSR = \sum (\hat{y}_i - \bar{y})^2$$

$$b) SSR(\beta_2 | \beta_0, \beta_1) = SSR(\beta_0, \beta_1, \beta_2) - SSR(\beta_0, \beta_1)$$

Interpretación: ¿Qué tanto

$$= SSE(\beta_0, \beta_1) - SSE(\beta_0, \beta_1, \beta_2)$$

mejora el ajuste por

ingresar β_2 ?

Modelo Parsimonioso $\rightarrow$ Modelo más simple

$$c) H_0: \beta_2 = \beta_3 = 0$$


$$MF: Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + \varepsilon_i \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$

$$MR: Y_i = \beta_0 + \beta_1 X_{i1} + \varepsilon_i$$

$$F_0 = \frac{SSR(\beta_2, \beta_3 | \beta_0, \beta_1) / \# \text{ de restricciones}}{MSE(MF)}$$

$$F_0 = \frac{[SSE(\beta_0, \beta_1) - SSE(\beta_0, \beta_1, \beta_2, \beta_3)] / 2}{SSE(\beta_0, \beta_1, \beta_2, \beta_3) / (n-4)}$$

$H_0 f_{2, n-4}$



$e \rightarrow$ residuos
 $e \rightarrow$ residuales

2. Determine el valor de verdad de las siguientes afirmaciones. Justifique.

- (a) La matriz $H = X(X^T X)^{-1} X^T$ es simétrica e idempotente, al igual que $(I_n - H)$, y el vector de residuales puede escribirse como $e = (I_n - H)Y$.
- (b) Una suma de cuadrados extra mide la reducción marginal en el SSE (equivalentemente, el incremento marginal en el SSR) cuando una o varias variables predictoras son agregadas al modelo de regresión, dado que las otras predictoras están en el modelo. $SS_{Extra}(\beta_0, \beta_1 | \beta_0, \beta_1, \beta_2)$
- (c) El estadístico T correspondiente al procedimiento empleado para probar la significancia marginal del j -ésimo parámetro es

$$T_{j0} = \frac{\hat{\beta}_j - 0}{ee(\hat{\beta}_j)} \sim t_{n-p}$$

con región de rechazo $R_c = \{|T_{j0}| > t_{1-\alpha/2, n-p}\}$ y p -valor $P(|t_{n-p}| > |T_{j0}|)$.

(d) Valores grandes de R^2 implican necesariamente que la superficie de respuesta ajustada es útil para hacer predicciones; por ello se prefiere siempre R^2 sobre R^2_{adj} como medida de bondad de ajuste.

a) $H = X(X^T X)^{-1} X^T$

$\hat{y} = X\hat{\beta}$ $\hat{\beta} = (X^T X)^{-1} X^T y$

$H = H^T$

$H^T = (X(X^T X)^{-1} X^T)^T$
 $= X[(X^T X)^{-1}]^T X^T$
simétrica

$H^T = X(X^T X)^{-1} X^T = H$

$H^2 = H$

$H^2 = (X(X^T X)^{-1} X^T)(X(X^T X)^{-1} X^T)$
 $= X \underbrace{(X^T X)^{-1} X^T X}_{I_n} (X^T X)^{-1} X^T$

$H^2 = X(X^T X)^{-1} X^T = H$

$(I - H)^T = I^T - H^T = I - H$

$(I - H)^2 = I^2 - 2IH + H^2$

$(I - H)^2 = I^2 - 2H + H = I - H$

c) $\hat{\beta} \sim N_p(\beta, \sigma^2(X^T X)^{-1})$

significancia marginal $\rightarrow$ 1 parámetro

$T_j = \frac{\hat{\beta}_j - \beta_j}{ee(\hat{\beta}_j)} \sim t_{n-p}$

$ee(\hat{\beta}_j) = \sqrt{\hat{\sigma}^2 c_{jj}}$
 $\downarrow$
 $(X^T X)^{-1}$

$X^T X = \begin{pmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \\ . & . & c_{33} \end{pmatrix}$

$H_0: \beta_1 = 0$ Bilateral
 $H_a: \beta_1 \neq 0$

d) Falso.

* No necesariamente es útil porque el rango de interpolación puede ser pequeño

* El MSE puede ser muy grande

* Preferimos el R^2_{adj} porque penaliza ingresar covariables

$\hat{y} = Hy$ $e = y - \hat{y}$

$e = y - Hy$

$= (I - H)y$

$p > n$

No ser simétrica

$(I - H)$
 H $\leftarrow$ Matrices de proyección

$C(X) \rightarrow$ {todas las combinaciones lineales de X }

$\hat{y} \in C(X)$

$y \xrightarrow{H} \hat{y}$
 $\uparrow$
 proyección sobre $C(X)$

H toma y y la manda a $C(X)$

$(I - H)$ toma la parte fuera del $C(X)$

$y = Hy + (I - H)y$
 $\hat{y} = \hat{y} + \underbrace{e}_{\text{explicabilidad}}$

$MSE = \frac{SSE}{n - p}$ $\leftarrow$ igual o empeora
 $\leftarrow$ decrece
 $\leftarrow$ # de parámetros

$R^2_{adj} = 1 - (n - 1) \frac{MSE}{SST}$

$R^2 = 1 - \frac{SSE}{SST}$

✓ (e) El R_{adj}^2 disminuye cuando se agregan al modelo variables predictoras que no logran reducir el SSE lo suficiente como para compensar la pérdida de grados de libertad; entre dos modelos ajustados se considera mejor el de mayor R_{adj}^2 (equivalentemente, el de menor MSE).

✓ (f) El estadístico F empleado para probar la significancia global del modelo es

$$MF \quad F_0 = \frac{SSR/k}{SSE/(n-p)} = \frac{MSR}{MSE} \sim f_{k, n-p},$$

con región de rechazo $R_c = \{F_0 > f_{1-\alpha, k, n-p}\}$ y p -valor $P(f_{k, n-p} > F_0)$.

✓ (g) Cuando el subconjunto A consta de un único coeficiente β_j , la prueba basada en la suma de cuadrados extra es equivalente a la prueba t para la significancia marginal de β_j ; en particular $F_{j,0} = T_{j,0}^2$ y $P(f_{1, n-p} > F_{j,0}) = P(|t_{n-p}| > |T_{j,0}|)$.

f) $H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$ ← No incluye el intercepto
 $H_a: \text{Algún } \beta_j \neq 0$

g) $A = \{\beta_1\}$ lo que voy a agregar

$B = \{\beta_0, \beta_2, \beta_3\}$ lo que ya está

$$T_0^2 = F_0$$

$$F_{j,0} = \frac{\hat{\beta}_j^2}{\hat{\sigma}^2 c_{jj}} = \left(\frac{\beta_j}{\text{ee}(\beta_j)} \right)^2 = T_{j,0}^2$$

$$1 \text{ MCV} = \beta_0 + \beta_1 \text{Injeksi} + \beta_2 \text{Salud} + \beta_3 \text{Trekyo} + \beta_4 \text{Capital} + \varepsilon_i \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$