

1. Pruebe que en el modelo de regresión lineal múltiple que incluye intercepto, la suma de los residuales es igual a cero.

$$\hat{\beta} = (X^T X)^{-1} X^T y \quad e = y - \hat{y} = y - X\hat{\beta}$$

$$(X^T X)\hat{\beta} = X^T y$$

$$X = \begin{pmatrix} 1 & x_{11} & \dots & x_{1k} \\ 1 & x_{21} & \dots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{nk} \end{pmatrix} \quad e = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix}$$

$$0 = X^T y - (X^T X)\hat{\beta}$$

$$= X^T y - X^T X\hat{\beta}$$

$$= X^T (y - X\hat{\beta}) = X^T e \neq 0$$

$$= \begin{pmatrix} 1 & 1 & \dots & 1 \\ x_{11} & x_{21} & \dots & x_{n1} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1k} & \dots & \dots & x_{nk} \end{pmatrix} \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

$$= (1 \ 1 \ \dots \ 1) \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = 0$$

$$= \sum_{i=1}^n e_i = 0$$

2. Determine el valor de verdad de las siguientes afirmaciones.

- Verdadero**
- (a) Bajo los supuestos del modelo de regresión lineal múltiple, se cumple que la **respuesta media estimada** $\hat{Y}_0 \sim N(E[Y|\mathbf{x}_0], \sigma^2 \mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0)$. $\sigma^2 + \dots$
 - (b) El error de predicción $\hat{Y}_0 - Y_0$ tiene una varianza asociada dada por $\sigma^2 \mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0$, al igual que $\hat{Y}_0$. De aquí que, si se sabe que $\mathbf{x}_0 = [1, x_{01}, x_{02}, \dots, x_{0k}]'$ es un punto en que no se comete extrapolación, entonces es correcto afirmar que $\mathbf{x}_0'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_0 < \max\{h_{ii}\}$.
 - (c) El procedimiento analítico **Shapiro-Wilk**, cuyo juego de hipótesis está dado por: $H_0: \varepsilon_i \sim N(0, \sigma^2)$ vs $H_1: \varepsilon_i \not\sim N(0, \sigma^2), i = 1, \dots, n$, permite determinar la normalidad de los ~~residuales~~ errores del modelo de regresión.

$$a) \hat{\mathbf{y}} = \mathbf{X}\hat{\beta} \quad \hat{y}_0 = \mathbf{x}_0' \hat{\beta} \sim N(\mathbf{x}_0' \beta, \sigma^2 (\mathbf{x}_0' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0))$$

$$E[\hat{y}_0 | \mathbf{x}_0] = E[\mathbf{x}_0' \hat{\beta}]$$

$$Var(aX) = a^2 Var(X) \quad = \mathbf{x}_0' E[\hat{\beta}] = \mathbf{x}_0' \beta$$

$$Var[\hat{y}_0 | \mathbf{x}_0] = \mathbf{x}_0' Var[\hat{\beta}] \mathbf{x}_0$$

$$\mathbf{y} \sim N(\mathbf{X}\beta, \sigma^2) \quad = \sigma^2 \mathbf{x}_0' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0$$

1 solo observación
Elipse de


$$b) Var[\hat{y}_0 - y_0] = Var[\hat{y}_0] + Var[y_0]$$

$$= \sigma^2 + \sigma^2 \mathbf{x}_0' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0$$

$$= \sigma^2 (1 + \mathbf{x}_0' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0)$$

$$\mathbf{x}_0' (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0 < \max\{h_{ii}\}$$


Diag{H}



$$c) H_0: \varepsilon_i \sim N(0, \sigma^2) \quad \text{vs} \quad H_a: \varepsilon_i \not\sim N(0, \sigma^2)$$

$$p = 0.0001 \quad \text{hay normalidad}$$

La web usa residuales pero conduce para los errores



Casi:
Si tienen pocos datos $\rightarrow$ Nunca rechaza H_0

Casi:
Si tienen muchos datos $\rightarrow$ Siempre rechaza H_0

Solo cuando el patrón tiene forma de U o invertida

* mínimos cuadrados ponderados
* usar transformaciones

Falso • (d) Si al validar los supuestos del modelo de regresión lineal múltiple se detecta varianza no homogénea, adicionar términos cuadráticos a las variables predictoras permite corregirla, ya que la heterocedasticidad siempre se debe a una especificación funcional incorrecta del modelo. $\rightarrow$ incorrecta a los datos

Falso • (e) Una observación atípica está separada del resto de las observaciones en su valor de respuesta Y, ~~aunque no afecta los resultados del ajuste~~. Su ~~evaluación~~ ^{evaluación} intuitiva se realiza a través del residual ~~estandarizado~~ ^{estandarizado} $|d_i| > 3$.

3. Seleccione las expresiones adecuadas que se muestran a continuación, interprételas y corrija las expresiones incorrectas.

✓ a. $d_i = \frac{e_i}{\sqrt{MSE}}$

b. $r_i = \frac{d_i}{\sqrt{1-h_{ii}}}$ ^{estandarizado}

✓ c. $\text{Var}(e_i) = \sigma^2(1 - h_{ii})$

⊗ d. $IP_{(1-\alpha)}(Y_0) = \hat{Y}_0 \pm t_{\alpha/2, n-p} \sqrt{MSE \mathbf{x}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0'}$ ^{falta el término}


$$e = (I - H) y$$

$$\text{Var}(e) = \sigma^2 (I - H)$$

$$\text{Var}(e_i) = \sigma^2 (1 - h_{ii})$$





$$\sigma^2 + \sigma^2 \mathbf{x}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0'$$

$$\sigma^2 (1 + \mathbf{x}_0 (\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_0')$$



Patrones de Diagnóstico en Gráficos de Residuales

Análisis de Residuales Ordinarios vs. Valores Ajustados



Valores Ajustados