

Taller Práctico: Regresión Lineal Múltiple (4) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al cuarto taller práctico del curso de **Estadística II** de la *Universidad Nacional de Colombia*, Sede Medellín, en el periodo 2026-02. El enfoque de este taller está en la comprensión del problema de multicolinealidad (efectos y diagnósticos), en los métodos de regresión penalizada Ridge y Lasso como alternativas para enfrentarlo, y en el método de todas las regresiones posibles para la selección de variables. **Monitor:** *Tomás Rodríguez Taborda*.

Keywords: regresión múltiple, multicolinealidad, Ridge, Lasso, selección de variables

Información general

Con el propósito de profundizar en los conceptos del modelo de regresión lineal múltiple vistos en clase, se propone abordar este taller en dos partes: una de teoría básica y otra práctica.

La parte computacional puede resolverse indistintamente en R o en Python. Ambos lenguajes son válidos y se publicará la solución en los dos; use el que le resulte más cómodo.

Parte teórica

Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación de ser necesario.**

1. Determine el valor de verdad de las siguientes afirmaciones.

- (a) Bajo el modelo de regresión lineal múltiple $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \varepsilon_i$; $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, la comparación de los efectos parciales de las variables debe realizarse a través del **escalamiento normal unitario de las covariables**.
- (b) La multicolinealidad refiere a la dependencia lineal casi perfecta entre covariables, afectando la matriz $\mathbf{X}'\mathbf{X}$. Esta puede descartarse si la correlación entre un par de variables $X_i \neq X_j$ es pequeña.
- (c) La multicolinealidad puede causar la inflación de las varianzas de los estimadores, además de estimadores $\hat{\beta}_j$ muy grandes en términos absolutos y valores de los coeficientes estimados con signo contrario a lo esperado.
- (d) Una forma en la que se manifiesta la multicolinealidad grave es cuando el modelo de regresión ajustado es significativo (globalmente), pero los parámetros individuales no lo son.

*El material asociado a este taller puede encontrarse en el repositorio del curso, (<https://github.com/torodriguez/Estadistica-II>)

2. Para los literales (a) y (b), indique cuál de las opciones i. a iv. es correcta. Justifique su respuesta.

(a) La regresión Lasso, en comparación con mínimos cuadrados, es:

- i. Más flexible y, por lo tanto, mejorará la precisión de predicción cuando su aumento en el sesgo sea menor que su disminución en la varianza.
- ii. Más flexible y, por lo tanto, mejorará la precisión de predicción cuando su aumento en la varianza sea menor que su disminución en el sesgo.
- iii. Menos flexible y, por lo tanto, mejorará la precisión de predicción cuando su aumento en el sesgo sea menor que su disminución en la varianza.
- iv. Menos flexible y, por lo tanto, mejorará la precisión de predicción cuando su aumento en la varianza sea menor que su disminución en el sesgo.

(b) Repita el literal (a) para la regresión Ridge en comparación con mínimos cuadrados.

3. Suponga que se estiman los coeficientes de un modelo de regresión lineal minimizando

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

para un valor particular de λ . Para los literales (a) a (e), indique cuál de las opciones i. a v. es correcta. Justifique su respuesta.

(a) A medida que λ aumenta desde 0, la suma de cuadrados de los errores (SSE) en el conjunto de entrenamiento:

- i. Aumenta inicialmente y luego empieza a disminuir, en forma de U invertida.
- ii. Disminuye inicialmente y luego empieza a aumentar, en forma de U.
- iii. Aumenta de forma sostenida.
- iv. Disminuye de forma sostenida.
- v. Permanece constante.

(b) Repita el literal (a) para la SSE en el conjunto de prueba.

(c) Repita el literal (a) para la varianza.

(d) Repita el literal (a) para el sesgo (al cuadrado).

(e) Repita el literal (a) para el error irreducible.

4. Determine el valor de verdad de las siguientes afirmaciones sobre el método de todas las regresiones posibles.
 - (a) Con $k = 4$ variables predictoras se ajustan $2^k - 1 = 15$ modelos con intercepto. Según el criterio R^2 , el mejor de ellos es el que tiene el mayor R^2 .
 - (b) Para el modelo que contiene las k variables predictoras siempre se cumple que $C_p = p$, con $p = k + 1$.
 - (c) Escoger el submodelo con el mayor R_{adj}^2 es equivalente a escoger el submodelo con el menor MSE_p .
 - (d) Para calcular el $PRESS_p$ de un submodelo es necesario ajustar n regresiones distintas, cada una sin la i -ésima observación, lo que hace que este criterio sea computacionalmente costoso.

Ejercicio con datos reales

Considere el siguiente conjunto de datos que agrupa información sobre el índice multidimensional de calidad de vida de la ciudad de Medellín. **Se incluyen únicamente algunas variables**, cuya descripción puede encontrarse **en el siguiente enlace**: <https://medata.gov.co/dataset/1-002-09-000041>

Table 1: Información en análisis

IMCV	Ingresos	Salud	Trabajo	Capital
32.06	0.780000	2.550000	0.5100000	3.310000
32.88	0.960000	2.620000	0.5200000	3.680000
33.27	1.100000	2.650000	0.5700000	3.830000
32.82	1.121182	2.569105	0.5520319	3.739863
33.53	1.039000	3.041000	0.4850000	3.667000

Considere a *IMCV* como la variable respuesta. Las covariables consideradas en el análisis se especifican en la tabla anterior. **Dé respuesta a los siguientes planteamientos:**

1. Escriba el modelo de regresión lineal múltiple, junto con sus supuestos. Deduzca a partir del modelo ajustado si podría haber problemas de multicolinealidad.
2. Realice un análisis de multicolinealidad a través del número de condición e índice de condición.
3. Ajuste un modelo de regresión Ridge, seleccionando λ por validación cruzada. Presente la gráfica de las trayectorias de los coeficientes y la del error cuadrático medio de validación cruzada frente a $\log(\lambda)$. Compare los coeficientes estimados con los de mínimos cuadrados obtenidos en el punto 1.
4. Ajuste un modelo de regresión Lasso, seleccionando λ por validación cruzada. Reporte los coeficientes estimados y el número de coeficientes distintos de cero. ¿Qué variables quedan por fuera del modelo? ¿Es coherente este resultado con el análisis de multicolinealidad del punto 2?

5. Use el método de todas las regresiones posibles para seleccionar los mejores submodelos según los criterios R^2 , R^2_{adj} (o MSE_p), C_p de Mallows y $PRESS_p$. **Seleccione el mejor modelo** y compare sus variables con las que conserva la regresión Lasso en el punto 4.

Observación: Para que los resultados sean reproducibles, use la misma configuración del ejemplo visto en clase: una grilla de 100 valores de λ entre 5 y 10^{-4} en escala logarítmica, validación cruzada de 3 particiones y semilla 50 (`set.seed(50)` en R o `random_state=50` en Python). Para el punto 5 en R puede usar las funciones `myAllRegTable`, `myR2_criterion`, `myAdj_R2_criterion` y `myCp_criterion` del archivo `functions.R` (requiere el paquete `leaps`), como en el ejemplo de clase. En Python, el archivo `functions.py` contiene funciones con los mismos nombres y la misma salida, que reciben un modelo ajustado con `statsmodels` (`from functions import myAllRegTable, myCp_criterion, ...`).