

Taller Práctico: Regresión Lineal Múltiple (5) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al quinto taller práctico del curso de **Estadística II** de la *Universidad Nacional de Colombia*, Sede Medellín, en el período 2026-02. El enfoque de este taller está en los métodos de remuestreo para estimar el error de prueba (conjunto de validación, LOOCV y validación cruzada de K particiones) como herramienta de selección de modelos, y en los modelos de regresión con variables indicadoras e interacciones. **Monitor:** *Tomás Rodríguez Taborda*.

Keywords: regresión múltiple, validación cruzada, LOOCV, variables indicadoras, interacción

Información general

Con el propósito de profundizar en los conceptos del modelo de regresión lineal múltiple vistos en clase, se propone abordar este taller en dos partes: una de teoría básica y otra práctica.

La parte computacional puede resolverse indistintamente en R o en Python. Ambos lenguajes son válidos y se publicará la solución en los dos; use el que le resulte más cómodo.

Parte teórica

Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación de ser necesario.**

1. A continuación se revisa la validación cruzada de K particiones.
 - (a) Explique cómo se implementa la validación cruzada de K particiones.
 - (b) ¿Cuáles son las ventajas y desventajas de la validación cruzada de K particiones en relación con:
 - i. el método del conjunto de validación?
 - ii. LOOCV?
 - (c) ¿Por qué, al comparar varios modelos candidatos, deben emplearse las mismas particiones en todos ellos?
2. Ahora se deriva la probabilidad de que una observación dada nunca sea usada para validar. Suponga que se dispone de n observaciones y que se aplica el método del conjunto de validación, reservando aleatoriamente n_V observaciones para validación.

*El material asociado a este taller puede encontrarse en el repositorio del curso, (<https://github.com/torodriguez/Estadistica-II>)

- (a) ¿Cuál es la probabilidad de que la j -ésima observación **no** pertenezca al conjunto de validación? Justifique su respuesta.
- (b) Suponga que el procedimiento se repite B veces de manera independiente (divisiones Monte Carlo). Argumente que la probabilidad de que la j -ésima observación nunca sea usada para validar es $(1 - n_V/n)^B$.
- (c) Con $n = 168$ y una división 80%–20%, ¿cuál es esa probabilidad cuando $B = 1$, $B = 5$ y $B = 10$?
- (d) ¿Cuál es la probabilidad correspondiente en la validación cruzada de K particiones? ¿Y en LOOCV? ¿Cuántos modelos se deben ajustar en cada caso?
- (e) Verifique numéricamente el resultado de (c) para $B = 5$: repita 10000 veces el experimento de generar cinco divisiones 80%–20% de las observaciones $1, \dots, 168$ y registre si la observación $j = 4$ quedó alguna vez en el conjunto de validación. Por ejemplo, en R:

```
store <- rep(NA, 10000)
for (i in 1:10000) {
  store[i] <- any(replicate(5, 4 %in% sample(1:168, 34)))
}
1 - mean(store)
```

o en Python:

```
import numpy as np
rng = np.random.default_rng()
store = np.empty(10000, dtype=bool)
for i in range(10000):
    store[i] = any(4 in rng.choice(np.arange(1, 169), 34, replace=False)
                  for _ in range(5))
1 - store.mean()
```

Comente los resultados obtenidos.

3. Determine el valor de verdad de las siguientes afirmaciones sobre variables indicadoras.

- (a) Si una variable cualitativa W con c categorías se representa en un modelo con intercepto mediante sus c variables indicadoras, la matriz $\mathbf{X}'\mathbf{X}$ es singular y el vector de parámetros no puede estimarse.
- (b) En el modelo de regresión lineal múltiple $Y_i = \beta_0 + \beta_2 I_{i2} + \dots + \beta_c I_{ic} + \varepsilon_i$; $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, con la categoría 1 como nivel de referencia, β_j representa la media de Y en la categoría j .

- (c) En el modelo de regresión lineal múltiple $Y_i = \beta_0 + \beta_1 X_i + \beta_2 I_{i2} + \dots + \beta_c I_{ic} + \varepsilon_i$; $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ las rectas generadas cambian su pendiente.
- (d) En el modelo de regresión lineal con interacción $Y_i = \beta_0 + \beta_1 X_i + \beta_2 I_{i2} + \dots + \beta_c I_{ic} + \beta_{c+1} X_i I_{i2} + \dots + \beta_{2c-1} X_i I_{ic} + \varepsilon_i$; $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ las rectas generadas cambian su intercepto y pendiente.

Ejercicio con datos reales

Considere el siguiente conjunto de datos que agrupa información sobre el índice multidimensional de calidad de vida de la ciudad de Medellín. **Se incluyen únicamente algunas variables**, cuya descripción puede encontrarse **en el siguiente enlace**: <https://medata.gov.co/dataset/1-002-09-000041>. La variable categórica *NivelIngresos* se obtiene al **discretizar la covariable continua Ingresos en tres niveles** ('Bajo', 'Medio' y 'Alto') de acuerdo con sus terciles.

Table 1: Información en análisis

IMCV	Ingresos	Salud	Trabajo	Capital	NivelIngresos
32.06	0.78	2.55	0.51	3.31	Bajo
32.88	0.96	2.62	0.52	3.68	Bajo
34.75	1.38	3.05	0.54	3.94	Medio
36.89	1.33	2.79	0.63	4.31	Medio
48.69	1.83	3.44	0.71	6.45	Alto
48.06	1.89	3.36	0.60	6.32	Alto

Considere a *IMCV* como la variable respuesta. Las covariables consideradas en el análisis se especifican en la tabla anterior. **Suponga que los supuestos del modelo se cumplen. Dé respuesta a los siguientes planteamientos:**

1. Considere el modelo de regresión lineal dado por la interacción $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 I_{i1} + \beta_3 I_{i2} + \beta_4 X_{i1} I_{i1} + \beta_5 X_{i1} I_{i2} + \varepsilon_i$; $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, empleado para evaluar el cambio del índice multidimensional de calidad de vida '*IMCV*' en función de '*Salud*' (numérica, X_1) y '*NivelIngresos*' (categórica), esta última con tres categorías '*Bajo*', '*Medio*' y '*Alto*', donde I_1 e I_2 son las indicadoras de las clases '*Medio*' y '*Alto*', respectivamente. **Se toma como referencia la categoría 'Bajo'. Responda:**

- (a) Caracterice la información en análisis, reportando la ecuación de las rectas en función de los diferentes niveles, así como las rectas ajustadas. Presente un gráfico de dispersión de '*IMCV*' vs. '*Salud*' con las tres rectas ajustadas.
- (b) Interprete la estimación del parámetro β_4 en términos del problema.
- (c) Determine si existe diferencia entre las ordenadas en el origen de las rectas correspondientes a las clases '*Bajo*' y '*Medio*' de '*NivelIngresos*'. Escriba la hipótesis correspondiente y el criterio de decisión.

- (d) Determine si el cambio promedio de ‘*IMCV*’ por unidad de cambio en ‘*Salud*’ es igual para las clases ‘*Bajo*’ y ‘*Medio*’ de ‘*NivelIngresos*’. Escriba la hipótesis correspondiente y el criterio de decisión.
- (e) Determine si las tres rectas son paralelas, es decir, si el efecto de ‘*Salud*’ sobre ‘*IMCV*’ es el mismo en los tres niveles de ingresos. Escriba la hipótesis correspondiente, el estadístico de prueba y el criterio de decisión.

En los puntos siguientes se consideran los modelos candidatos:

M_1 : $IMCV \sim Salud$.

M_2 : $IMCV \sim Salud + NivelIngresos$ (modelo básico, rectas paralelas).

M_3 : $IMCV \sim Salud * NivelIngresos$ (modelo general con interacciones del punto 1).

M_4 : $IMCV \sim Ingresos + Salud + Trabajo + Capital$.

2. Se estimará ahora el error de prueba del modelo M_1 usando el método del conjunto de validación. **No olvide fijar una semilla antes de comenzar el análisis.**

- (a) Ajuste el modelo M_1 con todas las observaciones y calcule su error cuadrático medio de entrenamiento.
- (b) Usando el método del conjunto de validación, estime el error de prueba de M_1 . Para ello, realice los siguientes pasos:
 - i. Divida la muestra en un conjunto de entrenamiento (80%) y uno de validación (20%).
 - ii. Ajuste el modelo usando únicamente las observaciones de entrenamiento.
 - iii. Obtenga la predicción de $IMCV$ para cada observación del conjunto de validación.
 - iv. Calcule el error cuadrático medio de validación, $ECM_{Validación}$.

¿Cómo se compara con el error de entrenamiento obtenido en (a)?

- (c) Repita el proceso de (b) tres veces, usando tres divisiones distintas de las observaciones en conjuntos de entrenamiento y validación. Comente los resultados obtenidos.
 - (d) Considere ahora los modelos M_2 y M_3 , que incluyen las variables indicadoras de *NivelIngresos* (y sus interacciones con *Salud*). Estime su error de prueba con el método del conjunto de validación, **usando las mismas divisiones** de (b) y (c). Comente si incluir las variables indicadoras conduce a una reducción del error de prueba.
3. Se realizará ahora la selección entre los cuatro modelos candidatos mediante validación cruzada.

- (a) Fije una semilla y calcule el error LOOCV y el error de validación cruzada de 10 particiones de los modelos M_1 a M_4 , usando las mismas particiones para todos ellos.
- (b) Repita (a) usando otra semilla y reporte los resultados. ¿Son los mismos que obtuvo en (a)? ¿Por qué? Distinga entre LOOCV y la validación cruzada de 10 particiones.
- (c) Presente una tabla con el ECM (y el RMSE) de los cuatro modelos. ¿Cuál modelo tuvo el menor error de validación cruzada? ¿Es lo que esperaba? Explique su respuesta.
- (d) Comente la significancia estadística de los coeficientes estimados en el ajuste por mínimos cuadrados de cada modelo (en particular, los términos de interacción de M_3 y la prueba del punto 1(e)). ¿Concuerdan estos resultados con las conclusiones de la validación cruzada? Ajuste el modelo ganador con todos los datos.

Observación: Para que los resultados sean reproducibles, use la misma configuración del ejemplo visto en clase: semilla 123 (`set.seed(123)` en R o `random_state=123` en Python) y las mismas particiones para todos los modelos comparados. En los puntos 2 y 3 puede usar `mc_cv` (con `times = 3` para el punto 2(c)), `loo_cv` y `vfold_cv` del paquete `tidymodels` junto con `workflow_set` y `workflow_map` en R; en Python, `ShuffleSplit` (con `n_splits=3`), `LeaveOneOut` y `KFold` de `sklearn.model_selection` con `cross_val_score`. En Python, la variable *NivelIngresos* debe codificarse con indicadoras tomando ‘*Bajo*’ como referencia (por ejemplo, con `pd.get_dummies(..., drop_first=True)` o usando fórmulas de `statsmodels`). Considere *NivelIngresos* como una variable dada (no recalcule los terciles en cada partición).