

1. Determine el valor de verdad de las siguientes afirmaciones.

- (a) Bajo el modelo de regresión lineal múltiple $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \varepsilon_i; \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, la comparación de los efectos parciales de las variables debe realizarse a través del **escalamiento normal unitario de las covariables**.

l I } $\begin{cases} \text{Falsa} \\ \text{L.D.} \end{cases}$
 (b) La multicolinealidad refiere a la dependencia lineal casi perfecta entre covariables, afectando la matriz $(X^T X)^{-1}$. Esta puede descartarse si la correlación entre un par de variables $X_i \neq X_j$ es pequeña. *Falsa* $\rightarrow$ guía, sospechas

verdadero (c) La multicolinealidad puede causar la inflación de las varianzas de los estimadores, además de estimadores $\hat{\beta}_j$ muy grandes en términos absolutos y valores de los coeficientes estimados con signo contrario a lo esperado.

verdadero (d) Una forma en la que se manifiesta la multicolinealidad grave es cuando el modelo de regresión ajustado es significativo (globalmente), pero los parámetros individuales no lo son.

a) Verdadero
 *adimensional } $\beta_1 \rightarrow X_1$: años de experiencia (5, 1, 7)
 *comparables } $\beta_2 \rightarrow X_2$: salarios anteriores (3.000.000, 7.000.000)
 Escalamiento $\rightarrow$ Adimensional

$$\sigma_x^2 = \frac{\sigma^2}{s_{yy}} \quad \varepsilon_i^* \stackrel{iid}{\sim} N(0, \sigma_*^2)$$

$$Y_i^* = \frac{Y_i - \bar{Y}}{\sqrt{s_{yy}}} \quad X_{ij}^* = \frac{X_{ij} - \bar{X}_j}{\sqrt{s_{jj}}} \quad Y_i^* = \beta_1^* X_{i1}^* + \beta_2^* X_{i1} + \dots + \varepsilon_i^*$$

c) $(X^T X)^*$
 $\downarrow$
 $-\text{Var}(\hat{\beta}_j^*) = \sigma^2 c_{jj}^*$
 $c_{jj}^* = \frac{1}{1 - R_j^2}$
 X_j es combinación lineal de las demás

$$R_j^2 \rightarrow 1 \quad \text{tr}(X^T X) = \sum_{j=1}^p \lambda_j$$

- $\hat{\beta}$ y β $\mathbb{E}[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^T] = \sigma^2 \text{tr}(X^T X)^{-1}$ λ_j es cercano a 0
 $|\hat{\beta}_j| \rightarrow \infty$ $= \sigma^2 \sum \frac{1}{\lambda_j}$ $\rightarrow$ Multicolinealidad
 Distancia muy grande

- $\hat{\beta}_j$ tiene signo contrario

d) $H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$
 H_a : Algún $\beta_j \neq 0 \rightarrow$ Rechaza H_0

significancia individual

$$H_0: \beta_j = 0$$


$H_a: \beta_j \neq 0 \rightarrow$ No rechaza H_0

2. Para los literales (a) y (b), indique cuál de las opciones i. a iv. es correcta. Justifique su respuesta.

(a) La regresión Lasso, en comparación con mínimos cuadrados, es:

- ✗ i. Más flexible y, por lo tanto, mejorará la precisión de predicción cuando su aumento en el sesgo sea menor que su disminución en la varianza.
- ✗ ii. Más flexible y, por lo tanto, mejorará la precisión de predicción cuando su aumento en la varianza sea menor que su disminución en el sesgo.
- ⓪ iii. Menos flexible y, por lo tanto, mejorará la precisión de predicción cuando su aumento en el sesgo sea menor que su disminución en la varianza.
- ✗ iv. Menos flexible y, por lo tanto, mejorará la precisión de predicción cuando su aumento en la varianza sea menor que su disminución en el sesgo.

(b) Repita el literal (a) para la regresión Ridge en comparación con mínimos cuadrados. (iii)



$$\hat{\beta}_{\text{Ridge}} = (X^T X + \lambda I)^{-1} X^T y$$

regularización

→ Aumenta el sesgo pero reduce la varianza



$$\hat{\beta}_{\text{Lasso}} \rightarrow \text{Forma cerrada sujeta a}$$

Permite tener $\beta_j = 0$

$$\sum |\beta_j|$$

$$x^2 + y^2 = r^2$$

$$\sum_{j=1}^p \beta_j^2$$



Descomposición del ECM: $E[(y_0 - \hat{y}_0)^2] = \text{Var}(\hat{y}_0) + [\text{sesgo}(\hat{y}_0)]^2 + \sigma^2$

Dataset 1: $(\bar{X}) \rightarrow (\bar{y}) \leftarrow$ No sabes cuánto es

Simulado 1: Correo 11

$$E[\hat{\beta}] = \beta$$

Insesgado

$$E[\hat{\theta}] = \frac{2}{3} \theta \rightarrow 10$$

$$y = \beta_0 + \sum_{j=1}^k \beta_j$$

3. Suponga que se estiman los coeficientes de un modelo de regresión lineal minimizando

$$\sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \lambda \sum_{j=1}^p \beta_j^2 \quad \text{Ridge}$$

para un valor particular de λ . Para los literales (a) a (e), indique cuál de las opciones i. a v. es correcta. Justifique su respuesta.

- (a) A medida que λ aumenta desde 0, la suma de cuadrados de los errores (SSE) en el conjunto de entrenamiento:
- Aumenta inicialmente y luego empieza a disminuir, en forma de U invertida.
 - Disminuye inicialmente y luego empieza a aumentar, en forma de U.
 - ~~Aumenta de forma sostenida.~~
 - Disminuye de forma sostenida.
 - Permanece constante.

(b) Repita el literal (a) para la SSE en el conjunto de prueba. (ii)

(c) Repita el literal (a) para la varianza. (iv)

(d) Repita el literal (a) para el sesgo (al cuadrado). (iii)

(e) Repita el literal (a) para el error irreducible (v) $\rightarrow$ depende de los datos, no de la estimación

3-

a) Cuando $\lambda = 0$ $\hat{\beta}_R = \hat{\beta}_{OLS}$

Minimiza el SSE en entrenamiento

Al aumentar λ , $\hat{\beta}_R$ se

aleja de $\hat{\beta}_{OLS}$ (se acercan

hacia cero) y la SSE bajo

cualquier estimación difiere de


$\hat{\beta}_{OLS}$ solo aumenta

b) Para λ muy grande los coeficientes ≈ 0

Por lo que el SSE prueba se comporta así:

* La reducción de la varianza pesa más que el sesgo SSE por lo que el ECM disminuye.

* Cuando sean contrarios al máximo, la varianza no puede reducirse, pero el sesgo sigue aumentando.



c)
$$\text{Var}[\hat{\beta}_R(\lambda)] = \sigma^2 (X^T X + \lambda I)^{-1} X^T X (X^T X + \lambda I)^{-1} \underbrace{\text{Var}(\hat{\beta}_0)}_{\downarrow} + \underbrace{\text{Sesgo}(\hat{\beta}_0)^2}_{\uparrow} + \sigma^2$$

es decir:
$$\frac{\sigma^2 \lambda_j}{(\lambda_j + \lambda)^2} \quad \lim_{\lambda \rightarrow \infty} \frac{\sigma^2 \lambda_j}{(\lambda_j + \lambda)^2} = 0$$

d)
$$E[\hat{\beta}_R(\lambda)] = (X^T X + \lambda I)^{-1} X^T X \beta$$

$\hookrightarrow$ si λ aumenta, la estimación aumenta y se aleja de β

$\lambda \rightarrow$ Validación cruzada

4. Determine el valor de verdad de las siguientes afirmaciones sobre el método de todas las regresiones posibles.


Falso. (a) Con $k = 4$ variables predictoras se ajustan $2^k - 1 = 15$ modelos con intercepto. Según el criterio R^2 , el mejor de ellos es el que tiene el mayor R^2 .

R^2 siempre aumenta con las covariables

Verdadero. (b) Para el modelo que contiene las k variables predictoras siempre se cumple que $C_p = p$, con $p = k + 1$.

Verdadero. (c) Escoger el submodelo con el mayor R_{adj}^2 es equivalente a escoger el submodelo con el menor MSE_p .

Falso. (d) Para calcular el $PRESS_p$ de un submodelo es necesario ajustar n regresiones distintas, cada una sin la i -ésima observación, lo que hace que este criterio sea computacionalmente costoso.



$$C_p = \frac{\text{SSE}_p}{\text{MSE}(\beta_0, \beta_1, \dots, \beta_k)} - (n - 2p)$$

Subconjunto todas las covariables

$$= \frac{\text{SSE}_p}{\text{SSE}_p / (n - p)} - (n - 2p) = (n - p) - (n - 2p) = p$$

$$c) R_{adj}^2 = 1 - \frac{\text{SSE}_p / (n - p)}{\text{SST}} = 1 - \frac{n - 1}{\text{SST}} \left(\frac{\text{MSE}_p}{k} \right)$$

$\frac{\text{SSE}}{k} = \text{MSE}$

Índice de condición $\frac{\lambda_{\max}}{\lambda_j}$

número de condición: $\frac{\lambda_{\max}}{\lambda_{\min}}$

$\lambda \rightarrow$ validación cruzada $\rightarrow$ k-fold
 $\rightarrow$ leave one out

Dataset

$P_1 | P_2 | P_3 | P_4$

$\lambda \rightarrow (0, 10)$

Lasso: $\{P_1, P_2, P_3\}$ Evaluo $\{P_4\}$ MSE

$\rightarrow$ Lasso $\{P_2, P_3, P_4\}$ Evaluo $\{P_1\}$ MSE $\lambda \rightarrow (0, 10)$

$\lambda = 6$

$\lambda = 4.6$

$n-1$ Ridge
1 Evaluo

$\lambda \rightarrow (0, 10)$