

Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación de ser necesario.**

1. A continuación se revisa la validación cruzada de K particiones.

- (a) Explique cómo se implementa la validación cruzada de K particiones. ✓
- (b) ¿Cuáles son las ventajas y desventajas de la validación cruzada de K particiones en relación con:
 - el método del conjunto de validación?
 - LOOCV?
- (c) ¿Por qué, al comparar varios modelos candidatos, deben emplearse las mismas particiones en todos ellos?

$K: 5$ o 10

1- k grupos: $C_1, C_2, \dots, C_k$
 Los datos se usan todo para validar

1ª iteración:
 $C_2, \dots, C_k \rightarrow$ Ajusto un modelo $\rightarrow ECM = \frac{1}{n_k} \sum_{i \in C_1} (y_i - y_i^{(-1)})^2$
 $C_1 \rightarrow$ Evalúo el modelo

2ª iteración:
 $C_1, C_3, \dots, C_k \rightarrow$ Ajusto un modelo
 $C_2 \rightarrow$ Evalúo el modelo

$\vdots$

k ª iteración:
 $C_1, C_2, \dots, C_{k-1} \rightarrow$ Ajusto un modelo
 $C_k \rightarrow$ Evalúo el modelo

entramiento

Más Datos $\rightarrow$ Disminuye el ECM

Normalización/Regulación

$CV = \sum_{k=1}^K \frac{n_k}{n} ECM_k$

$ECM = \frac{1}{n_k} \sum_{i \in C_k} (y_i - y_i^{(k)})^2$

b) Método Conjunto Validación $\rightarrow$ 80% datos para ajustar el modelo
 $\rightarrow$ 20% evaluar el modelo

LOOCV $\rightarrow$ Dejo fuera 1 observación, ajusto modelo.

99 $\rightarrow$ Ajusto el modelo
 1 $\rightarrow$ Evalúo si la medida es bien

100 veces (Equivalente a K-Fold cuando $K=n$)

K-Fold $\rightarrow$ K-veces

LOOCV $\rightarrow$ n veces (cantidad de datos)

Método de Validación $\rightarrow$ 1 sola partición

$\rightarrow$ Repetir muchas veces (5000)

* Conjunto de Validación

ahí no
 $n_1, n_2, \dots, n_{10}$

Ventaja K-Fold: Usa toda la información para ajustar y validar por lo menos una vez

Desventaja K-Fold: Hay que ajustar K modelos

* LOOCV

- Ventaja K-Fold: Más barato computacionalmente
 Varianza más chiquita

- Desventaja K-Fold: Dependencia de la partición, tiene un sesgo más alto
 Ajusto con menos observaciones que en LOOCV

c) Predecir un modelo "gore" porque tiene parámetros más fáciles de seguir que otro

2. Ahora se deriva la probabilidad de que una observación dada nunca sea usada para validar. Suponga que se dispone de n observaciones y que se aplica el método del conjunto de validación, reservando aleatoriamente n_v observaciones para validación.

- (a) ⁸ ¿Cuál es la probabilidad de que la j -ésima observación **no** pertenezca al conjunto de validación? Justifique su respuesta. *80% observar, 20% validar*
- (b) Suponga que el procedimiento se repite B veces de manera independiente (divisiones Monte Carlo). Argumente que la probabilidad de que la j -ésima observación nunca sea usada para validar es $(1 - n_v/n)^B$.
- (c) Con $n = 168$ y una división 80%-20%, ¿cuál es esa probabilidad cuando $B = 1$, $B = 5$ y $B = 10$?
- (d) ¿Cuál es la probabilidad correspondiente en la validación cruzada de K particiones? ¿Y en LOOCV? ¿Cuántos modelos se deben ajustar en cada caso?
- (e) Verifique numéricamente el resultado de (c) para $B = 5$: repita 10000 veces el experimento de generar cinco divisiones 80%-20% de las observaciones $1, \dots, 168$ y registre si la observación $j = 4$ quedó alguna vez en el conjunto de validación.

Por ejemplo, en R:

```
set.seed(2026)
store <- rep(NA, 10000)
for (i in 1:10000) {
  store[i] <- any(replicate(5, 4 %in% sample(1:168, 34)))
}
1 - mean(store)
```

Conjunto de validación 5 veces → *10.000 veces crea 5 particiones diferentes*

o en Python:

```
import numpy as np
rng = np.random.default_rng()
store = np.empty(10000, dtype=bool)
for i in range(10000):
  store[i] = any(4 in rng.choice(np.arange(1, 169), 34, replace=False)
                for _ in range(5))
1 - store.mean()
```

Comente los resultados obtenidos.

$$a) P(j \in V) = \frac{n_v}{n} \quad P(j \notin V) = 1 - \frac{n_v}{n} = \frac{n - n_v}{n} = 0.8$$

$$(A_1, A_2, A_3, A_4, \dots, A_B)$$

$$b) P(j \text{ nunca valida}) = P(A_1 \cap \dots \cap A_B) \\ = \prod_{b=1}^B P(A_b) \quad (\text{Independientes}) \\ = \left(1 - \frac{n_v}{n}\right)^1 \cdot \left(1 - \frac{n_v}{n}\right)^1 \dots \left(1 - \frac{n_v}{n}\right)^1 \\ \underbrace{\hspace{10em}}_{B \text{-elementos}} \\ = \left(1 - \frac{n_v}{n}\right)^B$$


*134: Entrenamiento/Ajuste
34: Validación*

$$\left(1 - \frac{34}{168}\right)^1 \left(1 - \frac{34}{168}\right)^5 \left(1 - \frac{34}{168}\right)^{10}$$

*Incluso con 10 repeticiones
deja el 10% todavía por
fuera.*

→ K-Fold: K Modelos LOOCV: n modelos

*Per construcción, siempre
entra en K-Fold por lo menos una
vez y en LOOCV una vez*



Buyo, Medo, Alto

	X_1	X_2	X_3
$n=1$	10.5	25	Alto

X_1	X_2	X_3	X_4	X_5
10.5	25	0	0	1

Indicadoras $\xrightarrow{\text{Buyo}} \begin{bmatrix} 1 & 0 & 0 \end{bmatrix}$

$\xrightarrow{\text{Medo}} \begin{bmatrix} 0 & 1 & 0 \end{bmatrix}$

3. Determine el valor de verdad de las siguientes afirmaciones sobre variables indicadoras.

Verdadero • (a) Si una variable cualitativa W con c categorías se representa en un modelo con intercepto mediante sus c variables indicadoras, la matriz $X'X$ es singular y el vector de parámetros no puede estimarse.

I_1 referencia no necesaria

Falso • (b) En el modelo de regresión lineal múltiple $Y_i = \beta_0 + \beta_2 I_{i2} + \dots + \beta_c I_{ic} + \varepsilon_i$; $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, con la categoría 1 como nivel de referencia, β_j representa la media de Y en la categoría j .

Falso • (c) En el modelo de regresión lineal múltiple $Y_i = \beta_0 + \beta_1 X_i + \beta_2 I_{i2} + \dots + \beta_c I_{ic} + \varepsilon_i$; $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ las rectas generadas cambian su ~~pendiente~~ β_1 pendiente

Verdadero (d) En el modelo de regresión lineal con interacción $Y_i = \beta_0 + \beta_1 X_i + \beta_2 I_{i2} + \dots + \beta_c I_{ic} + \beta_{c+1} X_i I_{i2} + \dots + \beta_{c+1} X_i I_{ic} + \varepsilon_i$; $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ las rectas generadas cambian su intercepto y pendiente.

$\beta_3 X_i I_{i2} \rightarrow \beta_3 X_i$

X_1 : Alive en categoría de la persona

~~$X = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \end{bmatrix}$~~ $\rightarrow$ Multicolinealidad

$(X'X)^{-1} \rightarrow$ No existe

Nivel de referencia: Buyo
 $\text{Buyo} = \text{No aparecer}$
 $\begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$

Las interpretaciones de las indicadoras

se hacen términos del nivel de referencia,

cuanto cambia la respuesta por cambio

de nivel

$I_{i2} = 1$

b) $E[Y | \text{categoría 1}] = \beta_0$ (nivel de referencia)
 ~~$Y_i = \beta_0 + \beta_2 I_{i2} + \dots + \beta_c I_{ic} + \varepsilon$~~

$E[Y | \text{categoría 2}] = \beta_0 + \beta_2$
 (cambio por pasar de categoría de referencia a categoría 2)

$d = 2$

$E[Y] = (\beta_0 + \beta_2) + (\beta_1 + \beta_3) X_i$
 Intercepto Pendiente

$d = 3$

$E[Y] = (\beta_0 + \beta_3) + (\beta_1 + \beta_4) X_i$

Tienen pendientes diferentes

1. Considere el modelo de regresión lineal dado por la interacción $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 I_{i1} + \beta_3 I_{i2} + \beta_4 X_{i1} I_{i1} + \beta_5 X_{i1} I_{i2} + \varepsilon_i$; $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, empleado para evaluar el cambio del índice multidimensional de calidad de vida 'IMCV' en función de 'Salud' (numérica, X_1) y 'NivelIngresos' (categórica), esta última con tres categorías 'Bajo', 'Medio' y 'Alto', donde I_1 e I_2 son las indicadoras de las clases 'Medio' y 'Alto', respectivamente. Se toma como referencia la categoría 'Bajo'. Responda:

$$\beta_0 + \beta_1 X_{i1} + \beta_2 I_{i1} + \beta_3 I_{i2} \quad \text{salud} + \text{NivelIngresos}$$

$$\beta_0 + \beta_1 X_{i1} + \beta_2 I_{i1} + \beta_3 I_{i2} + \beta_4 X_{i1} I_{i1} + \beta_5 X_{i1} I_{i2} \quad \text{salud} * \text{NivelIngresos}$$

a) $\beta_0 + \beta_1 X_{i1} + \beta_2 I_{i1} + \beta_4 X_{i1} I_{i1} \quad \text{Nivel medio} \quad (I_1 = 1)$

$\beta_0 + \beta_1 X_{i1} + \beta_3 I_{i2} + \beta_5 X_{i1} I_{i2} \quad \text{Nivel alto} \quad (I_2 = 1)$

$\beta_0 + \beta_1 X_{i1} \quad \text{Nivel de referencia bajo} \quad (I_1 = I_2 = 0)$

b) $\beta_4 = 4.789$ es la diferencia entre

las pendientes de los niveles medio

y bajo. Por cada unidad que aumenta el índice de Salud, el

IMCV promedio aumenta 4.789

unidades más en las observaciones

de ingresos medios que en las

de ingresos bajos

c) $H_0: \beta_2 = 0 \quad H_a: \beta_2 \neq 0$

No rechaza H_0 , no hay evidencia

para afirmar que las ordenadas en el

origen para la categoría Bajo y Medio

son distintos

d) $H_0: \beta_4 = 0 \quad H_a: \beta_4 \neq 0$

Se rechaza H_0 . El cambio promedio

del IMCV por unidad de cambio en

Salud, es distinto para Bajo y Medio.

e)

$H_0: \beta_4 = \beta_5 = 0 \quad H_a: \text{Algun } \beta_j \neq 0 \quad j=4,5$

$$F_0 = \frac{[SSE(H_0) - SSE(M_F)] / 2}{MSE(M_F)}$$

Se rechaza H_0 , las rectas no son

paralelas, el efecto de salud sobre el IMCV depende del nivel de ingresos $\rightarrow$ El modelo con interacción es el correcto.