

Problema práctico: Con el fin de estudiar algunos factores asociados al desempeño académico de los estudiantes que finalizan la educación media, se registró información de 1000 estudiantes que presentaron las pruebas Saber 11. Las variables registradas son: (Y) puntaje global obtenido en la prueba, (X_1) puntaje obtenido en la prueba de matemáticas, (X_2) edad del estudiante (en años) y (W) estrato socioeconómico de la vivienda, una variable categórica registrada en 7 niveles codificados como $1, 2, \dots, 7$. En el archivo **DatosSemana1.csv** se encuentran los registros obtenidos para estas cuatro variables (columnas Y , $PuntMat$, $Edad$ y $ESTRAT$, respectivamente). Para representar a W utilice el estrato 1 como nivel de referencia (el que R asigna por defecto con `factor(ESTRAT)`) y denote por I_{ij} la variable indicadora que toma el valor 1 si el estudiante i pertenece al estrato j y 0 en otro caso, $j = 2, \dots, 7$. A partir de esta información y empleando el software **R** responda las preguntas 1 hasta la 7 (considere $\alpha = 0.05$).

1. Considere el modelo de regresión de Y en función de X_1 y del estrato, sin interacción:

(solo intercepto) $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 I_{i2} + \beta_3 I_{i3} + \dots + \beta_7 I_{i7} + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2).$ (sin interacción)

¿Cuál de las siguientes opciones representa la ecuación ajustada para los estudiantes de estrato 3?

a. $\hat{Y} = 74.191 + 3.592 x_1,$

b. $\hat{Y} = 74.191 + 3.592 x_1 + \varepsilon_i$

c. ~~$\hat{Y} = 63.809 + 3.592 x_1,$~~

d. ~~$\hat{Y} = 63.809 + 13.974 x_1,$~~

El Estrato 3 es $I_3 = 1$

$$\hat{Y}_i = (63.809 + 10.38) + 3.59 X_1$$

2. Con base en el modelo ajustado en la pregunta anterior, ¿cuál de las siguientes opciones es correcta?

- a. Para un mismo puntaje en matemáticas, se estima que el puntaje global promedio de los estudiantes de estrato 6 es 22.794 puntos mayor que el de los estudiantes de estrato 1.
- b. Para un mismo puntaje en matemáticas, se estima que el puntaje global promedio de los estudiantes de estrato 6 es ~~24.794~~ puntos mayor que el de los estudiantes de estrato 3.
- c. Si se toma el estrato 2 como nivel de referencia (por ejemplo, con `factor(ESTRAT, levels = c(2, 1, 3, 4, 5, 6, 7))`), el coeficiente estimado de la indicadora del estrato 6 pasa a ser 17.966, mientras que la estimación de β_1 y la SSE del modelo no cambian.
- * Dos de las opciones anteriores son correctas.

Estrato 6 : $I_{i6} = 1$

Estrato 1 es el nivel de referencia

$$\hat{y}_{L(6)} = (\hat{\beta}_0 + \hat{\beta}_6) + \hat{\beta}_1 x_1 \quad \hat{y}_{L(1)} = \hat{\beta}_0 + \hat{\beta}_1 x_1$$

$$\hat{y}_{L(6)} - \hat{y}_{L(1)} = \hat{\beta}_6$$

Es el cambio promedio en la variable respecto al cambio de estrato 1 a estrato 6

$$\hat{\beta}_6 = 22.79$$

$$\hat{y}_{L(6)} - \hat{y}_{L(3)} = \hat{\beta}_6 - \hat{\beta}_3 = 22.79 - 10.38 = 12.41$$

3. Suponga que en una primera instancia se ajusta el modelo Y vs. X_1 y que en un paso posterior se evalúa la adición al modelo, de manera conjunta, de las variables indicadoras del estrato. Bajo este escenario, ¿cuál de las siguientes opciones es correcta?

a. $H_0 : \beta_2 = \beta_3 = \dots = \beta_7 = 0$ vs. $H_1 : \text{algún } \beta_j \neq 0, \text{ para } j = 2, \dots, 7$. Bajo H_0 se tiene que

$$F_0 = \frac{SSR(\beta_2, \dots, \beta_7 | \beta_0, \beta_1) / 7}{MSE(\beta_0, \beta_1, \dots, \beta_7)} \sim F_{7, 992}.$$

Así, $F_0 = 5.26$, entonces se concluye que el estrato es significativo.

b. $H_0 : \beta_2 = \beta_3 = \dots = \beta_7 = 0$ vs. $H_1 : \text{algún } \beta_j \neq 0, \text{ para } j = 2, \dots, 7$. Bajo H_0 se tiene que

$$F_0 = \frac{SSR(\beta_2, \dots, \beta_7 | \beta_0, \beta_1) / 6}{MSE(\beta_0, \beta_1, \dots, \beta_7)} \sim F_{6, 992}.$$

Así, $F_0 = 6.13$, entonces se concluye que, para un mismo puntaje en matemáticas, no todos los estratos tienen el mismo puntaje global promedio.

Individuale $\rightarrow$ Nivel Ref

c. $H_0 : \beta_2 = \beta_3 = \dots = \beta_7 = 0$ vs. $H_1 : \text{algún } \beta_j \neq 0, \text{ para } j = 2, \dots, 7$. Bajo H_0 se tiene que

$$F_0 = \frac{SSR(\beta_2, \dots, \beta_7 | \beta_0, \beta_1) / 6}{MSE(\beta_0, \beta_1, \dots, \beta_7)} \sim F_{6, 992}.$$

Así, $F_0 = 6.13$, entonces se concluye que, para un mismo puntaje en matemáticas, el puntaje global promedio de cada uno de los estratos 2 a 7 difiere significativamente del de los estudiantes de estrato 1.

Globalmente $\rightarrow$ Promedio de la respuesta

d. Dos de las opciones anteriores son correctas.

$$P\text{-value} = 2.0 \times 10^{-6} < \alpha$$

$$H_0 : \beta_2 = \beta_3 = \dots = \beta_7 = 0$$

$$H_a : \text{Algún } \beta_j \neq 0$$

$$F_0 = \frac{SSR(\beta_2, \dots, \beta_7 | \beta_0, \beta_1) / 6}{MSE(\beta_0, \beta_1, \dots, \beta_7)} \sim F_{6, 992}$$

$$n - p = 1000 - 8 = 992$$

No todos los estratos tienen el mismo puntaje global promedio

4. Ahora se desea evaluar si el efecto promedio de X_1 sobre Y depende del estrato. Para ello se ajusta el modelo general con interacciones

$$Y_i = \beta_0 + \beta_1 X_{i1} + \sum_{j=2}^7 \beta_j I_{ij} + \sum_{j=8}^{13} \beta_j X_{i1} I_{ij} + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2).$$

↗ Pendiente

¿Cuál de las siguientes opciones es correcta?

- ✗ a. Para $H_0 : \beta_2 = \beta_3 = \dots = \beta_{13} = 0$, al comparar el modelo general con el modelo que solo contiene a X_1 se obtiene $F_0 = 3.76$, que bajo H_0 sigue una distribución $F_{12, 986}$. Como $Vp < 0.05$, se rechaza H_0 y se concluye que la pendiente asociada a X_1 cambia según el estrato.
- b. En el modelo general, ninguna de las pruebas t individuales asociadas a $\beta_2, \dots, \beta_7$ resulta significativa; por tanto, se concluye que el estrato no tiene efecto sobre el puntaje global promedio. *Falso*
- ✓ c. Para $H_0 : \beta_8 = \beta_9 = \dots = \beta_{13} = 0$ vs. $H_1 : \text{algún } \beta_j \neq 0, \text{ para } j = 8, \dots, 13$, se compara el modelo general con el modelo de la pregunta 1, obteniéndose



$$F_0 = \frac{SSR(\beta_8, \dots, \beta_{13} | \beta_0, \dots, \beta_7) / 6}{MSE(\beta_0, \dots, \beta_{13})} = 1.37, \quad \text{con } F_0 \sim F_{6, 986} \text{ bajo } H_0.$$

Por tanto, no se rechaza H_0 y las rectas de Y vs. X_1 pueden considerarse paralelas en los siete estratos.

d. Dos de las opciones anteriores son correctas.

$$H_0: \beta_8 = \beta_9 = \dots = \beta_{13} = 0$$

$$H_a: \text{Algun } \beta_j \neq 0$$



Estrato4	11.20932	13.02191	0.861	0.390
Estrato5	-12.81215	17.99590	-0.712	0.477
Estrato6	3.23939	22.03763	0.147	0.883
Estrato7	-15.61122	17.50499	-0.892	0.373
PuntMat:Estrato2	-0.19856	0.18329	-1.083	0.279
PuntMat:Estrato3	0.02963	0.18328	0.162	0.872
PuntMat:Estrato4	-0.08876	0.24468	-0.363	0.717
PuntMat:Estrato5	0.39936	0.31690	1.260	0.208
PuntMat:Estrato6	0.37799	0.41608	0.908	0.364
PuntMat:Estrato7	0.37946	0.39142	0.969	0.333

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 22.01 on 986 degrees of freedom

Multiple R-squared: 0.8095, Adjusted R-squared: 0.807

F-statistic: 322.2 on 13 and 986 DF, p-value: < 2.2e-16

Modelo
Ajustado

$$F_6 = \frac{SSR(\beta_8, \dots, \beta_{13} | \beta_0, \dots, \beta_7) / 6}{MSE(\beta_0, \dots, \beta_{13})}$$

$$P\text{-value} > 0.05$$

Por tanto no rechazamos H_0

5. Considere ahora el modelo de RLM de Y en función únicamente de las predictoras cuantitativas:
 $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \varepsilon_i$. ¿Cuál de las siguientes opciones es correcta?

- ☒ a. En el modelo ajustado sin escalar se tiene que $|\hat{\beta}_1| = 3.626 > |\hat{\beta}_2| = 0.350$; por tanto, sin necesidad de escalar las variables, se puede concluir que X_1 tiene un mayor efecto parcial que X_2 sobre la respuesta promedio.
- ☒ b. Empleando el escalamiento de longitud unitaria y ajustando el modelo sin intercepto, se obtienen los coeficientes estandarizados $\hat{\beta}_1^* = 0.891$ y $\hat{\beta}_2^* = -0.017$. Así, en presencia de la otra predictora, X_1 tiene un mayor efecto parcial sobre la respuesta promedio que X_2 .
- c. El coeficiente estandarizado $\hat{\beta}_2^* = -0.017$ indica que, por cada año adicional de edad, el puntaje global promedio disminuye en 0.017 puntos, manteniendo constante el puntaje en matemáticas.
- d. Dos de las opciones anteriores son correctas.

↑ adimensional

6. Para el modelo de la pregunta anterior, ¿cuál de las siguientes opciones es correcta?

- ✓ a. Los factores de inflación de varianza son $VIF_1 = VIF_2 = 1.058$, por lo que, según este criterio, no hay problemas de multicolinealidad.
- ✓ b. Empleando la función `cond.index` del paquete `klaR`, el número de condición cumple $\sqrt{\kappa} = 20.56$, por lo que, según este criterio, hay problemas de multicolinealidad moderada.
- ✗ c. Como $VIF_1 = VIF_2$, se concluye que existe una dependencia casi lineal entre X_1 y X_2 , lo cual es consistente con su coeficiente de correlación muestral, $r_{12} = -0.235$.
- 8. Dos de las opciones anteriores son correctas.

$$VIF_1 = VIF_2 \quad (\text{con 2 predictores})$$

$$VIF_j = \frac{1}{1 - R_j^2}$$

$R_1^2 \quad Var_1 \sim Var_2 \quad R_2^2 \quad Var_2 \sim Var_1$
 R^2 en la var. de j y
 sin la regresión

$$\# \text{ números de condición} = \sqrt{\frac{\lambda_{\max}}{\lambda_{\min}}}$$

$$\text{índice de condición} = \sqrt{\frac{\lambda_{\max}}{\lambda_j}}$$

```

> cond.index(Y~PuntMat+Edad, data = data)
[1] 1.000000 7.783187 20.559602
>

```

números de
 condición

mayor a 10 y menor 31.62 multicolinealidad moderada

mayor a 31.62 multicolinealidad grave

7. Considere los $2^3 - 1 = 7$ modelos posibles (todos con intercepto) que se obtienen con los subconjuntos de las predictoras X_1 , X_2 y W , donde W ingresa siempre como el bloque de sus 6 variables indicadoras. Para calcular C_p tome como modelo completo el que contiene a X_1 , X_2 y W , y recuerde que p es el número de parámetros del modelo, incluido el intercepto. ¿Cuál de las siguientes opciones es correcta?

- a. El modelo con X_1 y W es el mejor tanto según C_p ($C_p = 8.11$, con $p = 8$) como según el criterio PRESS ($\text{PRESS}_p = 490427.1$). Además, su error cuadrático medio estimado por LOOCV es $\text{ECM}_{\text{LOOCV}} = \text{PRESS}_p/n = 490.43$.
- b. Si además se considera el modelo con interacciones de la pregunta 4, su error estimado por LOOCV sería menor que el del modelo con X_1 y W , pues su R^2 es mayor (0.8095 vs. 0.8079).
- c. Para el modelo con X_1 y W se tiene $p = 3$ de modo que $C_p = -1.89$ y $|C_p - p| = 4.89$; por tanto, este modelo debe descartarse según el criterio C_p .
- d. Dos de las opciones anteriores son correctas.

$$\text{ECM} = \frac{\text{PRESS}}{n}$$

$$W = \beta_2, \beta_3, \dots, \beta_7$$

$W \rightarrow 6$ puncheos

$X_1 \rightarrow 1$ puncheo

$\beta_5 \rightarrow 1$ puncheos

X_1
 X_2
 W
 $X_1 + X_2$
 $X_1 + W$ ✓
 $X_2 + W$

$X_1 + X_2 + W$ ✓

$W \rightarrow 1$

```
> tab[n_estr %in% c(0,6),]
```

	k	R_sq	adj_R_sq	SSE	Cp	Variables_in_model
1	1	0.801	0.801	499601	32.927	PuntMat
2	1	0.051	0.050	2379869	3905.342	Edad
13	2	0.801	0.801	498951	33.589	PuntMat Edad
246	6	0.059	0.054	2359072	3872.509	X_1 Estrato2 Estrato3 Estrato4 Estrato5 Estrato6 Estrato7
248	7	0.808	0.807	481726	8.114	PuntMat Estrato2 Estrato3 Estrato4 Estrato5 Estrato6 Estrato7
254	7	0.105	0.099	2243791	3637.088	Edad Estrato2 Estrato3 Estrato4 Estrato5 Estrato6 Estrato7
255	8	0.808	0.807	481185	9.000	PuntMat Edad Estrato2 Estrato3 Estrato4 Estrato5 Estrato6 Estrato7

```
> part <- crear_particiones(data, semilla = 123)
```

```
> validacion_cruzada(formulas, part$loocv)
```

```
# A tibble: 7 x 3
```

modelo	RMSE	MSE	(Err cuadrático medio)
<chr>	<dbl>	<dbl>	
1 X1_W	22.1	490.	$\sqrt{(y_i - \hat{y}_i)^2}$
2 X1_X2_W	22.2	491.	
3 X1	22.4	502.	
4 X1_X2	22.4	503.	
5 X2_W	47.9	2292.	
6 X2	48.9	2391.	
7 W	49.0	2403.	

8. ¿Cuál de las siguientes afirmaciones es verdadera?

No tiene forma cerrada

✗ a. Al igual que en la regresión Ridge, el estimador Lasso tiene la forma cerrada $\hat{\beta}^L(\lambda) = (\mathbf{X}'\mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}'\mathbf{y}$, la cual se reduce al estimador de mínimos cuadrados cuando $\lambda = 0$. verdad (Ridge)

✗ Si para el valor de λ seleccionado por validación cruzada la regresión Lasso conserva $\hat{\beta}_j^L \neq 0$, entonces se puede concluir que la predictora X_j es estadísticamente significativa.

✗ Antes de aplicar regresión Ridge o Lasso no es necesario estandarizar las variables, pues la penalización no depende de las unidades de medida de las predictoras.

✓ d. En la regresión Ridge, $\hat{\beta}^R(0)$ coincide con el estimador de mínimos cuadrados y, a medida que λ aumenta, las estimaciones se contraen hacia cero, aunque por lo general ninguna se hace exactamente cero; por esta razón, Ridge no puede utilizarse como método de selección de variables.

b) Lasso $\rightarrow$ selección de variables $\neq$ significancia estadística

c) β_j^2 $|\beta_j|$

$\beta_j \rightarrow$ depende de las unidades

Lasso $\rightarrow$ Manda a 0

Ridge $\rightarrow$ Conduce a 0 pero no 0 exactamente.

$$ECM_{LOOCV} = \frac{PRESS}{n}$$


9. ¿Cuál de las siguientes afirmaciones es falsa?

Falso Si la estandarización de las variables depende de los datos, basta con realizarla una sola vez con todas las observaciones antes de construir las particiones de la validación cruzada, ya que esto no afecta la estimación del error de prueba.

Verdad b. Por lo general, el error de entrenamiento subestima el error de prueba, especialmente cuando se consideran modelos muy flexibles.

Verdad c. La validación cruzada de K particiones con $K = n$ corresponde a LOOCV y, para un modelo de RLM estimado por mínimos cuadrados, se cumple que $ECM_{LOOCV} = PRESS/n$, donde $PRESS = \sum_{i=1}^n (e_i)^2 (1 - h_{ii})^2$.



Verdad d. Para comparar varios modelos candidatos mediante validación cruzada de K particiones, todos deben evaluarse con exactamente las mismas particiones.



a) Si
Estandarizo con todos los datos, estoy
usando la validación para evaluar datos
que voy a usar en el ajuste.

Entrenamiento $\rightarrow$ Estandarizo

Validación $\rightarrow$ Estandarizo



10. ¿Cuál de las siguientes opciones es verdadera?

- ✗ En el modelo sin intercepto $Y_i = \beta_1 I_{i1} + \beta_2 I_{i2} + \dots + \beta_c I_{ic} + \varepsilon_i$, el coeficiente β_j representa el cambio promedio de la respuesta cuando se pasa de la categoría 1 a la categoría j .
- ✗ Bajo la restricción $\sum_{j=1}^c \beta_j = 0$, el intercepto β_0 coincide siempre con la media global de la respuesta, sin importar el número de observaciones en cada categoría. *Si categoría 1 es el nivel de referencia*
- ✓ Si en un modelo con intercepto se incluyen las c variables indicadoras de una predictora categórica con c categorías, la primera columna de la matriz $\mathbf{X}$ es igual a la suma de las c columnas indicadoras; por tanto, $\mathbf{X}'\mathbf{X}$ es singular y $(\mathbf{X}'\mathbf{X})^{-1}$ no existe.
- ✗ En presencia de multicolinealidad grave, $(\mathbf{X}'\mathbf{X})^{-1} = \sum_{j=1}^c 1/n_j$ toma valores ~~pequeños~~ *muy grande* por lo que la distancia cuadrática esperada entre $\hat{\beta}$ y β también es ~~pequeña~~ *muy grande*.

a) Falso, eso es cuando hay un nivel de referencia. *$\beta = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y}$ No incluye*

b) Falso, $\mu_j = \beta_0 + \beta_j$

$$\beta_0 = \left[\frac{1}{c} \frac{1}{n_j} \sum_j \mu_j \right] \text{ (No importa por tamaño del nivel)}$$

c) $\mathbf{X} = \begin{bmatrix} 1 & w_1 & w_2 & w_3 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \end{bmatrix}$ *Multicolinealidad perfecta*

LD con el intercepto

$$\mathbf{e}^T \mathbf{e} = \sum e_i^2$$

d) $E[(\hat{\beta} - \beta)^T (\hat{\beta} - \beta)]$

$$\sum E[(\hat{\beta}_j - \beta_j)^2] = \text{Var}(\hat{\beta}_j)$$

$$\text{Var}(\beta_0) = \begin{pmatrix} \sigma^2 & \sigma_{12}^2 & \sigma_{13}^2 \\ \sigma_{21}^2 & \sigma_2^2 & \sigma_{23}^2 \\ \sigma_{31}^2 & \sigma_{32}^2 & \sigma_3^2 \end{pmatrix}$$

$$\sum_{j=1}^p \text{Var}(\hat{\beta}_j) = \text{tr}(\text{Var}(\hat{\beta}))$$

$$= \text{tr}(\sigma^2 (\mathbf{X}'\mathbf{X})^{-1}) = \sigma^2 \text{tr}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2 \sum \frac{1}{n_j}$$