Taller Práctico: Regresión Logística (1) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al sexto taller práctico del curso de **Estadística II** de la *Universidad Nacional de Colombia*, Sede Medellín, en el período 2026-02, y al **primer taller del tercer parcial**. Se brinda una introducción al modelo de regresión logística, su ajuste mediante máxima verosimilitud y la interpretación de sus parámetros con covariables cuantitativas, binarias y categóricas. **Monitor:** *Tomás Rodríguez Taborda.*

Keywords: regresión logística, función de enlace, máxima verosimilitud, odds ratio, interpretación de parámetros

---

Información general

Con el propósito de profundizar en los conceptos del modelo de regresión logística vistos en clase, se propone abordar este taller en dos partes: una de teoría básica y otra práctica. Se conserva el alcance del primer taller de regresión logística de 2026-I.

La parte computacional puede resolverse indistintamente en R o en Python. Justifique sus respuestas y presente las interpretaciones en el contexto del problema.

Parte teórica

Determine el valor de verdad de las siguientes afirmaciones. **Justifique cada respuesta y, cuando la afirmación sea falsa, corríjala.**

1. En un modelo de regresión logística binaria, la variable respuesta satisface $Y_i \mid \mathbf{x}_i \sim \text{Bernoulli}(\theta_i)$, donde $\theta_i = P(Y_i = 1 \mid \mathbf{x}_i)$ es la probabilidad del evento de interés para la observación i.

2. Los coeficientes $\boldsymbol{\beta}$ de un modelo de regresión logística se estiman mediante mínimos cuadrados ordinarios, porque la función de verosimilitud es no lineal.

3. Al representar una variable categórica con c niveles mediante indicadoras en un modelo con intercepto, se pueden incluir $c - 1$ indicadoras y tomar el nivel restante como referencia. Los coeficientes asociados comparan cada nivel con dicha referencia, manteniendo constantes las demás covariables.

4. En un modelo logístico sin interacciones, $\exp(\beta_j)$ representa el cambio en el logaritmo de los *odds* por cada incremento unitario en la covariable X_j, manteniendo constantes las demás covariables.

*El material asociado a este taller puede encontrarse en el repositorio del curso, **(https://github.com/torodriguezt/Estadistica-II)**

Ejercicio con datos

Considere la base simplificada **nacimientos_simplificado.csv**, utilizada en el taller de 2026-I y disponible en la subcarpeta **data** de este taller. Contiene **2000 registros** y las siguientes variables para estudiar el bajo peso al nacer:

- **BAJO_PESO**: vale 1 si el recién nacido tuvo bajo peso al nacer (menos de 2500 g) y 0 en caso contrario.
- **EDAD_MADRE**: edad de la madre, en años cumplidos.
- **CONSULTAS**: número de consultas o controles prenatales realizados durante el embarazo.
- **GEMELAR**: vale 1 si el embarazo fue múltiple (gemelar o más) y 0 si fue simple.
- **REGIMEN**: régimen de seguridad social de la madre, con niveles *Contributivo*, *Subsidiado* y *NoAsegurado*. Se toma *Contributivo* como nivel de referencia.

Table 1: Primeras cinco observaciones de la base de datos

BAJO_PESO	EDAD_MADRE	CONSULTAS	GEMELAR	REGIMEN
0	23	5	0	Contributivo
0	38	12	0	Contributivo
0	31	9	0	Contributivo
0	22	9	0	Contributivo
0	34	4	0	Contributivo

Considere **BAJO_PESO** como la variable respuesta y las otras cuatro variables como covariables. Ajuste el modelo **con intercepto y sin interacciones**, usando todas las observaciones. Para el ejercicio, suponga independencia condicional entre las respuestas y una relación lineal entre el logit de la probabilidad y las covariables codificadas.

1. **Formulación y ajuste del modelo.**

   - (a) Escriba el modelo de regresión logística e identifique sus componentes: la probabilidad θ_i, la función de enlace $g(\theta_i)$ y el predictor lineal $\psi(\mathbf{x}_i) = \mathbf{x}_i^\top \boldsymbol{\beta}$. Defina explícitamente las dos variables indicadoras asociadas a *REGIMEN*.
   - (b) ¿Por qué se emplea la función *logit* como función de enlace? Escriba la expresión que permite recuperar θ_i a partir del predictor lineal.
   - (c) Plantee la función de verosimilitud y su logaritmo para este modelo. Explique por qué se recurre a un procedimiento numérico para estimar los parámetros. Ajuste el modelo por máxima verosimilitud y reporte la ecuación estimada.

2. **Interpretación de los parámetros.**

   - (a) Interprete cada coeficiente estimado directamente en la escala de los log-*odds*. ¿Qué representa el intercepto y qué limitación tiene su interpretación en este contexto?

   - (b) Calcule e interprete $\exp(\widehat{\beta}_j)$ para cada covariable como una razón de momios (*odds ratio*). Distinga entre un incremento unitario en *EDAD_MADRE* o *CONSULTAS*, un embarazo múltiple frente a uno simple y cada régimen frente a *Contributivo*. Mantenga constantes las demás covariables en cada comparación.

   - (c) Explique por qué un *odds ratio* no es, en general, una razón de probabilidades ni un cambio constante en la probabilidad de bajo peso al nacer.

Guía: En R puede usar `glm()` con `family = binomial(link = "logit")`; en Python, `GLM` de `statsmodels` con familia binomial y enlace logit. Verifique que el evento modelado sea `BAJO_PESO = 1`, incluya el intercepto y establezca explícitamente **Contributivo** como referencia de **REGIMEN**.