Taller Práctico: Regresión Logística (2) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al séptimo taller práctico del curso de **Estadística II** de la *Universidad Nacional de Colombia*, Sede Medellín, en el período 2026-02, y al **segundo taller del tercer parcial**. Se estudian las pruebas de significancia global e individual del modelo de regresión logística y su evaluación como clasificador mediante la predicción, la matriz de confusión, la curva ROC, el AUC y la elección del punto de corte. **Monitor:** *Tomás Rodríguez Taborda.*

Keywords: regresión logística, deviance, prueba de Wald, clasificación, matriz de confusión, curva ROC, AUC, punto de corte

---

Información general

Con el propósito de profundizar en los conceptos del modelo de regresión logística vistos en clase, se propone abordar este taller en dos partes: una de teoría básica y otra práctica. Se conserva el alcance del segundo taller de regresión logística de 2026-I.

La parte computacional puede resolverse indistintamente en R o en Python. Justifique sus respuestas y presente las interpretaciones en el contexto del problema.

Parte teórica

Determine el valor de verdad de las siguientes afirmaciones. **Justifique cada respuesta y, cuando la afirmación sea falsa, corríjala.**

1. El modelo de regresión logística $\text{logit}(\theta_i) = \psi(\mathbf{x}_i)$ clasifica directamente cada observación como éxito ($Y_i = 1$) o fracaso ($Y_i = 0$).

2. Considere la matriz de confusión cuyas filas corresponden a la clase real y cuyas columnas a la clase predicha, de modo que n_{jk} es el número de observaciones con $Y_i = j$ clasificadas como $\widehat{Y}_i = k$, con $j, k \in \{0, 1\}$. La tasa de falsos positivos se calcula como $n_{01}/(n_{00} + n_{01})$ e indica la proporción de observaciones clasificadas como positivas cuando realmente eran positivas.

3. La curva ROC muestra cómo cambian la sensibilidad y la especificidad a medida que varía el punto de corte θ^*: cada punto de la curva corresponde a un valor de θ^* y tiene coordenadas $(1 - \text{especificidad}, \text{sensibilidad})$. De ella se deriva el AUC, que resume el desempeño del modelo sin fijar un punto de corte.

4. La elección del punto de corte θ^* modifica la matriz de confusión y las métricas que se derivan de ella, pero no cambia los coeficientes estimados ni las probabilidades estimadas $\widehat{\theta}_i$.

*El material asociado a este taller puede encontrarse en el repositorio del curso, **(https://github.com/torodriguezt/Estadistica-II)**

5. Un modelo con un AUC igual a 0.5 no discrimina mejor que una asignación al azar; por tanto, su tasa de clasificación correcta es necesariamente cercana al 50 %.

6. Para probar la significancia global del modelo, $H_0 : \beta_1 = \cdots = \beta_k = 0$, se usa el estadístico $\chi^2_c = D_0 - D$, donde D_0 y D son la deviance nula y la deviance residual, y se rechaza H_0 si $\chi^2_c > \chi^2_{k,\alpha}$. Para la significancia individual, en cambio, se prefiere la prueba *t de Student*.

Ejercicio con datos

Considere nuevamente la base **nacimientos_simplificado.csv** del primer taller, disponible en la subcarpeta **data** de este taller. Contiene **2000 registros** y las siguientes variables:

- **BAJO_PESO**: vale 1 si el recién nacido tuvo bajo peso al nacer (menos de 2500 g) y 0 en caso contrario.
- **EDAD_MADRE**: edad de la madre, en años cumplidos.
- **CONSULTAS**: número de consultas o controles prenatales realizados durante el embarazo.
- **GEMELAR**: vale 1 si el embarazo fue múltiple (gemelar o más) y 0 si fue simple.
- **REGIMEN**: régimen de seguridad social de la madre, con niveles *Contributivo*, *Subsidiado* y *NoAsegurado*. Se toma *Contributivo* como nivel de referencia.

Table 1: Primeras cinco observaciones de la base de datos

BAJO_PESO	EDAD_MADRE	CONSULTAS	GEMELAR	REGIMEN
0	23	5	0	Contributivo
0	38	12	0	Contributivo
0	31	9	0	Contributivo
0	22	9	0	Contributivo
0	34	4	0	Contributivo

Para evaluar el modelo como clasificador, divida la base en un conjunto de **entrenamiento**, formado por las **primeras 1400 observaciones** (70 %), y uno de **prueba**, formado por las **600 restantes** (30 %). Los registros no están ordenados por ninguna variable, de modo que esta partición fija cumple el papel de una partición aleatoria y permite obtener los mismos resultados en R y en Python.

Considere **BAJO_PESO** como la variable respuesta y retome el modelo del primer taller: **con intercepto, sin interacciones** y con las otras cuatro variables como covariables. Ajústelo **solo con el conjunto de entrenamiento** y use el conjunto de prueba únicamente para evaluar su desempeño. En todo el taller, una observación se clasifica como bajo peso ($\widehat{Y}_i = 1$) si $\widehat{\theta}_i \geq \theta^*$, y como peso normal ($\widehat{Y}_i = 0$) en caso contrario. Use un nivel de significancia $\alpha = 0.05$.

1. Realice una prueba de significancia de los parámetros individuales. Provea una *interpretación directa* de los parámetros del modelo de regresión logística, así como una *interpretación en términos de la razón de probabilidades*.

2. Realice una predicción de futuras observaciones. Utilice las probabilidades obtenidas para la construcción de un clasificador logístico con etiquetas.

3. Analice el rendimiento del modelo a través de la curva ROC y el AUC. Interprete.

4. Halle un valor de corte θ^* óptimo que permita mantener una **tasa de clasificación acertada alta**, minimizando el número de falsos negativos.

5. Reporte la matriz de confusión y la tasa de clasificación correcta. ¿Cómo cambian estas matrices con diferentes valores de θ^*?

Guía: En R puede usar `glm()` con `family = binomial(link = "logit")`, `predict(..., type = "response")` y las funciones `roc()` y `auc()` del paquete `pROC`; en Python, `GLM` de `statsmodels` con familia binomial y las funciones `roc_curve()`, `roc_auc_score()` y `confusion_matrix()` de `sklearn.metrics`. Verifique que el evento modelado sea `BAJO_PESO = 1` y que **Contributivo** sea la referencia de **REGIMEN**.