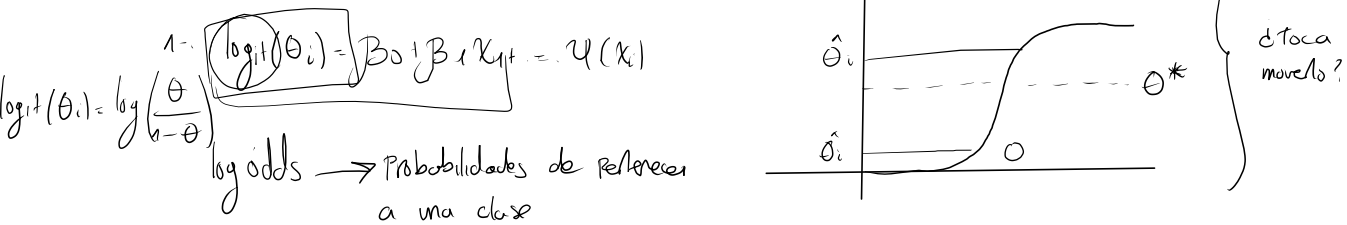
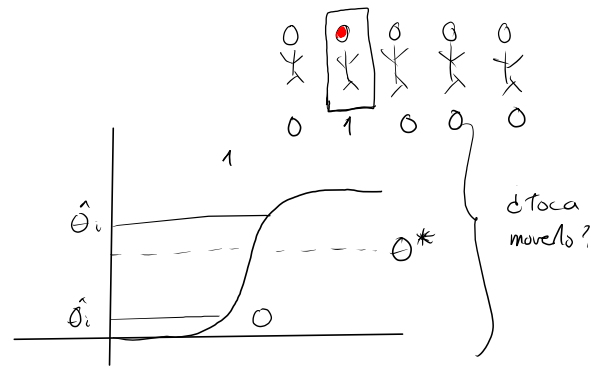
1. El modelo de regresión logística $\text{logit}(\theta_i) = \psi(\mathbf{x}_i)$ clasifica directamente cada observación como éxito ($Y_i = 1$) o fracaso ($Y_i = 0$). Falso

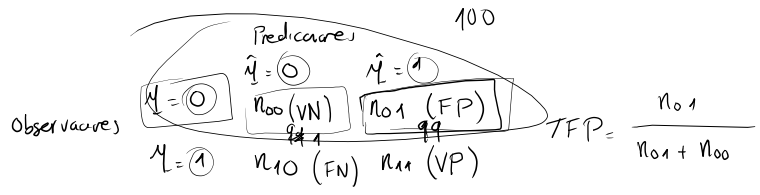
V 2. Considere la matriz de confusión cuyas filas corresponden a la clase real y cuyas columnas a la clase predicha, de modo que n_{jk} es el número de observaciones con $Y_i = j$ clasificadas como $\hat{Y}_i = k$, con $j, k \in \{0, 1\}$. La tasa de falsos positivos se calcula como $n_{01}/(n_{00} + n_{01})$ e indica la proporción de observaciones clasificadas como negativas cuando realmente eran positivas.

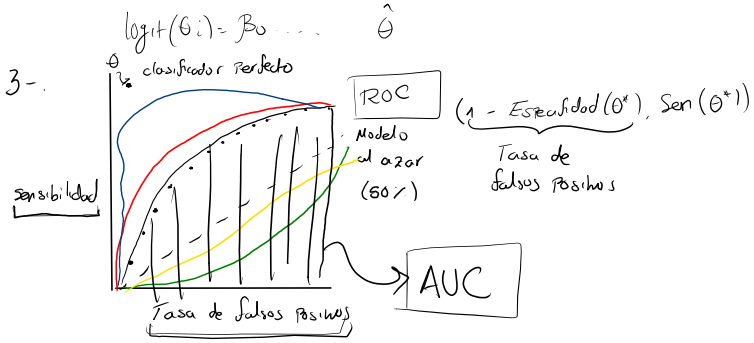
3. La curva ROC muestra cómo cambian la sensibilidad y la especificidad a medida que varía el punto de corte θ^*: cada punto de la curva corresponde a un valor de θ^* y tiene coordenadas $(1 - \text{especificidad}, \text{sensibilidad})$. De ella se deriva el AUC, que resume el desempeño del modelo sin fijar un punto de corte. Verdadero

4. La elección del punto de corte θ^* modifica la matriz de confusión y las métricas que se derivan de ella, pero no cambia los coeficientes estimados ni las probabilidades estimadas $\hat{\theta}_i$. Verdadero









4 - $\hat{\beta}$ → Máxima verosimilitud.

$\hat{\theta}_i$ → $\hat{\beta}$, x_i

θ^* → Cambiar como clasifico el resultado del logit

$\text{logit}(\theta_i) = \beta_0 + \beta_1 x_1 + \ldots$

	$\theta^* = 0.5$	$\theta^* = 0.95$
0.9 →	1	0
0.4	0	0
0.7	1	0
0.6	1	0
0.85	1	0

verdadero

5. Un modelo con un AUC igual a 0.5 no discrimina mejor que una asignación al azar; por tanto, su tasa de clasificación correcta es ~~necesariamente cercana al 50 %~~. Falso

6. Para probar la significancia global del modelo, $H_0 : \beta_1 = \cdots = \beta_k = 0$, se usa el estadístico $\chi^2_c = D_0 - D$, donde D_0 y D son la deviance nula y la deviance residual, y se rechaza H_0 si $\chi^2_c > \chi^2_{k,\alpha}$. Para la significancia individual, en cambio, se prefiere la prueba ~~t de Student~~. Falso

Z - estándar

600 → 540 Peso normal $\hat{y}_i = 0$ AUC ≈ 0.5

60 desnutrición se equivoca siempre.

TCC → Aciertos / Total

$\frac{540}{600} = 90\%$

6 - $H_0: \beta_1 = \ldots = \beta_k = 0$

H_a: Algún $\beta_j \neq 0$

$$D = 2\left[\ell(\hat{\theta}_{sat}) - \ell(\hat{\theta})\right] \qquad \chi^2 = D_0 - D$$

Un modelo con tantos parametros como para reproducir perfectamente los datos.

Modelo candidato

$$z_c = \frac{\hat{\beta}_j}{\hat{ee}(\hat{\beta}_j)} \overset{approx}{\sim} N(0,1)$$

$y \sim Binomial(n, p)$

$Var(y) = p(1-p)$

1. Realice una prueba de significancia de los parámetros individuales. Provea una *interpretación directa* de los parámetros del modelo de regresión logística, así como una *interpretación en términos de la razón de probabilidades.*
2. Realice una predicción de futuras observaciones. Utilice las probabilidades obtenidas para la construcción de un clasificador logístico con etiquetas.
3. Analice el rendimiento del modelo a través de la curva ROC y el AUC. Interprete.
4. Halle un valor de corte θ^* óptimo que permita mantener una **tasa de clasificación acertada alta**, minimizando el número de falsos negativos.
5. Reporte la matriz de confusión y la tasa de clasificación correcta. ¿Cómo cambian estas matrices con diferentes valores de θ^*?

$\beta_j \rightarrow$ cambio en el log odds (Aditivo)

$\exp(\beta_j) \rightarrow$ cuantas veces cambian los odds (multiplicativos)

No significativos.

	coef	std err	z	P>|z|	[0.025	0.975]
Intercept	-1.4400	0.485	-2.966	0.003	-2.392	-0.488
REGIMEN[T.NoAsegurado]	-0.0283	0.318	-0.089	0.929	-0.652	0.596
REGIMEN[T.Subsidiado]	0.1764	0.209	0.843	0.399	-0.234	0.587
EDAD_MADRE	0.0113	0.015	0.745	0.456	-0.018	0.041
CONSULTAS	-0.1545	0.036	-4.248	0.000	-0.226	-0.083
GEMELAR	4.0486	0.534	7.585	0.000	3.003	5.095

```
np.exp(modelo.params)
✓ 0.0s

Intercept                0.236930
REGIMEN[T.NoAsegurado]   0.972094
REGIMEN[T.Subsidiado]    1.192962
EDAD_MADRE               1.011314
CONSULTAS                0.856829
GEMELAR                 57.318988
dtype: float64
```

$0.856 \rightarrow 1$ lo reduce un $0.144 \rightarrow 14.32\%$

Consultas: por cada consulta adicional el log de la razón de probabilidades de bajo peso disminuye 0.1545

$\exp(\hat{\beta}) = 0.85$, cada consulta adicional multiplica los odds de bajo peso por 0.85

Entrenamiento

$$2.\ \text{logit}(\theta_i) = \eta = \hat{\beta}_0 + 30\hat{\beta}_1 + 4\hat{\beta}_2 + \hat{\beta}_4$$

$$\hat{\theta} = \frac{1}{1+\exp(-\eta)} = 0.1759$$

```
y_prueba = test["BAJO_PESO"]
prob_test = modelo.predict(test)

print(pd.crosstab(y_prueba, prob_test>=0.5))

[13] ✓ 0.0s
```

Predicción

col_0	False	True
BAJO_PESO		
0	538 (n_{00})	2 (n_{01})
1	53 (n_{10})	7 (n_{11})

Real