Taller Práctico: Bosques Aleatorios, Boosting e Interpretación Global de Modelos de Caja Negra *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al taller práctico sobre bosques aleatorios, *boosting* y métodos globales de interpretación del curso de **Estadística II** de la *Universidad Nacional de Colombia*, Sede Medellín, en el período 2026-02. Se estudian las dos formas de mejorar el promedio de árboles (decorrelacionarlos y construirlos de manera secuencial) y la manera de describir un modelo de caja negra mediante la importancia de las variables, la dependencia parcial, las curvas ICE y los modelos sustitutos. **Monitor:** *Tomás Rodríguez Taborda.*

Keywords: bosques aleatorios, boosting, importancia por permutación, dependencia parcial, curvas ICE, modelo sustituto

---

Información general

Con el propósito de profundizar en los conceptos de bosques aleatorios, *boosting* y métodos globales de interpretación vistos en clase, se propone afrontar este taller en dos partes: una de teoría básica y otra práctica.

La parte computacional puede resolverse indistintamente en R o en Python.

Parte teórica

Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación cuando sea necesario**.

1. Sean $Z_1, \ldots, Z_B$ variables aleatorias con $Var(Z_b) = \sigma^2$ y $Corr(Z_b, Z_{b'}) = \rho$ para todo $b \neq b'$.

   - (a) Demuestre que $Var\left(\bar{Z}\right) = \rho\,\sigma^2 + \frac{1-\rho}{B}\,\sigma^2$.
   - (b) Obtenga el límite cuando $B \to \infty$. Explique por qué aumentar el número de árboles en *bagging* no reduce la varianza indefinidamente y cuál de los dos términos ataca un bosque aleatorio.

2. Un bosque aleatorio elige al azar m de las p predictoras cada vez que se considera una partición.

   - (a) Si existe una predictora mucho más fuerte que las demás, obtenga la proporción esperada de particiones en las que esa predictora **no es candidata**, y evalúela para $p = 8$ y $m = 3$.

*El material asociado a este taller puede encontrarse en el repositorio del curso, **(https://github.com/torodriguezt/Estadistica-II)**

- (b) Explique por qué lo anterior **decorrelaciona** los árboles. ¿Qué procedimiento se obtiene cuando $m = p$?

3. Considere el algoritmo de *boosting* para árboles de regresión, con B árboles, parámetro de contracción λ y d particiones por árbol.

   - (a) Explique por qué se dice que el procedimiento **aprende despacio** y en qué se diferencia de *bagging*.
   - (b) Discuta la relación entre λ y B, y por qué B debe elegirse con cuidado en *boosting* pero no en *bagging*.

4. Determine el valor de verdad de las siguientes afirmaciones. **Justifique en todos los casos.**

   - (a) En un bosque aleatorio, las m predictoras candidatas se eligen una sola vez por árbol y se mantienen en todas sus particiones.
   - (b) Si la importancia por permutación de X_j es cercana a cero, la respuesta Y no depende de X_j en la población.
   - (c) Si las curvas ICE de X_j son paralelas, el modelo no tiene interacciones entre X_j y las demás predictoras.
   - (d) La importancia por reducción de impureza, calculada en el entrenamiento, tiende a favorecer a las predictoras con muchos puntos de corte posibles, aunque no se relacionen con Y.

Ejercicio con datos reales: bosques aleatorios y boosting

Considere el conjunto de datos `Boston`, con información de 506 sectores censales del área de Boston. La respuesta es *medv*, el valor mediano de las viviendas en miles de dólares.

Table 1: Información en análisis: Boston

medv	lstat	rm	crim	ptratio	dis
24.0	4.98	6.575	0.00632	15.3	4.0900
21.6	9.14	6.421	0.02731	17.8	4.9671
34.7	4.03	7.185	0.02729	17.8	4.9671
33.4	2.94	6.998	0.03237	18.7	6.0622
36.2	5.33	7.147	0.06905	18.7	6.0622

1. Divida el conjunto en entrenamiento y prueba, **fijando la semilla**. Ajuste bosques aleatorios con $m \in \{1, 2, 3, 4, 5\}$ y B entre 1 y 500, y grafique el MSE de prueba en función de B, con una curva por cada m. **Describa los resultados** e indique qué curva corresponde a *bagging*.

2. Para el mejor modelo, compare el error *out-of-bag* con el MSE de prueba y obtenga la importancia de las variables. **Interprete.**

Considere ahora el conjunto de datos `Hitters`, con estadísticas de jugadores de béisbol y su salario.

Table 2: Información en análisis: Hitters

Salary	CRuns	CRBI	CHits	Years	Walks	PutOuts
475.0	321	414	835	14	39	632
480.0	224	266	457	3	76	880
500.0	828	838	1575	11	37	200
91.5	48	46	101	2	30	805
750.0	501	336	1133	11	35	282

3. Elimine los salarios desconocidos, use $\log(\textit{Salary})$ como respuesta (**justifique**) y tome las primeras 200 observaciones como entrenamiento y las restantes como prueba.

4. Ajuste *boosting* con $B = 1000$ árboles para una rejilla de valores de λ. Grafique el MSE de entrenamiento y el de prueba en función de λ. Elija λ y **explique** por qué las dos curvas no llevan a la misma conclusión.

5. Con el λ elegido, compare los errores de prueba con $d = 1$ y $d = 4$ y con los de una regresión lineal múltiple y un bosque aleatorio. **Discuta** cuál procedimiento preferiría.

Ejercicio con datos reales: interpretación global

Considere el conjunto de datos `Bikeshare`, que registra el número de usuarios por hora de un sistema de bicicletas compartidas de Washington D. C. en 2011 (8645 registros). Está disponible en `ISLR2` (R) y en `ISLP` (Python).

Table 3: Información en análisis: Bikeshare

bikers	hr	workingday	temp	atemp	hum	windspeed
16	0	0	0.24	0.2879	0.81	0
40	1	0	0.22	0.2727	0.80	0
32	2	0	0.22	0.2727	0.80	0
13	3	0	0.24	0.2879	0.75	0
1	4	0	0.24	0.2879	0.75	0

La respuesta es *bikers* (usuarios en la hora); *hr* es la hora del día, que debe tratarse como **numérica**, y *temp* y *atemp* son la temperatura y la sensación térmica normalizadas.

1. Divida el conjunto en entrenamiento (70%) y prueba (30%), **fijando la semilla**. Ajuste un bosque aleatorio con $B = 500$ árboles y compare su MSE de prueba con el de una regresión lineal múltiple.

2. Agregue dos variables de ruido, *ruido_bin* $\sim$ Bernoulli(0.5) y *ruido_cont* $\sim N(0,1)$, reajuste el bosque y obtenga la importancia por reducción de impureza y por permutación (en prueba). **Compare** la importancia de cada variable de ruido según los dos criterios.

3. Reajuste el bosque **sin** *atemp* y compare la importancia por permutación de *temp*. Relacione el resultado con la correlación entre ambas.

4. Grafique la dependencia parcial de *temp* y de *hr*, y las curvas ICE de *hr* para 300 observaciones, **centradas** y coloreadas según *workingday*. **Describa** la forma de los efectos y qué oculta la dependencia parcial.

5. Ajuste un árbol de regresión de profundidad 3 a las **predicciones** del bosque en el entrenamiento. Reporte su fidelidad en el conjunto de prueba, **interprete** dos de sus reglas y discuta si el árbol podría reemplazar al bosque.