Taller Práctico: Interpretación de Modelos de Caja Negra II (Métodos Locales) *

Estadística II *Universidad Nacional de Colombia, Sede Medellín*

Este documento corresponde al taller práctico sobre métodos locales de interpretación del curso de **Estadística II** de la *Universidad Nacional de Colombia*, Sede Medellín, en el período 2026-02. El enfoque de este taller se centra en explicar una predicción individual desde tres preguntas distintas: cómo responde el modelo alrededor de la observación (LIME), cuánto aporta cada predictora a la diferencia con la predicción media (valores de Shapley y SHAP) y qué tendría que cambiar para obtener otra predicción (explicaciones contrafactuales). **Monitor:** *Tomás Rodríguez Taborda.*

Keywords: LIME, valores de Shapley, SHAP, explicaciones contrafactuales

---

Información general

Con el propósito de profundizar en los métodos locales de interpretación vistos en clase, se propone afrontar este taller en dos partes: una de teoría básica y otra práctica.

La parte computacional puede resolverse indistintamente en R o en Python.

Parte teórica

Dé respuesta a las preguntas formuladas a continuación con base en la teoría tratada en clase. **Provea una interpretación cuando sea necesario**.

1. Un modelo de riesgo de crédito estima la probabilidad de incumplimiento a partir del saldo de la tarjeta (S), el ingreso (I) y la condición de estudiante (E). Para un cliente x_0, la predicción promedio conociendo únicamente las predictoras de cada coalición es

$\emptyset$	$\{S\}$	$\{I\}$	$\{E\}$	$\{S, I\}$	$\{S, E\}$	$\{I, E\}$	$\{S, I, E\}$
0.10	0.30	0.08	0.12	0.26	0.36	0.09	0.32

(adaptado de Molnar, 2022, capítulo de valores de Shapley).

   - (a) Escriba los $3! = 6$ órdenes de revelación con la contribución de cada predictora, y obtenga ϕ_S, ϕ_I y ϕ_E como el promedio de los seis órdenes.
   - (b) Verifique la propiedad de **eficiencia** e interprete el signo de ϕ_I para este cliente.
   - (c) Si el modelo cumpliera $v(\mathcal{C} \cup \{I\}) = v(\mathcal{C})$ para toda coalición $\mathcal{C}$ sin I, ¿cuánto valdría ϕ_I? ¿Qué propiedad lo garantiza?

*El material asociado a este taller puede encontrarse en el repositorio del curso, **(https://github.com/torodriguezt/Estadistica-II)**

2. Considere un modelo lineal $\widehat{f}(x) = \beta_0 + \sum_{j=1}^{p} \beta_j x_j$ y la función de valor vista en clase, $v(\mathcal{C}) = \frac{1}{n} \sum_{i=1}^{n} \widehat{f}\left(x_{0,\mathcal{C}},\ x_{\bar{\mathcal{C}}}^{(i)}\right)$.

   - (a) Demuestre que $\phi_j = \beta_j \, (x_{0j} - \bar{x}_j)$.
   - (b) Explique por qué ϕ_j puede ser cero aunque $|\beta_j|$ sea muy grande, y qué diferencia hay entre leer β_j y leer ϕ_j.
   - (c) En una regresión logística, el resultado de (a) se cumple en la escala del logaritmo de las chances, pero **no** en la de la probabilidad. Explique por qué.

3. Para el mismo modelo lineal, considere LIME con regresores estandarizados $\tilde{z}_{ij} = (z_{ij} - x_{0j})/s_j$ y pesos $\pi_{x_0}(z_i) > 0$.

   - (a) Demuestre que, para cualquier ancho de núcleo, la solución de mínimos cuadrados ponderados es $\widehat{\beta}_0 = \widehat{f}(x_0)$ y $\widehat{\beta}_j = \beta_j \, s_j$.
   - (b) Compare esta explicación con la de SHAP del punto 2(a). ¿Por qué, aun para un modelo lineal, responden preguntas distintas?

4. Determine el valor de verdad de las siguientes afirmaciones. **Justifique en todos los casos.**

   - (a) Si $\phi_j > 0$ para la observación x_0, aumentar X_j aumenta la predicción del modelo en x_0.
   - (b) ϕ_j es la diferencia entre la predicción de x_0 con el modelo completo y la de un modelo reajustado sin X_j.
   - (c) Si se cambia el conjunto de referencia, cambian ϕ_0 y los ϕ_j, pero su suma sigue siendo igual a $\widehat{f}(x_0)$.
   - (d) Como el modelo ajustado es determinista, dos ejecuciones de LIME con semillas distintas producen la misma explicación.
   - (e) La media de $|\phi_j|$ sobre un conjunto de prueba y la importancia por permutación miden lo mismo, aunque en escalas distintas.

Ejercicio con datos reales

Considere el conjunto de datos `Default`, que registra para 10 000 clientes de una entidad financiera si incumplieron el pago de su tarjeta de crédito. Está disponible en `ISLR2` (R) y en `ISLP` (Python).

Table 1: Información en análisis: Default

default	student	balance	income
No	No	729.53	44361.63
No	Yes	817.18	12106.13
No	No	1073.55	31767.14
No	No	529.25	35704.49
No	No	785.66	38463.50

La respuesta es *default* (si el cliente incumplió). Las covariables son *student* (codifíquela como 0/1), *balance* (saldo promedio de la tarjeta) e *income* (ingreso anual). La predicción del modelo es la **probabilidad estimada de incumplimiento**. **Dé respuesta a los siguientes planteamientos:**

1. Divida el conjunto en entrenamiento (70%) y prueba (30%), **fijando la semilla**. Ajuste un bosque aleatorio de clasificación con $B = 500$ árboles y tamaño mínimo de nodo 20, y compare su tasa de error de prueba con la de una regresión logística.

2. Tome como x_0 al cliente de prueba con probabilidad estimada **más cercana a** 0.5. **Sin usar librerías de interpretación**, obtenga $v(\mathcal{C})$ para las 8 coaliciones, usando el entrenamiento como referencia, y calcule los valores de Shapley como en el punto 1. Verifique la eficiencia.

3. Obtenga los valores SHAP de x_0 con una librería (`shap` en Python o `kernelshap` en R), compárelos con el punto anterior y preséntelos en un **gráfico de cascada**. **Interprete.**

4. Implemente LIME para x_0 con $M = 3000$ perturbaciones y anchos de núcleo $0.25\sqrt{p}$, $0.75\sqrt{p}$ y $3\sqrt{p}$. Repita con 10 semillas distintas y **comente** la estabilidad del coeficiente de *balance*.

5. Con la curva ICE de *balance* para x_0, encuentre el saldo a partir del cual la probabilidad estimada baja de 0.5. **Discuta** si este contrafactual es plausible y accionable para el cliente.

6. Obtenga los valores SHAP para 500 clientes de prueba y construya el gráfico de resumen y el de dependencia de *balance* coloreado por *student*. Compare la media de $|\phi_j|$ con la importancia por permutación del bosque y **explique** las diferencias.