

Repaso Primer Parcial — Estadística II

Motivación de estudio

El análisis de regresión es una de las herramientas fundamentales de la estadística: permite realizar tanto **inferencia** como **predicción** sobre un fenómeno dentro del rango experimental observado. Aunque el modelo de regresión lineal simple es quizás el modelo estadístico más elemental, su generalización, el **modelo lineal**, constituye la base de muchos de los métodos más poderosos que existen en estadística y *Machine Learning*. Comprender bien la regresión múltiple no solo es esencial para el análisis de datos a nivel básico, sino que abre la puerta a métodos intermedios y avanzados que comparten la misma estructura algebraica.

Con esto como motivación, el presente notebook busca servir como **material de repaso** tras la interrupción académica del semestre 2026-1 en la Universidad Nacional de Colombia. Se recomienda acompañar este repaso con el archivo `.ipynb` disponible en el GitHub del curso, donde se presentan casos complementarios del uso de modelos lineales implementados en Python. **El contenido de ese archivo no hace parte de la evaluación del curso**, pero sí ofrece perspectiva sobre la conexión entre regresión y modelos más avanzados, que pueden resultar interesantes.

1. Regresión lineal simple: recordatorio

Se utilizará el caso de la regresión lineal simple como manera de ilustrar conceptos básicos del análisis de regresión, recuerde que la regresión lineal simple es un caso especial de la regresión lineal múltiple. Suponga que se cuenta con una variable de interés y (puede ser de naturaleza ecológica, demográfica, económica, etc.) y una variable adicional x que está correlacionada con ella. De manera formal, a x la llamaremos **variable predictora** o **covariable**. Podemos modelar la relación entre ambas de la siguiente forma:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n$$

donde:

- β_0 es el **intercepto**: el valor esperado de y cuando $x = 0$.
- β_1 es la **pendiente**: el cambio esperado en y por cada unidad de cambio en x . Este es el parámetro de interés principal.
- ε_i son los **errores** del modelo, asociados a la variabilidad no explicada por la relación lineal. Estos errores no son directamente observables.

Se asume típicamente que $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$.

Nuestro objetivo es **estimar** los parámetros desconocidos β_0 y β_1 a partir de los datos observados $(x_1, y_1), \dots, (x_n, y_n)$. Los dos métodos de estimación más conocidos son el de **Mínimos Cuadrados Ordinarios (MCO)** y el de **Máxima Verosimilitud (MV)**.

1.1 Estimación por Mínimos Cuadrados Ordinarios (MCO)

El método de mínimos cuadrados ordinarios es un método geométrico que, intuitivamente, busca minimizar la distancia entre una función ajustada y los datos observados. La idea de MCO es encontrar los valores de β_0 y β_1 que **minimizan la suma de los errores al cuadrado**:

$$S(\beta_0, \beta_1) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Derivando S con respecto a β_0 y β_1 e igualando a cero, se obtienen las **ecuaciones normales**:

$$\frac{\partial S}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

Resolviendo este sistema, los estimadores MCO son:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

donde $\bar{x} = \frac{1}{n} \sum x_i$, $\bar{y} = \frac{1}{n} \sum y_i$, $S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$ y $S_{xx} = \sum (x_i - \bar{x})^2$.

Nota: Estos estimadores no requieren el supuesto de normalidad, solo que el modelo sea lineal y los errores tengan media cero y varianza constante.

Ejemplo numérico: MCO a mano Suponga que se tienen $n = 5$ observaciones sobre las horas de estudio (x) y la calificación obtenida (y):

i	x_i	y_i
1	1	2.5
2	2	3.8
3	3	5.2
4	4	6.1
5	5	8.4

Calculamos las cantidades necesarias:

$$\bar{x} = \frac{1 + 2 + 3 + 4 + 5}{5} = 3, \quad \bar{y} = \frac{2.5 + 3.8 + 5.2 + 6.1 + 8.4}{5} = 5.2$$

$$S_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y}) = (-2)(-2.7) + (-1)(-1.4) + (0)(0) + (1)(0.9) + (2)(3.2) = 5.4 + 1.4 + 0 + 0.9 + 6.4 = 14.1$$

$$S_{xx} = \sum (x_i - \bar{x})^2 = 4 + 1 + 0 + 1 + 4 = 10$$

Entonces:

$$\hat{\beta}_1 = \frac{S_{xy}}{S_{xx}} = \frac{14.1}{10} = 1.41$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 5.2 - 1.41 \times 3 = 0.97$$

El modelo ajustado es: $\hat{y} = 0.97 + 1.41x$. Es decir, **por cada hora adicional de estudio, la calificación aumenta en promedio 1.41 puntos.**

Verifiquemos en R:

```
x <- c(1, 2, 3, 4, 5)
y <- c(2.5, 3.8, 5.2, 6.1, 8.4)
modelo_simple <- lm(y ~ x)
summary(modelo_simple)

##
## Call:
## lm(formula = y ~ x)
##
## Residuals:
##      1      2      3      4      5
## 1.200e-01 1.000e-02 4.443e-16 -5.100e-01 3.800e-01
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   0.9700     0.3920   2.475  0.08969 .
## x             1.4100     0.1182  11.931  0.00127 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3737 on 3 degrees of freedom
## Multiple R-squared:  0.9794, Adjusted R-squared:  0.9725
## F-statistic: 142.3 on 1 and 3 DF,  p-value: 0.001266

par(mar = c(5, 4.5, 3, 1))
plot(x, y, pch = 19, col = "steelblue", cex = 1.8,
     xlab = "Horas de estudio", ylab = "Calificación",
     main = "Regresión lineal simple: Horas vs Calificación",
     las = 1, bty = "l")

# Línea ajustada
abline(modelo_simple, col = "tomato", lwd = 2.5)

# Segmentos de residuos (para visualizar lo que minimiza MCO)
y_hat <- fitted(modelo_simple)
segments(x, y, x, y_hat, col = rgb(0.5, 0.5, 0.5, 0.5), lty = 2, lwd = 1.2)


# Re-dibujar puntos encima de los segmentos
points(x, y, pch = 19, col = "steelblue", cex = 1.8)

# Ecuación del modelo
coefs_s <- round(coef(modelo_simple), 2)
text(1.2, max(y) - 0.2,
     bquote(hat(y) == .(coefs_s[1]) + .(coefs_s[2]) * x),
     cex = 0.95, adj = 0, col = "gray20")

legend("bottomright",
     legend = c("Datos observados", "Recta ajustada (MCO)", "Residuos"),
```

```
col = c("steelblue", "tomato", "gray50"),
pch = c(19, NA, NA),
lty = c(NA, 1, 2),
lwd = c(NA, 2.5, 1.2),
pt.cex = c(1.8, NA, NA),
bty = "n", cex = 0.85)
```

Regresión lineal simple: Horas vs Calificación



1.2 Estimación por Máxima Verosimilitud (MV)

El método de verosimilitud lo que busca es maximizar la función de verosimilitud, de tal manera que el parámetro que obtenemos sea el que nos da una mayor probabilidad de que nuestro modelo propuesto haya generado esos datos. Bajo el supuesto de normalidad $\varepsilon_i \sim N(0, \sigma^2)$, cada observación tiene distribución:

$$y_i | x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$$

La **función de verosimilitud** para la muestra completa es:

$$L(\beta_0, \beta_1, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \beta_0 - \beta_1 x_i)^2}{2\sigma^2}\right)$$

Tomando el logaritmo natural (la **log-verosimilitud**):

$$\ell(\beta_0, \beta_1, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Maximizar ℓ con respecto a β_0 y β_1 equivale a **minimizar** $\sum (y_i - \beta_0 - \beta_1 x_i)^2$, que es exactamente el criterio de MCO. Por lo tanto:

$$\boxed{\hat{\beta}_1^{MV} = \hat{\beta}_1^{MCO} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}_0^{MV} = \hat{\beta}_0^{MCO} = \bar{y} - \hat{\beta}_1 \bar{x}}$$

Es decir, **bajo normalidad, los estimadores de MV y MCO para los coeficientes de regresión coinciden.**

La diferencia aparece en la estimación de la varianza. Derivando ℓ respecto a σ^2 :

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = 0$$

Se obtiene el estimador MV de la varianza:

$$\boxed{\hat{\sigma}_{MV}^2 = \frac{1}{n} \sum_{i=1}^n \hat{\varepsilon}_i^2 = \frac{SCE}{n}}$$

donde $\hat{\varepsilon}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$ son los **residuales** y $SCE = \sum \hat{\varepsilon}_i^2$ es la suma de cuadrados del error.

$$\hat{\sigma}_{MCO}^2 = \frac{SCE}{n-2} = MSE$$

Este es un estimador **insesgado** de σ^2 , mientras que $\hat{\sigma}_{MV}^2$ es sesgado. Tenga en cuenta que para el caso de regresión lineal múltiple el denominador deja de ser $n-2$ y pasa a ser $n-p$ como se verá más adelante.

2. Regresión lineal múltiple: generalizando lo anterior

Ahora podemos generalizar todo lo anterior al caso donde no tenemos solo una variable predictora, sino que podemos tener todas las que queramos (o tengamos acceso). Para generalizar lo anterior, es útil representarlo de forma matricial, por lo que escribimos el modelo de regresión lineal múltiple de la siguiente manera:

$$\mathbf{Y} = \mathbf{X}\beta +$$

Donde las dimensiones de cada una de las variables son:

$$\mathbf{Y} \in \mathcal{R}^{(n \times 1)}$$

$$\mathbf{X} \in \mathcal{R}^{(n \times p)}$$

$$\beta \in \mathcal{R}^{(p \times 1)}$$

$$\epsilon \in \mathcal{R}^{(n \times 1)}$$

Sin embargo, debido a que los β son desconocidos, pasaremos a estimarlos mediante la siguiente expresión, la cual se encuentra demostrada en la solución del taller 1. Este estimador es además un estimador insesgado.

$$\hat{\beta} = (X^t X)^{-1} X^t y$$

Ejemplo numérico: estimación matricial Retomemos el ejemplo anterior (horas de estudio vs calificación) y veamos cómo se obtiene $\hat{\beta}$ de forma matricial. La matriz de diseño $\mathbf{X}$ incluye una columna de unos para el intercepto:

$$\mathbf{X} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad \mathbf{Y} = \begin{pmatrix} 2.5 \\ 3.8 \\ 5.2 \\ 6.1 \\ 8.4 \end{pmatrix}$$

Calculamos paso a paso:

$$X^t X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$$

$$X^t Y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} \begin{pmatrix} 2.5 \\ 3.8 \\ 5.2 \\ 6.1 \\ 8.4 \end{pmatrix} = \begin{pmatrix} 26.0 \\ 92.1 \end{pmatrix}$$

$$(X^t X)^{-1} = \frac{1}{5 \cdot 55 - 15 \cdot 15} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \frac{1}{50} \begin{pmatrix} 55 & -15 \\ -15 & 5 \end{pmatrix} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix}$$

$$\hat{\beta} = (X^t X)^{-1} X^t Y = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix} \begin{pmatrix} 26.0 \\ 92.1 \end{pmatrix} = \begin{pmatrix} 0.97 \\ 1.41 \end{pmatrix}$$

Obtenemos los mismos valores: $\hat{\beta}_0 = 0.97$ y $\hat{\beta}_1 = 1.41$. Verifiquemos en R:

```
X <- cbind(1, c(1,2,3,4,5))
Y <- c(2.5, 3.8, 5.2, 6.1, 8.4)

# Estimación matricial explícita
beta_hat <- solve(t(X) %*% X) %*% t(X) %*% Y
beta_hat
```

```
##      [,1]
## [1,] 0.97
## [2,] 1.41
```

Ahora, pasemos a un ejemplo con **múltiples predictoras** usando el dataset `mtcars` de R. Modelaremos el rendimiento de combustible (`mpg`) en función del peso (`wt`) y la potencia (`hp`):

```
# Ajuste del modelo de regresión múltiple
modelo_mult <- lm(mpg ~ wt + hp, data = mtcars)
summary(modelo_mult)
```

```
##
## Call:
## lm(formula = mpg ~ wt + hp, data = mtcars)
##
## Residuals:
```

```
##      Min      1Q Median      3Q      Max
## -3.941 -1.600 -0.182  1.050  5.854
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 37.22727    1.59879   23.285 < 2e-16 ***
## wt          -3.87783    0.63273   -6.129 1.12e-06 ***
## hp          -0.03177    0.00903   -3.519 0.00145 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.593 on 29 degrees of freedom
## Multiple R-squared:  0.8268, Adjusted R-squared:  0.8148
## F-statistic: 69.21 on 2 and 29 DF,  p-value: 9.109e-12
```

Interpretación de los coeficientes:

- $\hat{\beta}_0 \approx 37.23$: el rendimiento esperado cuando $wt = 0$ y $hp = 0$ (no interpretable en la práctica, pues un auto con peso y potencia cero no existe).
- $\hat{\beta}_{wt} \approx -3.88$: **manteniendo la potencia constante**, por cada 1000 libras adicionales de peso, el rendimiento disminuye en promedio 3.88 millas por galón.
- $\hat{\beta}_{hp} \approx -0.03$: **manteniendo el peso constante**, por cada caballo de fuerza adicional, el rendimiento disminuye en promedio 0.03 millas por galón.

Verifiquemos la estimación matricial para este modelo:

```
X_mt <- model.matrix(~ wt + hp, data = mtcars) # Matriz de diseño
Y_mt <- mtcars$mpg

# Estimación matricial
beta_mt <- solve(t(X_mt) %*% X_mt) %*% t(X_mt) %*% Y_mt
beta_mt
```

```
##              [,1]
## (Intercept) 37.22727012
## wt          -3.87783074
## hp          -0.03177295
```

La matriz de varianzas y covarianzas de este estimador esta dada por:

$$\text{var}(\hat{\beta}) = \sigma^2(X^t X)^{-1}$$

En la diagonal principal se encuentran las varianzas de los estimadores $\text{Var}(\hat{\beta}_j) = \hat{\sigma}^2 c_{jj}$, donde c_{jj} es el j -ésimo elemento de la diagonal de la matriz $(X^t X)^{-1}$.

```
# Matriz (X'X)^{-1}
XtX_inv <- solve(t(X_mt) %*% X_mt)

# Estimación de sigma^2 (MSE)
e <- Y_mt - X_mt %*% beta_mt
n <- nrow(mtcars)
p <- ncol(X_mt)
sigma2_hat <- sum(e^2) / (n - p)

# Matriz de varianzas-covarianzas de beta_hat
var_beta <- sigma2_hat * XtX_inv
var_beta
```

```
##          (Intercept)          wt          hp
## (Intercept)  2.5561215917 -0.73594515  1.484701e-04
## wt          -0.7359451464  0.40035167 -3.763690e-03
## hp          0.0001484701 -0.00376369  8.153566e-05
```

```
# Los errores estándar son la raíz de la diagonal
sqrt(diag(var_beta))
```

```
## (Intercept)          wt          hp
##  1.59878754  0.63273349  0.00902971
```

Compare estos errores estándar con los que aparecen en la columna Std. Error del `summary(modelo_mult)`.

$$\text{Var}(\beta) = \begin{pmatrix} \text{Var}(\beta_0) & \text{Cov}(\beta_0, \beta_1) & \cdots & \text{Cov}(\beta_0, \beta_k) \\ \text{Cov}(\beta_1, \beta_0) & \text{Var}(\beta_1) & \cdots & \text{Cov}(\beta_1, \beta_k) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(\beta_k, \beta_0) & \text{Cov}(\beta_k, \beta_1) & \cdots & \text{Var}(\beta_k) \end{pmatrix}$$

Debido a que los $\hat{\beta}$ son una combinación lineal de las observaciones, se tiene la siguiente distribución:

$$\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2(X^\top X)^{-1})$$

Y para cada uno de los β_j :

$$\hat{\beta}_j \sim \mathcal{N}(\beta_j, \sigma^2 c_{jj}), \quad j = 0, 1, \dots, k.$$

Al estimar los β , nuestro modelo de regresión lineal múltiple queda escrito de la siguiente manera:

$$\hat{\mathbf{Y}} = \mathbf{X}\hat{\beta}$$

Bajo lo anterior, establecemos la respuesta media de la siguiente manera:

$$E(Y | X_1, X_2, \dots, X_k) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k$$

Bajo los supuestos de normalidad, independencia y varianza constante de los errores, se tiene que:

$$Y_i | X_{i1}, \dots, X_{ik} \stackrel{\text{ind}}{\sim} N(\beta_0 + \beta_1 X_{i1} + \cdots + \beta_k X_{ik}, \sigma^2), \quad i = 1, 2, \dots, n$$

Una de las ventajas del modelo de regresión lineal, es que es altamente interpretable, de manera general, la interpretación de los parámetros se da de la siguiente manera:

- Para β_0 : Es solo interpretable si en los datos se encuentra la coordenada $(X_1, X_2, \dots, X_k) = (0, 0, \dots, 0)$
- Para β_j : Indican el cambio en la respuesta media (promedio) de Y por unidad de incremento en la respectiva variable X_j al mantener las demás predictoras constantes

Ya que tenemos entonces una expresión para estimar los betas, observe lo siguiente

$$\hat{y} = X\hat{\beta} = X(X^\top X)^{-1}X^\top y = Hy$$

H recibe el nombre de la matriz hat, y es aquella que proyecta el vector de observaciones y , en el plano ajustado, es decir, es una transformación lineal sobre las filas de X . Esta matriz H es simétrica e idempotente (ver demostración en el taller 2)

Con el modelo de regresión lineal ajustado, podemos cuantificar cuanto nos equivocamos entre lo que observamos y lo que ajustamos, esa cantidad recibirá el nombre de residuos, la estimación de los errores, los cuales se calculan de la siguiente manera:

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{X}\hat{\beta}$$

Podemos expresar los errores en términos de la matriz H de la siguiente manera

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - H\mathbf{y} = (I - H)\mathbf{y}$$

ANOVA: Análisis de varianza

Al plantear un modelo de regresión lineal, es interesante ver si al menos alguna de las predictoras si aporta a explicar la variable respuesta, o ninguna es estadísticamente diferente de 0, por lo cual se plantea el test lineal general, bajo el siguiente juego de hipótesis:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0 \quad H_a : \text{Al menos algún de los } \beta_j \neq 0, j = 1, 2, \dots, k$$

Para probar la hipótesis anterior utilizamos el análisis de varianza (ANOVA), para lo cual vamos a descomponer las sumas de cuadrados del modelo ajustado

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{SS_{Total}} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{SS_{Regresin}} + \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2}_{SS_{Error}}$$

$$SS_{Total} = SS_{Regresin} + SS_{Error}$$

- SST: Mide la dispersión total de los datos.
- SSR: Mide cuánto de la variación total es explicada por la recta de regresión.
- SSE: Mide la discrepancia entre los datos observados y las predicciones del modelo (el residuo).

Cada suma de cuadrados tiene asociados unos **grados de libertad** (g.l.):

Fuente	Suma de Cuadrados	g.l.	Cuadrado Medio	F_0
Regresión	SSR	k	$MSR = \frac{SSR}{k}$	$F_0 = \frac{MSR}{MSE}$
Error	SSE	$n - p$	$MSE = \frac{SSE}{n - p}$	
Total	SST	$n - 1$		

donde $p = k + 1$ (número de parámetros incluyendo el intercepto). La identidad de grados de libertad es: $(n - 1) = k + (n - p)$.

El **estadístico de prueba** para el test de significancia general es:

$$F_0 = \frac{MSR}{MSE} = \frac{SSR/k}{SSE/(n - p)}$$

Bajo H_0 , este estadístico sigue una distribución $F_{k, n-p}$. Se rechaza H_0 si $F_0 > f_{1-\alpha; k, n-p}$, o equivalentemente si el valor- p asociado es menor que α .

Ejemplo: tabla ANOVA con mtcars Retomemos el modelo $\text{mpg} \sim \text{wt} + \text{hp}$:

```
anova(modelo_mult)
```

```
## Analysis of Variance Table
##
## Response: mpg
##           Df Sum Sq Mean Sq F value    Pr(>F)
## wt         1  847.73   847.73  126.041 4.488e-12 ***
## hp         1   83.27    83.27   12.381  0.001451 **
## Residuals 29  195.05     6.73
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Calculemos el estadístico F_0 manualmente a partir de las sumas de cuadrados:

```
Y_m <- mtcars$mpg
y_hat <- fitted(modelo_mult)
y_bar <- mean(Y_m)
```

```
SST <- sum((Y_m - y_bar)^2)
SSR <- sum((y_hat - y_bar)^2)
SSE <- sum((Y_m - y_hat)^2)
```

```
cat("SST =", round(SST, 2), "\n")
```

```
## SST = 1126.05
```

```
cat("SSR =", round(SSR, 2), "\n")
```

```
## SSR = 931
```

```
cat("SSE =", round(SSE, 2), "\n")
```

```
## SSE = 195.05
```

```
cat("SST = SSR + SSE?", round(SST, 2) == round(SSR + SSE, 2), "\n\n")
```

```
## SST = SSR + SSE? TRUE
```

```
k <- 2          # número de predictoras (wt, hp)
n <- nrow(mtcars)
p <- k + 1      # parámetros totales (intercepto + wt + hp)
```

```
MSR <- SSR / k
MSE <- SSE / (n - p)
```

```
F0 <- MSR / MSE
valor_p <- 1 - pf(F0, df1 = k, df2 = n - p)
```

```
cat("MSR =", round(MSR, 2), "\n")
```

```
## MSR = 465.5
```

```
cat("MSE =", round(MSE, 2), "\n")
```

```
## MSE = 6.73
```

```
cat("F0 =", round(F0, 2), "\n")
```

```
## F0 = 69.21
```

```
cat("valor-p =", format.pval(valor_p), "\n")

## valor-p = 9.109e-12

Compare este resultado con el que aparece al final del summary(modelo_mult):

summary(modelo_mult)

##
## Call:
## lm(formula = mpg ~ wt + hp, data = mtcars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.941  -1.600  -0.182   1.050   5.854
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  37.22727    1.59879   23.285  < 2e-16 ***
## wt          -3.87783    0.63273   -6.129  1.12e-06 ***
## hp           -0.03177    0.00903   -3.519  0.00145 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.593 on 29 degrees of freedom
## Multiple R-squared:  0.8268, Adjusted R-squared:  0.8148
## F-statistic: 69.21 on 2 and 29 DF,  p-value: 9.109e-12
```

Prueba de significancia individual

Una vez evaluada la significancia general del modelo, es de interés evaluar cuáles de las variables predictoras contribuyen de manera individual. Para realizar inferencia sobre los β planeamos la siguiente prueba de hipótesis.

$$H_0 : \beta_j = 0 \quad H_a : \beta_j \neq 0$$

Es decir, se evalúa si la variable X_j tiene un efecto estadísticamente significativo sobre Y , controlando por las demás variables. Dicha prueba de hipótesis se evalúa mediante el siguiente estadístico de prueba:

$$T_0 = \frac{\hat{\beta}_j}{se(\hat{\beta}_j)} = \frac{\hat{\beta}_j}{\sqrt{\hat{\sigma}^2 c_{jj}}}$$

Bajo H_0 , este estadístico sigue una distribución t_{n-p} . Se rechaza H_0 si $|T_0| > t_{\alpha/2, n-p}$.

Nota: De manera más general, si se quiere contrastar $H_0 : \beta_j = \beta_j^0$ (un valor específico distinto de cero), el estadístico es:

$$T_0 = \frac{\hat{\beta}_j - \beta_j^0}{se(\hat{\beta}_j)}$$

Ejemplo: prueba t individual con mtcars Retomemos el modelo $\text{mpg} \sim \text{wt} + \text{hp}$. Queremos evaluar si el peso (wt) tiene un efecto significativo sobre el rendimiento, controlando por la potencia. Es decir:

$$H_0 : \beta_{\text{wt}} = 0 \quad \text{vs} \quad H_a : \beta_{\text{wt}} \neq 0$$

```
# Extraemos lo necesario del modelo ajustado anteriormente
coefs <- summary(modelo_mult)$coefficients
coefs

##              Estimate Std. Error  t value    Pr(>|t|)
## (Intercept) 37.22727012 1.59878754 23.284689 2.565459e-20
## wt          -3.87783074 0.63273349 -6.128695 1.119647e-06
## hp          -0.03177295 0.00902971 -3.518712 1.451229e-03
```

Verifiquemos el cálculo del estadístico T_0 manualmente:

```
beta_wt <- coefs["wt", "Estimate"]
se_wt    <- coefs["wt", "Std. Error"]

T0 <- beta_wt / se_wt
T0
```

```
## [1] -6.128695
```

```
# Valor crítico al 5% con n - p grados de libertad
n <- nrow(mtcars)
p <- 3 # intercepto + wt + hp
alpha <- 0.05
t_critico <- qt(1 - alpha/2, df = n - p)
t_critico
```

```
## [1] 2.04523
```

```
# ¿Rechazamos H0?
abs(T0) > t_critico
```

```
## [1] TRUE
```

Como $|T_0| \approx 5.95 > t_{0.025, 29} \approx 2.045$, rechazamos H_0 : hay evidencia estadística de que el peso del auto tiene un efecto significativo sobre el rendimiento, aun controlando por la potencia. Observe que este valor coincide con el que aparece en la columna **t value** del `summary()`.

Coeficiente de determinación R^2

El coeficiente de determinación mide la **proporción de la variabilidad total de Y que es explicada por el modelo de regresión**:

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

donde $0 \leq R^2 \leq 1$. Un valor cercano a 1 indica que el modelo explica una gran proporción de la variabilidad observada.

Sin embargo, el R^2 tiene un problema: **nunca disminuye al agregar más variables** al modelo, incluso si estas no son relevantes. Por esta razón se define el R^2 **ajustado**, que penaliza la inclusión de variables innecesarias:

$$R_{adj}^2 = 1 - \frac{SSE/(n-p)}{SST/(n-1)} = 1 - \frac{MSE}{MST}$$

A diferencia del R^2 , el R_{adj}^2 **puede disminuir** si se agrega una variable que no mejora el ajuste del modelo lo suficiente como para compensar la pérdida de un grado de libertad.

```
# R^2 manual
R2 <- SSR / SST
cat("R^2 =", round(R2, 4), "\n")
```

Ejemplo: R^2 y R_{adj}^2 con mtcars

```
## R^2 = 0.8268
```

```
# R^2 ajustado manual
R2_adj <- 1 - (SSE / (n - p)) / (SST / (n - 1))
cat("R^2 ajustado =", round(R2_adj, 4), "\n")
```

```
## R^2 ajustado = 0.8148
```

Estos valores coinciden con los reportados en `summary(modelo_mult)`.

Ahora, veamos qué pasa si agregamos una variable que **no aporta información** al modelo. Agreguemos `am` (transmisión manual o automática):

```
modelo_ext <- lm(mpg ~ wt + hp + am, data = mtcars)
```

```
cat("Modelo original (wt + hp):\n")
```

```
## Modelo original (wt + hp):
```

```
cat("  R^2      =", round(summary(modelo_mult)$r.squared, 4), "\n")
```

```
##    R^2      = 0.8268
```

```
cat("  R^2 adj =", round(summary(modelo_mult)$adj.r.squared, 4), "\n\n")
```

```
##    R^2 adj = 0.8148
```

```
cat("Modelo extendido (wt + hp + am):\n")
```

```
## Modelo extendido (wt + hp + am):
```

```
cat("  R^2      =", round(summary(modelo_ext)$r.squared, 4), "\n")
```

```
##    R^2      = 0.8399
```

```
cat("  R^2 adj =", round(summary(modelo_ext)$adj.r.squared, 4), "\n")
```

```
##    R^2 adj = 0.8227
```

Observe que el R_{adj}^2 puede disminuir si la variable agregada no compensa la pérdida de un grado de libertad. Este es el motivo por el cual el R_{adj}^2 es preferible para **comparar modelos** con distinto número de predictoras.

Sumas de cuadrados extra

También puede que el interés no radique en evaluar la significancia general del modelo de regresión, sino de un subconjunto de parámetros. Una **suma de cuadrados extra** (SS_{extra}) mide la reducción marginal en SSE (o equivalentemente el incremento marginal en SSR) producida por uno o varios coeficientes de regresión, dado que los otros coeficientes ya están presentes en el modelo.

Para entender cómo es que esa suma de cuadrados extra nos permite cuantificar cuánto mejora el modelo, hay que entender que el SST de un modelo no cambia según qué variable se agregue o se quite, siempre será el mismo; sin embargo, lo que aportan el SSR y el SSE para el mismo sí varía.

Para definir una SS_{extra} se necesitan dos subconjuntos:

- A : el subconjunto de coeficientes de regresión del que se quiere obtener la SS_{extra} .
- B : el subconjunto de coeficientes de regresión que acompañan a A en el modelo.

Se debe cumplir que $A \cup B$ esté incluido en el conjunto de todos los coeficientes de regresión del modelo, y que $A \cap B = \emptyset$.

La suma de cuadrados extra del subconjunto A dado B se denota y calcula como:

$$SSR(A | B) = SSR(A \cup B) - SSR(B) = SSE(B) - SSE(A \cup B)$$

Es decir, se compara un **modelo completo** (que incluye $A \cup B$) contra un **modelo reducido** (que solo incluye B).

Ejemplos de notación Suponga el modelo $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$. Algunas sumas de cuadrados extra son:

1. La contribución de β_1 dado que $\beta_0, \beta_2, \beta_3$ ya están en el modelo:

$$SSR(\beta_1 | \beta_0, \beta_2, \beta_3) = SSR(\beta_0, \beta_1, \beta_2, \beta_3) - SSR(\beta_0, \beta_2, \beta_3) = SSE(\beta_0, \beta_2, \beta_3) - SSE(\beta_0, \beta_1, \beta_2, \beta_3)$$

2. La contribución conjunta de β_1 y β_2 dado que β_0, β_3 ya están:

$$SSR(\beta_1, \beta_2 | \beta_0, \beta_3) = SSR(\beta_0, \beta_1, \beta_2, \beta_3) - SSR(\beta_0, \beta_3) = SSE(\beta_0, \beta_3) - SSE(\beta_0, \beta_1, \beta_2, \beta_3)$$

3. La contribución de β_1 dado que solo β_0, β_3 están:

$$SSR(\beta_1 | \beta_0, \beta_3) = SSR(\beta_0, \beta_1, \beta_3) - SSR(\beta_0, \beta_3) = SSE(\beta_0, \beta_3) - SSE(\beta_0, \beta_1, \beta_3)$$

Prueba de significancia de un subconjunto de coeficientes

Si se desea probar si un subconjunto A de coeficientes es significativo dado que B ya está en el modelo:

$$H_0 : \beta_j = 0 \quad \forall \beta_j \in A \quad \text{vs.} \quad H_a : \text{algún } \beta_j \neq 0, \beta_j \in A$$

Los **grados de libertad** de la SS_{extra} son iguales al tamaño del subconjunto A , es decir, al número de coeficientes que se están probando. Equivalentemente:

$$g.l. (SSR(A | B)) = g.l. (SSR(A \cup B)) - g.l. (SSR(B)) = g.l. (SSE(B)) - g.l. (SSE(A \cup B))$$

El **cuadrado medio extra** es:

$$MSR(A | B) = \frac{SSR(A | B)}{|A|}$$

donde $|A|$ es el número de coeficientes en A . El **estadístico de prueba** es:

$$F_0 = \frac{MSR(A | B)}{MSE_{\text{completo}}} = \frac{SSR(A | B)/|A|}{MSE_{\text{completo}}}$$

donde MSE_{completo} es **siempre** el cuadrado medio del error del modelo completo ($A \cup B$). Bajo H_0 :

$$F_0 \sim F_{|A|, n-p_{\text{completo}}}$$

Se rechaza H_0 si $F_0 > f_{1-\alpha; |A|, n-p_{\text{completo}}}$.

Ejemplo concreto de notación En el modelo $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \beta_5 X_5 + \varepsilon$, para probar:

$$H_0 : \beta_1 = \beta_2 = \beta_5 = 0 \quad \text{vs.} \quad H_a : \text{algún } \beta_j \neq 0, j = 1, 2, 5$$

Aquí $A = \{\beta_1, \beta_2, \beta_5\}$ y $B = \{\beta_0, \beta_3, \beta_4\}$. El estadístico es:

$$F_0 = \frac{SSR(\beta_1, \beta_2, \beta_5 | \beta_0, \beta_3, \beta_4)/3}{MSE_{\text{completo}}} \sim F_{3, n-6}$$

Se rechaza H_0 si $F_0 > f_{1-\alpha; 3, n-6}$.

Caso particular: prueba individual vía SS_{extra}

Cuando $A = \{\beta_j\}$ (un solo coeficiente), la prueba se reduce a:

$$H_0 : \beta_j = 0 \quad \text{vs.} \quad H_a : \beta_j \neq 0$$

$$F_{j,0} = \frac{SSR(\beta_j | \beta_0, \beta_1, \dots, \beta_{j-1}, \beta_{j+1}, \dots, \beta_k)}{MSE}$$

Dado que la SS_{extra} tiene un solo grado de libertad, $F_{j,0} \sim F_{1, n-p}$ bajo H_0 . Esta prueba es **equivalente a la prueba t individual**:

$$F_{j,0} = T_{j,0}^2$$

y los valores- p de ambas pruebas coinciden:

$$P(F_{1, n-p} > F_{j,0}) = P(|t_{n-p}| > |T_{j,0}|)$$

Además, la prueba de significancia general de la regresión (ANOVA) es un caso particular de la prueba de SS_{extra} donde $A = \{\beta_1, \beta_2, \dots, \beta_k\}$ y $B = \{\beta_0\}$.

Ejemplo en R: sumas de cuadrados extra con mtcars Usamos el modelo completo $\text{mpg} \sim \text{wt} + \text{hp} + \text{am} + \text{qsec}$ para ilustrar la prueba de un subconjunto de coeficientes. Probaremos si β_{am} y β_{qsec} son significativos de manera conjunta, dado que wt y hp ya están en el modelo:

$$H_0 : \beta_{\text{am}} = \beta_{\text{qsec}} = 0 \quad \text{vs.} \quad H_a : \text{algún } \beta_j \neq 0$$

```
# Modelo completo (A B)
completo <- lm(mpg ~ wt + hp + am + qsec, data = mtcars)

# Modelo reducido (solo B)
reducido <- lm(mpg ~ wt + hp, data = mtcars)

# SSE de ambos modelos
SSE_completo <- sum(residuals(completo)^2)
SSE_reducido <- sum(residuals(reducido)^2)

# Suma de cuadrados extra
SS_extra <- SSE_reducido - SSE_completo

# Grados de libertad
A_size <- 2 # probamos am y qsec
n <- nrow(mtcars)
p_completo <- length(coef(completo)) # 5

# Estadístico F
MSE_completo <- SSE_completo / (n - p_completo)
F0 <- (SS_extra / A_size) / MSE_completo
valor_p <- 1 - pf(F0, df1 = A_size, df2 = n - p_completo)

cat("SSE modelo reducido (wt + hp):", round(SSE_reducido, 2), "\n")

## SSE modelo reducido (wt + hp): 195.05
cat("SSE modelo completo (wt + hp + am + qsec):", round(SSE_completo, 2), "\n")

## SSE modelo completo (wt + hp + am + qsec): 160.07
cat("SS_extra (am, qsec | wt, hp):", round(SS_extra, 2), "\n")

## SS_extra (am, qsec | wt, hp): 34.98
cat("F0 =", round(F0, 4), "\n")

## F0 = 2.9503
cat("valor-p =", round(valor_p, 4), "\n")

## valor-p = 0.0694
```

Podemos verificar esto directamente con la función `anova()` comparando ambos modelos:

```
anova(reducido, completo)

## Analysis of Variance Table
##
## Model 1: mpg ~ wt + hp
## Model 2: mpg ~ wt + hp + am + qsec
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
```



```
## 1      29 195.05
## 2      27 160.07  2      34.981 2.9503 0.06937 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Ahora verifiquemos la equivalencia $F_{j,0} = T_{j,0}^2$ para un coeficiente individual. Tomemos β_{wt} del modelo `mpg ~ wt + hp`:

```
# Prueba t del summary
coefs_mult <- summary(modelo_mult)$coefficients
T0_wt <- coefs_mult["wt", "t value"]

# Prueba F vía SS extra
completo_2 <- lm(mpg ~ wt + hp, data = mtcars)
reducido_2 <- lm(mpg ~ hp, data = mtcars)      # sin wt

SSE_c <- sum(residuals(completo_2)^2)
SSE_r <- sum(residuals(reducido_2)^2)
SS_extra_wt <- SSE_r - SSE_c
MSE_c <- SSE_c / (n - length(coef(completo_2)))
F0_wt <- SS_extra_wt / MSE_c

cat("T0^2 =", round(T0_wt^2, 4), "\n")
```

```
## T0^2 = 37.5609
```

```
cat("F0  =", round(F0_wt, 4), "\n")
```

```
## F0  = 37.5609
```

```
cat("¿Son iguales?", all.equal(T0_wt^2, F0_wt), "\n")
```

```
## ¿Son iguales? TRUE
```

Prueba de la hipótesis lineal general

Todo lo anterior (prueba de significancia general, prueba de un subconjunto, prueba individual) puede unificarse bajo un mismo marco: la **prueba de hipótesis lineal general**.

Suponga un modelo de RLM completo (FM) con k variables predictoras:

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k + \varepsilon$$

con $SSR(FM)$ con $k = p - 1$ g.l. y $SSE(FM)$ con $n - p$ g.l.

Considere una matriz $\mathbf{L}$ de dimensión $m \times p$ de constantes, con $r \leq m$ filas linealmente independientes, y un vector $\mathbf{c}$ de dimensión $m \times 1$. Se formula la **hipótesis lineal general**:

$$H_0 : \mathbf{L}\beta = \mathbf{c} \quad \text{vs.} \quad H_a : \mathbf{L}\beta \neq \mathbf{c}$$

donde $\mathbf{L}\beta = \mathbf{c}$ es un sistema de m ecuaciones que se prueban simultáneamente. El caso más frecuente es $\mathbf{c} = \mathbf{0}$, pero la formulación general permite probar cualquier combinación lineal de los coeficientes contra valores arbitrarios.

Al aplicar lo establecido en H_0 al modelo completo, se llega a un **modelo reducido** (RM). Se define la **suma de cuadrados debida a la hipótesis (SSH)**:

$$\boxed{SSH = SSE(RM) - SSE(FM) = SSR(FM) - SSR(RM)}$$

con r grados de libertad (el número de filas linealmente independientes de $\mathbf{L}$):

$$r = g.l.(SSE(RM)) - g.l.(SSE(FM)) = g.l.(SSR(FM)) - g.l.(SSR(RM))$$

El **cuadrado medio debido a la hipótesis** es:

$$MSH = \frac{SSH}{r}$$

Y el **estadístico de prueba**:

$$\boxed{F_0 = \frac{MSH}{MSE} = \frac{SSH/r}{MSE} \sim F_{r, n-p}}$$

donde MSE es **siempre** el cuadrado medio del error del modelo completo. Se rechaza H_0 si $F_0 > f_{1-\alpha; r, n-p}$.

Ejemplo 1: $H_0 : \beta_1 = \beta_2, \beta_3 = \beta_4$ Suponga un modelo con $k = 4$ predictoras. Se desea probar:

$$H_0 : \beta_1 = \beta_2, \beta_3 = \beta_4 \quad \text{vs.} \quad H_a : \beta_1 \neq \beta_2 \text{ ó } \beta_3 \neq \beta_4$$

Reescribimos H_0 igualando a cero: $\beta_1 - \beta_2 = 0, \beta_3 - \beta_4 = 0$. En forma matricial:

$$H_0 : \underbrace{\begin{pmatrix} 0 & 1 & -1 & 0 & 0 \\ 0 & 0 & 0 & 1 & -1 \end{pmatrix}}_{\mathbf{L}} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$\mathbf{L}$ tiene $r = 2$ filas linealmente independientes. El **modelo reducido** se obtiene sustituyendo $\beta_1 = \beta_2$ y $\beta_3 = \beta_4$:

$$RM : Y = \beta_0 + \beta_1(X_1 + X_2) + \beta_3(X_3 + X_4) + \varepsilon = \beta_0 + \beta_1 X_{1,2} + \beta_3 X_{3,4} + \varepsilon$$

donde $X_{1,2} = X_1 + X_2$ y $X_{3,4} = X_3 + X_4$. El $SSE(RM)$ tiene $n - 3$ g.l.

$$F_0 = \frac{SSH/2}{MSE} \sim F_{2, n-5}$$

Ejemplo 2: $H_0 : \beta_1 = \beta_2 = 0, \beta_3 = \beta_4$ Con el mismo modelo de $k = 4$:

$$H_0 : \beta_1 = 0, \beta_2 = 0, \beta_3 - \beta_4 = 0$$

$$H_0 : \underbrace{\begin{pmatrix} 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & -1 \end{pmatrix}}_{\mathbf{L}} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

$\mathbf{L}$ tiene $r = 3$ filas linealmente independientes. El modelo reducido es:

$$RM : Y = \beta_0 + \beta_3(X_3 + X_4) + \varepsilon = \beta_0 + \beta_3 X_{3,4} + \varepsilon$$

$$F_0 = \frac{SSH/3}{MSE} \sim F_{3, n-5}$$

Ejemplo 3: la prueba de significancia general como caso particular La prueba ANOVA $H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4 = 0$ es un caso particular con:

$$\mathbf{L} = \begin{pmatrix} 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}, \quad \mathbf{c} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

$r = k = 4$ filas linealmente independientes. El modelo reducido es $RM : Y = \beta_0 + \varepsilon$, donde $\hat{\beta}_0 = \bar{Y}$ y por tanto $SSE(\beta_0) = SST$ y $SSR(\beta_0) = 0$. Entonces:

$$SSH = SST - SSE(FM) = SSR(FM) = SSR$$

y el estadístico coincide con el de la tabla ANOVA:

$$F_0 = \frac{SSH/k}{MSE} = \frac{SSR/k}{MSE} = \frac{MSR}{MSE} \sim F_{k, n-p}$$

Caso general: $H_0 : \mathbf{L}\beta = \mathbf{c}$ con $\mathbf{c} \neq \mathbf{0}$ Hasta ahora hemos visto el caso $\mathbf{c} = \mathbf{0}$, pero es posible probar hipótesis donde los coeficientes se comparan contra valores específicos. Por ejemplo, en el modelo $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$:

$$H_0 : \beta_1 = 3, \beta_2 = -1 \quad \text{vs.} \quad H_a : \beta_1 \neq 3 \text{ ó } \beta_2 \neq -1$$

se escribe como:

$$\underbrace{\begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}}_{\mathbf{L}} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{pmatrix} = \underbrace{\begin{pmatrix} 3 \\ -1 \end{pmatrix}}_{\mathbf{c}}$$

En este caso la SSH se puede calcular con la fórmula cerrada:

$$SSH = (\mathbf{L}\hat{\boldsymbol{\beta}} - \mathbf{c})^\top [\mathbf{L}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{L}^\top]^{-1} (\mathbf{L}\hat{\boldsymbol{\beta}} - \mathbf{c})$$

Observe que cuando $\mathbf{c} = \mathbf{0}$ esta expresión se reduce a $SSH = (\mathbf{L}\hat{\boldsymbol{\beta}})^\top [\mathbf{L}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{L}^\top]^{-1} (\mathbf{L}\hat{\boldsymbol{\beta}})$.

Revisar el taller 2, para ver como esta expresión es importante para demostrar varias de las igualdades que usamos en el curso.

Ejemplo en R: hipótesis lineal general con mtcars Veamos un ejemplo completo. Con el modelo `mpg ~ wt + hp + qsec`, probemos la hipótesis $H_0 : \beta_{wt} = \beta_{hp}, \beta_{qsec} = 0$ (es decir, que el efecto del peso y la potencia son iguales, y que `qsec` no aporta):

```
modelo_full <- lm(mpg ~ wt + hp + qsec, data = mtcars)
summary(modelo_full)

##
## Call:
## lm(formula = mpg ~ wt + hp + qsec, data = mtcars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.8591 -1.6418 -0.4636  1.1940  5.6092
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  27.61053     8.41993   3.279  0.00278 **
## wt          -4.35880     0.75270  -5.791 3.22e-06 ***
## hp           -0.01782     0.01498  -1.190  0.24418
## qsec          0.51083     0.43922   1.163  0.25463
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.578 on 28 degrees of freedom
## Multiple R-squared:  0.8348, Adjusted R-squared:  0.8171
## F-statistic: 47.15 on 3 and 28 DF,  p-value: 4.506e-11
```

Construimos la prueba manualmente:

```
# Coeficientes: (Intercept), wt, hp, qsec -> p = 4
# H0: beta_wt - beta_hp = 0, beta_qsec = 0

L <- matrix(c(0, 1, -1, 0,
              0, 0,  0, 1), nrow = 2, byrow = TRUE)
c_vec <- c(0, 0)

beta_hat_full <- coef(modelo_full)
X_full <- model.matrix(modelo_full)
XtX_inv <- solve(t(X_full) %*% X_full)

# SSH con fórmula cerrada
Lb_minus_c <- L %*% beta_hat_full - c_vec
SSH <- t(Lb_minus_c) %*% solve(L %*% XtX_inv %*% t(L)) %*% Lb_minus_c

r <- qr(L)$rank # filas linealmente independientes
```

```

n_obs <- nrow(mtcars)
p_full <- length(beta_hat_full)
MSE_full <- sum(residuals(modelo_full)^2) / (n_obs - p_full)

F0_test <- (SSH / r) / MSE_full
vp <- 1 - pf(F0_test, df1 = r, df2 = n_obs - p_full)

cat("Matriz L:\n")

```

```
## Matriz L:
```

```
print(L)
```

```
##      [,1] [,2] [,3] [,4]
## [1,]    0    1   -1    0
## [2,]    0    0    0    1

```

```
cat("\nSSH =", round(SSH, 4), "\n")
```

```
##
```

```
## SSH = 252.8573
```

```
cat("r =", r, "\n")
```

```
## r = 2
```

```
cat("F0 =", round(F0_test, 4), "\n")
```

```
## F0 = 19.0262
```

```
cat("valor-p =", round(vp, 4), "\n")
```

```
## valor-p = 0
```

Ahora probemos un caso con $\mathbf{c} \neq \mathbf{0}$. Supongamos que la teoría sugiere que $\beta_{wt} = -4$ y $\beta_{hp} = -0.03$. Queremos probar:

$$H_0 : \beta_{wt} = -4, \beta_{hp} = -0.03 \quad \text{vs.} \quad H_a : \beta_{wt} \neq -4 \text{ ó } \beta_{hp} \neq -0.03$$

```

L2 <- matrix(c(0, 1, 0, 0,
               0, 0, 1, 0), nrow = 2, byrow = TRUE)
c_vec2 <- c(-4, -0.03)

```

```

Lb_minus_c2 <- L2 %*% beta_hat_full - c_vec2
SSH2 <- t(Lb_minus_c2) %*% solve(L2 %*% XtX_inv %*% t(L2)) %*% Lb_minus_c2

```

```

r2 <- qr(L2)$rank
F0_test2 <- (SSH2 / r2) / MSE_full
vp2 <- 1 - pf(F0_test2, df1 = r2, df2 = n_obs - p_full)

```

```
cat("H0: beta_wt = -4, beta_hp = -0.03\n")
```

```
## H0: beta_wt = -4, beta_hp = -0.03
```

```
cat("SSH =", round(SSH2, 4), "\n")
```

```
## SSH = 4.7524
```

```

cat("F0 =", round(F0_test2, 4), "\n")

## F0 = 0.3576

cat("valor-p =", round(vp2, 4), "\n")

## valor-p = 0.7025

if (vp2 < 0.05) {
  cat("-> Rechazamos H0: los valores teóricos no son compatibles con los datos.\n")
} else {
  cat("-> No rechazamos H0: los datos son compatibles con los valores teóricos.\n")
}

## -> No rechazamos H0: los datos son compatibles con los valores teóricos.

Finalmente, verifiquemos que la prueba ANOVA general es un caso particular. Si  $\mathbf{L} = [\mathbf{0} \mid \mathbf{I}_k]$  y  $\mathbf{c} = \mathbf{0}$ :

# L para prueba de significancia general: probar que todos los betas (excepto intercepto) son 0
k_pred <- p_full - 1
L_anova <- cbind(rep(0, k_pred), diag(k_pred))
c_anova <- rep(0, k_pred)

Lb_anova <- L_anova %*% beta_hat_full - c_anova
SSH_anova <- t(Lb_anova) %*% solve(L_anova %*% XtX_inv %*% t(L_anova)) %*% Lb_anova

F0_anova <- (SSH_anova / k_pred) / MSE_full

cat("F0 (vía hipótesis lineal general) =", round(F0_anova, 4), "\n")

## F0 (vía hipótesis lineal general) = 47.1528

cat("F0 (vía summary del modelo)          =", round(summary(modelo_full)$fstatistic[1], 4), "\n")

## F0 (vía summary del modelo)          = 47.1528

```

Predicción de valores futuros

Suponga ahora que después de haber ajustado el modelo de regresión lineal ingresa una nueva observación $(X_1, X_2, \dots, X_k)$, este conjunto de valores se llamará x_0 . Uno entonces puede calcular tanto la esperanza de la respuesta, es decir, el promedio de todos los individuos con esos valores, o estimar la respuesta para un solo individuo con esos valores. Para ambos casos, la mejor estimación es $\hat{Y}_0 = x_0 \hat{\beta}$, sin embargo, la incertidumbre para esta no es la misma en ambos escenarios.

- Para la **esperanza de la respuesta** (intervalo de confianza), la varianza de $\hat{Y}_0$ es $Var(\hat{Y}_0) = \sigma^2 x_0 (\mathbf{X}^\top \mathbf{X})^{-1} x_0^\top$.
- Para la **predicción de un nuevo individuo** (intervalo de predicción), la varianza es $Var(Y_0 - \hat{Y}_0) = \sigma^2 (1 + x_0 (\mathbf{X}^\top \mathbf{X})^{-1} x_0^\top)$.

Por lo anterior se observa que el intervalo de predicción es siempre más amplio que el intervalo de confianza para la respuesta media, ya que incorpora la variabilidad adicional de la respuesta individual (σ^2), mientras que el intervalo de confianza solo considera la variabilidad de la estimación de la media.

Ejemplo en R: Intervalos de confianza vs. predicción Usemos el modelo de `mtcars` ajustado previamente para ilustrar ambos tipos de intervalos. Incluimos un punto dentro de la región de observación y otro que está **fuera** (extrapolación) para ver cómo se comportan los intervalos.

```

# Ajustar modelo
modelo <- lm(mpg ~ wt + hp, data = mtcars)

```

```

# Puntos dentro de la región de observación
nuevos_dentro <- data.frame(wt = c(2.5, 3.0, 3.5), hp = c(110, 150, 200))

# Punto de extrapolación: un auto extremadamente liviano y con mucha potencia
# (fuera de la región conjunta observada en los datos)
nuevo_extra <- data.frame(wt = 1.2, hp = 350)

nuevos_datos <- rbind(nuevos_dentro, nuevo_extra)
rownames(nuevos_datos) <- c(paste0("Punto ", 1:3), "Extrapolación")

# Intervalo de confianza para la respuesta media  $E[Y|x_0]$ 
ic_media <- predict(modelo, newdata = nuevos_datos, interval = "confidence", level = 0.95)

# Intervalo de predicción para un valor futuro  $Y_0$ 
ip_futuro <- predict(modelo, newdata = nuevos_datos, interval = "prediction", level = 0.95)

cat("Intervalos de confianza para la respuesta media:\n")

## Intervalos de confianza para la respuesta media:
print(round(ic_media, 3))

##           fit      lwr      upr
## Punto 1      24.038 22.867 25.209
## Punto 2      20.828 19.836 21.820
## Punto 3      17.300 16.072 18.528
## Extrapolación 21.453 15.562 27.344

cat("\nIntervalos de predicción para un valor futuro:\n")

##
## Intervalos de predicción para un valor futuro:
print(round(ip_futuro, 3))

##           fit      lwr      upr
## Punto 1      24.038 18.606 29.470
## Punto 2      20.828 15.432 26.224
## Punto 3      17.300 11.856 22.745
## Extrapolación 21.453 13.526 29.380

cat("\nAmplitud promedio IC (media):", round(mean(ic_media[, "upr"] - ic_media[, "lwr"]), 3), "\n")

##
## Amplitud promedio IC (media): 4.641
cat("Amplitud promedio IP (futuro):", round(mean(ip_futuro[, "upr"] - ip_futuro[, "lwr"]), 3), "\n")

## Amplitud promedio IP (futuro): 12.1
cat("\nNote cómo el punto de extrapolación tiene intervalos mucho más amplios,\n")

##
## Note cómo el punto de extrapolación tiene intervalos mucho más amplios,
cat("reflejando la mayor incertidumbre al predecir fuera de la región observada.\n")

## reflejando la mayor incertidumbre al predecir fuera de la región observada.

```

Visualización: IC para la media vs. IP para un valor futuro Para ver gráficamente la diferencia entre ambos intervalos, graficamos las bandas de confianza y predicción variando el peso (**wt**) mientras fijamos **hp** en su mediana.

```
# Crear secuencia de valores para wt (incluyendo zona de extrapolación)
wt_seq <- seq(min(mtcars$wt) - 0.8, max(mtcars$wt) + 0.8, length.out = 200)
datos_pred <- data.frame(wt = wt_seq, hp = median(mtcars$hp))

# Calcular ambos intervalos
ic <- predict(modelo, newdata = datos_pred, interval = "confidence", level = 0.95)
ip <- predict(modelo, newdata = datos_pred, interval = "prediction", level = 0.95)

# Identificar zona de interpolación vs extrapolación
en_rango <- wt_seq >= min(mtcars$wt) & wt_seq <= max(mtcars$wt)

par(mar = c(5, 4.5, 3, 1))
plot(mtcars$wt, mtcars$mpg, pch = 19, col = "gray30", cex = 1.2,
     xlab = "Peso (wt, miles de libras)", ylab = "Rendimiento (mpg)",
     main = "Bandas de confianza (media) vs. predicción (individuo)",
     xlim = range(wt_seq), ylim = range(ip[, c("lwr", "upr")]))

# Zona de extrapolación (fondo sombreado)
rect(min(wt_seq), par("usr")[3], min(mtcars$wt), par("usr")[4],
     col = rgb(1, 0.9, 0.8, 0.4), border = NA)
rect(max(mtcars$wt), par("usr")[3], max(wt_seq), par("usr")[4],
     col = rgb(1, 0.9, 0.8, 0.4), border = NA)

# Banda de predicción (más amplia)
polygon(c(wt_seq, rev(wt_seq)), c(ip[, "lwr"], rev(ip[, "upr"])),
       col = rgb(1, 0.4, 0.4, 0.15), border = NA)
lines(wt_seq, ip[, "lwr"], col = rgb(1, 0.3, 0.3, 0.6), lty = 2, lwd = 1.5)
lines(wt_seq, ip[, "upr"], col = rgb(1, 0.3, 0.3, 0.6), lty = 2, lwd = 1.5)

# Banda de confianza (más estrecha)
polygon(c(wt_seq, rev(wt_seq)), c(ic[, "lwr"], rev(ic[, "upr"])),
       col = rgb(0.2, 0.4, 0.8, 0.25), border = NA)
lines(wt_seq, ic[, "lwr"], col = rgb(0.2, 0.4, 0.8, 0.6), lty = 2, lwd = 1.5)
lines(wt_seq, ic[, "upr"], col = rgb(0.2, 0.4, 0.8, 0.6), lty = 2, lwd = 1.5)

# Línea ajustada
lines(wt_seq, ic[, "fit"], col = "navy", lwd = 2.5)

# Líneas verticales delimitando la región de observación
abline(v = min(mtcars$wt), col = "darkorange", lty = 3, lwd = 1.5)
abline(v = max(mtcars$wt), col = "darkorange", lty = 3, lwd = 1.5)

# Re-dibujar los puntos encima
points(mtcars$wt, mtcars$mpg, pch = 19, col = "gray30", cex = 1.2)

legend("topright",
      legend = c("Datos observados", "Línea ajustada",
                 "IC 95% (respuesta media)", "IP 95% (valor futuro)",
                 "Zona de extrapolación"),
      col = c("gray30", "navy", rgb(0.2, 0.4, 0.8, 0.6),
```




```

      rgb(1, 0.3, 0.3, 0.6), rgb(1, 0.7, 0.5, 0.6)),
pch = c(19, NA, NA, NA, 15),
lty = c(NA, 1, 2, 2, NA),
lwd = c(NA, 2.5, 1.5, 1.5, NA),
pt.cex = c(1.2, NA, NA, NA, 2),
bty = "n", cex = 0.9)

```

Bandas de confianza (media) vs. predicción (individuo)



Note cómo ambas bandas se ensanchan al alejarse del centro de los datos, y especialmente al entrar en la zona de extrapolación (sombreada en naranja). Esto refleja que **la incertidumbre crece al alejarnos de la región observada**.

Ejemplo con más de dos covariables Para reforzar la interpretación *ceteris paribus* (manteniendo todo lo demás constante), ajustemos un modelo con más predictoras. Usaremos mpg en función de wt, hp, drat (relación del eje trasero) y qsec (tiempo en el cuarto de milla).

```

modelo_multi <- lm(mpg ~ wt + hp + drat + qsec, data = mtcars)
summary(modelo_multi)

```

```

##
## Call:
## lm(formula = mpg ~ wt + hp + drat + qsec, data = mtcars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.5775 -1.6626 -0.3417  1.1317  5.4422
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)

```

```
## (Intercept) 19.25970    10.31545    1.867 0.072785 .
## wt          -3.70773     0.88227   -4.202 0.000259 ***
## hp          -0.01784     0.01476   -1.209 0.237319
## drat         1.65710     1.21697    1.362 0.184561
## qsec         0.52754     0.43285    1.219 0.233470
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.539 on 27 degrees of freedom
## Multiple R-squared:  0.8454, Adjusted R-squared:  0.8225
## F-statistic: 36.91 on 4 and 27 DF,  p-value: 1.408e-10
```

Interpretación de los coeficientes:

- $\hat{\beta}_{wt}$: por cada 1000 libras adicionales de peso, el rendimiento disminuye en promedio $|\hat{\beta}_{wt}|$ mpg, **manteniendo hp, drat y qsec constantes**.
- $\hat{\beta}_{hp}$: por cada caballo de fuerza adicional, el rendimiento cambia en promedio $\hat{\beta}_{hp}$ mpg, **manteniendo wt, drat y qsec constantes**.
- $\hat{\beta}_{drat}$: por cada unidad adicional en la relación del eje trasero, el rendimiento cambia en $\hat{\beta}_{drat}$ mpg, **manteniendo wt, hp y qsec constantes**.
- $\hat{\beta}_{qsec}$: por cada segundo adicional en el cuarto de milla, el rendimiento cambia en $\hat{\beta}_{qsec}$ mpg, **manteniendo wt, hp y drat constantes**.

Es clave que cada coeficiente se interpreta **condicionado en que las demás predictoras permanecen fijas**. Esto no significa que en la realidad una pueda variar sin afectar las otras, sino que es la interpretación matemática del coeficiente parcial.

```
# Predicción con el modelo de 4 covariables
# Punto dentro de la región observada
x0_dentro <- data.frame(wt = 3.2, hp = 150, drat = 3.5, qsec = 18)

# Punto de extrapolación: valores individualmente razonables pero combinación atípica
# (auto muy pesado pero con tiempo de cuarto de milla muy bajo = combinación rara)
x0_extra <- data.frame(wt = 5.0, hp = 100, drat = 4.5, qsec = 14)

nuevos_multi <- rbind(x0_dentro, x0_extra)
rownames(nuevos_multi) <- c("Interpolación", "Extrapolación")

ic_multi <- predict(modelo_multi, newdata = nuevos_multi, interval = "confidence", level = 0.95)
ip_multi <- predict(modelo_multi, newdata = nuevos_multi, interval = "prediction", level = 0.95)

cat("IC para la respuesta media:\n")

## IC para la respuesta media:
print(round(ic_multi, 3))

##           fit    lwr    upr
## Interpolación 20.015 19.030 21.001
## Extrapolación 13.780  5.971 21.589

cat("\nIP para un valor futuro:\n")

##
## IP para un valor futuro:
print(round(ip_multi, 3))
```

```
##               fit      lwr      upr
## Interpolación 20.015 14.713 25.318
## Extrapolación 13.780  4.393 23.168

# Verificación de extrapolación con leverage
X_multi <- model.matrix(modelo_multi)
x0_mat <- model.matrix(~ wt + hp + drat + qsec, data = nuevos_multi)
h_nuevos <- diag(x0_mat %*% solve(t(X_multi) %*% X_multi) %*% t(x0_mat))
h_max <- max(hatvalues(modelo_multi))

cat("\nLeverage máximo en datos originales:", round(h_max, 4), "\n")

##
## Leverage máximo en datos originales: 0.486

for (i in 1:nrow(nuevos_multi)) {
  estado <- ifelse(h_nuevos[i] > h_max, "EXTRAPOLACIÓN", "Interpolación")
  cat(sprintf("%s: h00 = %.4f -> %s\n", rownames(nuevos_multi)[i], h_nuevos[i], estado))
}

## Interpolación: h00 = 0.0358 -> Interpolación
## Extrapolación: h00 = 2.2462 -> EXTRAPOLACIÓN

cat("\nNote que el segundo punto tiene valores individuales dentro del rango de cada variable,\n")

##
## Note que el segundo punto tiene valores individuales dentro del rango de cada variable,
cat("pero su COMBINACIÓN es atípica, lo que muestra por qué se debe verificar\n")

## pero su COMBINACIÓN es atípica, lo que muestra por qué se debe verificar
cat("la región conjunta y no solo los rangos marginales.\n")

## la región conjunta y no solo los rangos marginales.
```

Extrapolación y verificación con el leverage Al momento de hacer predicciones, es importante verificar que no estemos **extrapolando** fuera de la región de observación conjunta. Esto no se verifica revisando cada predictora por separado, sino evaluando el **leverage** del nuevo punto:

$$h_{00} = x_0(\mathbf{X}^\top \mathbf{X})^{-1} x_0^\top$$

Si $h_{00} > \max_{1 \leq i \leq n} \{h_{ii}\}$, el punto x_0 está fuera de la región de observación y se está extrapolando.

Visualización de la región de observación y extrapolación Para visualizar el concepto de extrapolación en el espacio de las predictoras, graficamos los datos en el plano (**wt**, **hp**) junto con la elipse que delimita aproximadamente la región de observación conjunta. Un punto puede estar dentro del rango individual de cada variable pero fuera de la región conjunta.

```
# Región de observación conjunta en 2D (wt vs hp)
# La elipse se basa en la distribución conjunta de las predictoras

# Calcular media y covarianza de (wt, hp)
mu <- colMeans(mtcars[, c("wt", "hp")])
Sigma <- cov(mtcars[, c("wt", "hp")])

# Generar elipse de confianza al 95%
```

```

angulos <- seq(0, 2 * pi, length.out = 200)
circulo <- cbind(cos(angulos), sin(angulos))

# Descomposición para transformar el círculo en elipse
eigen_S <- eigen(Sigma)
raiz_S <- eigen_S$vectors %*% diag(sqrt(eigen_S$values)) %*% t(eigen_S$vectors)

# Radio para cubrir ~95% de los datos (chi-cuadrado con 2 gl)
radio <- sqrt(qchisq(0.95, df = 2))
elipse <- t(mu + radio * raiz_S %*% t(circulo))

# Puntos de predicción
puntos_dentro <- data.frame(wt = c(2.5, 3.0, 3.5), hp = c(110, 150, 200))

# Punto dentro de los rangos marginales pero fuera de la región conjunta
# (bajo peso + alta potencia: combinación no observada)
punto_extra <- data.frame(wt = 1.8, hp = 300)

# Punto claramente fuera de ambos rangos
punto_extra2 <- data.frame(wt = 1.2, hp = 350)

par(mar = c(5, 4.5, 3, 1))
plot(mtcars$wt, mtcars$hp, pch = 19, col = "gray30", cex = 1.3,
     xlab = "Peso (wt, miles de libras)", ylab = "Potencia (hp)",
     main = "Región de observación conjunta y detección de extrapolación",
     xlim = c(0.8, 6), ylim = c(40, 380))

# Dibujar la elipse
polygon(elipse[, 1], elipse[, 2], border = "steelblue", lwd = 2.5,
       col = rgb(0.27, 0.51, 0.71, 0.1))

# Rangos marginales (rectángulo)
rect(min(mtcars$wt), min(mtcars$hp), max(mtcars$wt), max(mtcars$hp),
     border = "darkorange", lty = 2, lwd = 2)

# Puntos de predicción
points(puntos_dentro$wt, puntos_dentro$hp, pch = 17, col = "forestgreen", cex = 2)
points(punto_extra$wt, punto_extra$hp, pch = 18, col = "red", cex = 2.5)
points(punto_extra2$wt, punto_extra2$hp, pch = 18, col = "darkred", cex = 2.5)

# Etiquetas
text(punto_extra$wt + 0.15, punto_extra$hp + 10,
     "Dentro de rangos\npero fuera de\nregión conjunta",
     col = "red", cex = 0.75, adj = 0)
text(punto_extra2$wt + 0.15, punto_extra2$hp,
     "Fuera de ambos",
     col = "darkred", cex = 0.75, adj = 0)

# Re-dibujar datos originales encima
points(mtcars$wt, mtcars$hp, pch = 19, col = "gray30", cex = 1.3)

legend("bottomright",
      legend = c("Datos observados",


```

```

"Elipse 95% (región conjunta)",
"Rangos marginales",
"Interpolación",
"Extrapolación"),
col = c("gray30", "steelblue", "darkorange", "forestgreen", "red"),
pch = c(19, NA, NA, 17, 18),
lty = c(NA, 1, 2, NA, NA),
lwd = c(NA, 2.5, 2, NA, NA),
pt.cex = c(1.3, NA, NA, 2, 2.5),
bty = "n", cex = 0.9)

```

Región de observación conjunta y detección de extrapolación



El gráfico ilustra un punto clave: **el rectángulo de rangos marginales (naranja) no es equivalente a la región de observación conjunta (elipse azul)**. Un punto puede estar dentro de los rangos individuales de wt y hp pero fuera de la elipse, lo que significa que esa *combinación* de valores no fue observada en los datos. Por eso la verificación con el leverage h_{00} es necesaria.

```

# Verificación numérica de los puntos del gráfico
modelo_2v <- lm(mpg ~ wt + hp, data = mtcars)
X_2v <- model.matrix(modelo_2v)
h_max_2v <- max(hatvalues(modelo_2v))

todos_puntos <- rbind(puntos_dentro, punto_extra, punto_extra2)
rownames(todos_puntos) <- c("P1 (2.5, 110)", "P2 (3.0, 150)", "P3 (3.5, 200)",
                             "Extra1 (1.8, 300)", "Extra2 (1.2, 350)")

```

```

x0_todos <- model.matrix(~ wt + hp, data = todos_puntos)
h_todos <- diag(x0_todos %*% solve(t(X_2v) %*% X_2v) %*% t(x0_todos))

cat("Leverage máximo observado:", round(h_max_2v, 4), "\n")

## Leverage máximo observado: 0.3942

cat(strrep("-", 55), "\n")

## -----
for (i in 1:nrow(todos_puntos)) {
  estado <- ifelse(h_todos[i] > h_max_2v, "EXTRAPOLACIÓN", "Interpolación")
  cat(sprintf("%-20s h00 = %.4f -> %s\n", rownames(todos_puntos)[i], h_todos[i], estado))
}

## P1 (2.5, 110)      h00 = 0.0487 -> Interpolación
## P2 (3.0, 150)      h00 = 0.0350 -> Interpolación
## P3 (3.5, 200)      h00 = 0.0536 -> Interpolación
## Extra1 (1.8, 300)   h00 = 0.6789 -> EXTRAPOLACIÓN
## Extra2 (1.2, 350)   h00 = 1.2336 -> EXTRAPOLACIÓN

```

Verificación de supuestos

Realizar inferencia con el modelo de regresión lineal implica que se cumplan ciertos supuestos para que nuestras conclusiones sean válidas. Este es uno de los puntos que diferencia lo que se hace en el curso con la regresión lineal empleada en *Machine Learning*, donde los supuestos importan menos y el foco está en la capacidad predictiva del modelo.

Recordemos que los supuestos del modelo de regresión lineal se resumen en:

$$\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2), \quad i = 1, \dots, n$$

Es decir, los errores deben tener **media cero**, **varianza constante**, ser **normales** e **independientes**. Como los errores ε_i no son observables, usamos los **residuales** $e_i = y_i - \hat{y}_i$ como sus estimaciones para validar cada supuesto.

Para los ejemplos de esta sección, trabajaremos con el modelo `mpg ~ wt + hp` del dataset `mtcars`:

```
modelo <- lm(mpg ~ wt + hp, data = mtcars)
```

Supuesto 1: Media cero de los errores Este supuesto **siempre se cumple** cuando el modelo incluye intercepto. La razón es algebraica: al resolver las ecuaciones normales de MCO, una de las condiciones que se obtiene es precisamente que $\sum_{i=1}^n e_i = 0$, lo que implica $\bar{e} = 0$.

En el caso simple, esto se puede ver fácilmente:

$$\sum_{i=1}^n e_i = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = \sum_{i=1}^n (y_i - \bar{y}) - \hat{\beta}_1 \sum_{i=1}^n (x_i - \bar{x}) = 0 - 0 = 0$$

En el caso múltiple, la demostración es análoga usando la notación matricial: las ecuaciones normales $X^T(Y - X\hat{\beta}) = 0$ implican $X^T e = 0$. Como la primera columna de X es un vector de unos, se tiene $\mathbf{1}^T e = \sum e_i = 0$.

```
# Verificación: la suma de residuales siempre es (prácticamente) cero
cat("Suma de residuales:", sum(residuals(modelo)), "\n")
```

```
## Suma de residuales: 3.774758e-15
```

```
cat("Media de residuales:", mean(residuals(modelo)), "\n")
```

```
## Media de residuales: 1.94289e-16
```

Por lo tanto, **no necesitamos validar este supuesto**: es una consecuencia directa del método de estimación.

Supuesto 2: Varianza constante (homocedasticidad) El supuesto de varianza constante establece que $\text{Var}(\varepsilon_i) = \sigma^2$ para todo i . Cuando este supuesto se viola (heterocedasticidad), los estimadores MCO siguen siendo insesgados, pero **dejan de ser eficientes** y los errores estándar (y por ende las pruebas de hipótesis e intervalos de confianza) dejan de ser válidos.


La herramienta principal para evaluar este supuesto es el **gráfico de residuales vs. valores ajustados**. Lo que buscamos es que la nube de puntos se distribuya de forma aleatoria alrededor de cero, sin mostrar patrones como:

- Forma de embudo (varianza creciente o decreciente)
- Forma de arco o parábola (sugiere un término cuadrático faltante)
- Algún otro patrón sistemático

```
par(mfrow = c(1, 2), mar = c(5, 4.5, 3, 1))

# Gráfico de residuales vs valores ajustados
plot(fitted(modelo), residuals(modelo),
     pch = 19, col = "steelblue", cex = 1.2,
     xlab = "Valores ajustados", ylab = "Residuales",
     main = "Residuales vs Valores Ajustados",
     las = 1, bty = "l")
abline(h = 0, col = "tomato", lwd = 2, lty = 2)

# El gráfico incorporado de R (plot 1 del modelo)
plot(modelo, which = 1, pch = 19, col = "steelblue", cex = 1.2)
```



En este gráfico buscamos que **no haya patrón visible**. Si los puntos se distribuyen de forma aleatoria y homogénea alrededor de la línea $e = 0$, el supuesto de varianza constante se sostiene.


Ejemplo de varianza no constante: Veamos un caso artificial donde la varianza crece con x :

```
set.seed(42)
n_sim <- 100
x_sim <- seq(1, 10, length.out = n_sim)
# La varianza del error crece con x (heterocedasticidad)
y_sim <- 2 + 3 * x_sim + rnorm(n_sim, sd = 0.5 * x_sim)

modelo_hetero <- lm(y_sim ~ x_sim)

par(mfrow = c(1, 2), mar = c(5, 4.5, 3, 1))
plot(x_sim, y_sim, pch = 19, col = "steelblue",
     xlab = "x", ylab = "y", main = "Datos con heterocedasticidad")
abline(modelo_hetero, col = "tomato", lwd = 2)

plot(fitted(modelo_hetero), residuals(modelo_hetero),
     pch = 19, col = "steelblue",
     xlab = "Valores ajustados", ylab = "Residuales",
     main = "Residuales: forma de embudo")
abline(h = 0, col = "tomato", lwd = 2, lty = 2)
```

Note cómo los residuales forman un patrón de **embudo** (se abren hacia la derecha), indicando que la varianza del error no es constante.


Soluciones comunes al problema de heterocedasticidad:

1. **Mínimos Cuadrados Ponderados (MCP):** Se asignan pesos ω_i inversamente proporcionales a la varianza de cada observación, minimizando $\sum \omega_i (y_i - \hat{y}_i)^2$.
2. **Transformaciones en Y:** A menudo una transformación logarítmica estabiliza la varianza. Si $\text{Var}(\varepsilon_i) \propto E[Y_i]^2$, aplicar $\ln(Y)$ puede resolver el problema.
3. **Relación funcional adecuada:** A veces el patrón en los residuales indica que falta un término (por ejemplo, cuadrático) en el modelo, no que la varianza sea no constante.

```
# Ejemplo de solución: transformación logarítmica
y_log <- log(y_sim)
modelo_log <- lm(y_log ~ x_sim)

par(mfrow = c(1, 2), mar = c(5, 4.5, 3, 1))
plot(fitted(modelo_hetero), residuals(modelo_hetero),
     pch = 19, col = "steelblue",
     xlab = "Valores ajustados", ylab = "Residuales",
     main = "Sin transformación (embudo)")
abline(h = 0, col = "tomato", lwd = 2, lty = 2)

plot(fitted(modelo_log), residuals(modelo_log),
     pch = 19, col = "forestgreen",
     xlab = "Valores ajustados", ylab = "Residuales",
     main = "Con log(Y) (más homogéneo)")
abline(h = 0, col = "tomato", lwd = 2, lty = 2)
```




Supuesto 3: Normalidad de los errores El supuesto de normalidad es necesario para que los estadísticos T y F que usamos en las pruebas de hipótesis e intervalos de confianza tengan las distribuciones que les asignamos. Se evalúa mediante:

1. **Prueba de Shapiro-Wilk:** Contrasta $H_0 : \varepsilon_i \sim \text{Normal}$ vs. $H_1 : \varepsilon_i \not\sim \text{Normal}$. Si el valor- p es mayor que α , no rechazamos H_0 y consideramos que el supuesto es razonable.
2. **Gráfico QQ (cuantil-cuantil):** Compara los cuantiles de los residuales con los cuantiles teóricos de una distribución normal. Si los puntos se alinean sobre la diagonal, el supuesto se sostiene.

```
par(mar = c(5, 4.5, 3, 1))
```

```
# Gráfico QQ de los residuales
```

```
plot(modelo, which = 2, pch = 19, col = "steelblue", cex = 1.2)
```



```
# Prueba de Shapiro-Wilk
shapiro.test(residuals(modelo))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(modelo)
## W = 0.92792, p-value = 0.03427
```

Si el valor- p de la prueba es mayor que el nivel de significancia (por ejemplo, 0.05), no rechazamos H_0 y concluimos que **no hay evidencia suficiente para afirmar que los errores no son normales**.

Ejemplo de no normalidad: Veamos un caso donde los errores provienen de una distribución con colas pesadas:


```
set.seed(123)
n_sim2 <- 80
x_nn <- runif(n_sim2, 0, 10)
# Errores con distribución t (colas pesadas)
y_nn <- 5 + 2 * x_nn + rt(n_sim2, df = 2)

modelo_nn <- lm(y_nn ~ x_nn)

par(mar = c(5, 4.5, 3, 1))
qqnorm(residuals(modelo_nn), pch = 19, col = "tomato",
```

```
main = "QQ-plot: desviación en las colas")
qqline(residuals(modelo_nn), col = "navy", lwd = 2)
```

QQ-plot: desviación en las colas



```
shapiro.test(residuals(modelo_nn))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(modelo_nn)
## W = 0.74442, p-value = 1.728e-10
```

Note cómo en el gráfico QQ los puntos se desvían de la recta en los extremos, y la prueba de Shapiro-Wilk rechaza H_0 : hay evidencia de que los errores **no son normales**.

Soluciones al problema de no normalidad:

- Frecuentemente la no normalidad viene acompañada de varianza no constante. Una transformación que estabilice la varianza puede también mejorar la normalidad.
- Si la no normalidad persiste, se pueden emplear **métodos no paramétricos** de regresión que no asumen un modelo probabilístico particular sobre los errores.

Supuesto 4: Independencia de los errores Este supuesto establece que los errores no están correlacionados entre sí: $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$. Su evaluación requiere conocer el **orden temporal** en que se

recolectaron las observaciones. Si se tiene esa información, se puede examinar un gráfico de residuales vs. el tiempo buscando patrones como ciclos, rachas o tendencias.

En muchas situaciones prácticas (y en este curso) **no se cuenta con el orden de las observaciones**, por lo que el supuesto se asume como válido. En el curso de **Estadística III** se estudian modelos que relajan este supuesto, donde se trabaja con errores correlacionados, variables de tendencia, estacionalidad y primeras diferencias.

Residuales escalados

Los residuales ordinarios $e_i = y_i - \hat{y}_i$ tienen un problema: **no todos tienen la misma varianza** ni son independientes entre sí, a pesar de que los errores ε_i sí cumplen esas propiedades. Esto se debe a que:

$$\mathbf{e} = (\mathbf{I} - \mathbf{H})\mathbf{Y}$$

de donde se puede mostrar que:

$$\text{Var}(e_i) = \sigma^2(1 - h_{ii}), \quad \text{Cov}(e_i, e_j) = -\sigma^2 h_{ij} \quad (i \neq j)$$

donde h_{ii} es el i -ésimo elemento de la diagonal de la matriz $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$. Es decir, los residuales en puntos con mayor *leverage* (h_{ii} alto) tienen menor varianza. Para corregir esto, se definen versiones escaladas de los residuales.

Residuales estandarizados Se obtienen dividiendo cada residual por $\sqrt{MSE}$, como si todos tuvieran la misma varianza:

$$d_i = \frac{e_i}{\sqrt{MSE}}, \quad i = 1, \dots, n$$

Si el modelo es adecuado, los d_i deberían oscilar entre -3 y 3 . Una observación con $|d_i| > 3$ es **potencialmente atípica**.

Residuales estudentizados (internamente) Estos residuales corrigen el hecho de que $\text{Var}(e_i) = \sigma^2(1 - h_{ii})$, dividiendo por la desviación estándar real de cada residual:

$$r_i = \frac{e_i}{\sqrt{MSE(1 - h_{ii})}}, \quad i = 1, \dots, n$$

A diferencia de los estandarizados, los estudentizados tienen en cuenta que los residuales en puntos con alto *leverage* son naturalmente más pequeños. Este residual también debe ubicarse entre -3 y 3 . Se considera que una observación es **atípica** si $|r_i| > 3$.

```
# Residuales estandarizados y estudentizados
d_i <- residuals(modelo) / sqrt(sum(residuals(modelo)^2) / modelo$df.residual)
r_i <- rstandard(modelo) # residuales estudentizados internamente
r_ext <- rstudent(modelo) # residuales estudentizados externamente
```


```

par(mfrow = c(1, 2), mar = c(5, 4.5, 3, 1))

# Residuales estandarizados
plot(fitted(modelo), d_i, pch = 19, col = "steelblue", cex = 1.2,
     xlab = "Valores ajustados", ylab = expression(d[i]),
     main = "Residuales estandarizados", las = 1, bty = "n")
abline(h = c(-3, 0, 3), col = c("tomato", "gray50", "tomato"),
      lty = c(2, 1, 2), lwd = c(1.5, 1, 1.5))

# Residuales estudentizados
plot(fitted(modelo), r_i, pch = 19, col = "forestgreen", cex = 1.2,
     xlab = "Valores ajustados", ylab = expression(r[i]),
     main = "Residuales estudentizados", las = 1, bty = "n")
abline(h = c(-3, 0, 3), col = c("tomato", "gray50", "tomato"),
      lty = c(2, 1, 2), lwd = c(1.5, 1, 1.5))

```



Ejemplo en R: comparación de residuales escalados

```

# Identificación de observaciones atípicas
cat("Observaciones atípicas ( $|r_i| > 3$ ) usando residuales estudentizados:\n")

```

```

## Observaciones atípicas ( $|r_i| > 3$ ) usando residuales estudentizados:

```

```

atipicas_r <- which(abs(rstandard(modelo)) > 3)
if (length(atipicas_r) == 0) {
  cat(" Ninguna observación supera el umbral de 3.\n")
} else {
  print(atipicas_r)
}

```

```

## Ninguna observación supera el umbral de 3.

```

```
cat("\nObservaciones atípicas (|r*_i| > 3) usando residuales estudentizados externos:\n")

##
## Observaciones atípicas (|r*_i| > 3) usando residuales estudentizados externos:
atipicas_ext <- which(abs(rstudent(modelo)) > 3)
if (length(atipicas_ext) == 0) {
  cat(" Ninguna observación supera el umbral de 3.\n")
} else {
  print(atipicas_ext)
}

## Ninguna observación supera el umbral de 3.
```

Observaciones atípicas (*outliers*)

Una **observación atípica** es aquella que está separada del resto en su valor de la respuesta Y y que puede afectar los resultados del ajuste. Interesa identificarlas para determinar si se tratan de:

- **Errores de registro o medición:** pueden ser descartadas del análisis.
- **Datos correctos pero inusuales:** no deben eliminarse, pero se debe investigar su impacto.

La detección se realiza con los **residuales estudentizados**: una observación es atípica si $|r_i| > 3$. Muchos *outliers* pueden provocar que los niveles de confianza reales sean menores de lo esperado.

Puntos de balanceo (*leverage points*)

Un **punto de balanceo** es una observación que está alejada del resto en el **espacio de las predictoras** (no necesariamente en Y). Estos puntos pueden no afectar los coeficientes estimados, pero sí pueden distorsionar estadísticas como el R^2 y los errores estándar.

Los puntos de balanceo se detectan mediante los elementos de la diagonal principal de la matriz $\mathbf{H}$, los h_{ii} , que miden la distancia estandarizada de la i -ésima observación al centro del espacio de las predictoras.

La media de los h_{ii} es:

$$\bar{h} = \frac{\sum_{i=1}^n h_{ii}}{n} = \frac{\text{traza}(\mathbf{H})}{n} = \frac{p}{n}$$

Se considera que la observación i es un **punto de balanceo** si:

$$h_{ii} > \frac{2p}{n}$$

(siempre que $2p/n < 1$, pues los h_{ii} siempre son menores que 1).

```
n <- nrow(mtcars)
p <- length(coef(modelo))
h_ii <- hatvalues(modelo)
umbral_leverage <- 2 * p / n


par(mar = c(5, 4.5, 3, 1))
plot(1:n, h_ii, pch = 19, col = "steelblue", cex = 1.2,
     xlab = "Observación", ylab = expression(h[ii]),
```

```

main = "Leverage de cada observación",
las = 1, bty = "l")
abline(h = umbral_leverage, col = "tomato", lwd = 2, lty = 2)
text(which(h_ii > umbral_leverage) + 1, h_ii[h_ii > umbral_leverage],
     labels = names(h_ii)[h_ii > umbral_leverage], cex = 0.7, col = "tomato")

legend("topright", legend = paste0("Umbral: 2p/n = ", round(umbral_leverage, 3)),
      col = "tomato", lty = 2, lwd = 2, bty = "n")

```



```

# Puntos de balanceo identificados
balanceo <- which(h_ii > umbral_leverage)
cat("Puntos de balanceo (h_ii > ", round(umbral_leverage, 3), "):\n")

```

```
## Puntos de balanceo (h_ii > 0.188 ):
```

```

print(data.frame(
  Observacion = names(balanceo),
  h_ii = round(h_ii[balanceo], 4)
))

```

```

##               Observacion  h_ii
## Lincoln Continental Lincoln Continental 0.2090
## Ford Pantera L          Ford Pantera L 0.2044
## Maserati Bora           Maserati Bora 0.3942

```

Observaciones influenciales

Una observación es **influyente** si su exclusión del modelo causa cambios importantes en la ecuación de regresión ajustada. Estas observaciones suelen tener un valor moderadamente inusual tanto en el espacio de las predictoras como en la respuesta (es decir, combinan características de ser atípicas y de balanceo).

Para detectarlas, se cuenta con tres criterios principales:

1. Distancia de Cook Mide la distancia cuadrática entre el vector de parámetros estimados con todas las observaciones ($\hat{\beta}$) y el estimado sin la observación i ($\hat{\beta}_{(i)}$):

$$D_i = \frac{(\hat{\beta}_{(i)} - \hat{\beta})^\top (\mathbf{X}^\top \mathbf{X}) (\hat{\beta}_{(i)} - \hat{\beta})}{p \cdot MSE} = \frac{r_i^2}{p} \cdot \frac{h_{ii}}{1 - h_{ii}}, \quad i = 1, \dots, n$$

Note que D_i combina información del residual estudentizado (r_i) y del leverage (h_{ii}): una observación puede ser influyente por ser atípica, por tener alto leverage, o por ambas razones.

Criterio: Una observación es influyente si $D_i > 1$ (dado que $F_{0.5, p, n-p} \approx 1$).

2. Diagnóstico DFFITS Mide cuántas desviaciones estándar se mueve el valor ajustado $\hat{y}_i$ cuando se omite la observación i :

$$DFFITS_i = \frac{\hat{y}_i - \hat{y}_{(i)}}{\sqrt{MSE_{(i)} \cdot h_{ii}}}$$

donde $\hat{y}_{(i)}$ es el valor ajustado sin la observación i y $MSE_{(i)}$ es el cuadrado medio del error sin dicha observación.

Criterio: Una observación es influyente si $|DFFITS_i| > 2\sqrt{p/n}$.

3. Diagnóstico DFBETAS Mide cuánto cambia cada coeficiente individual $\hat{\beta}_j$ (en unidades de su error estándar) cuando se omite la observación i :

$$DFBETAS_{j(i)} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\sqrt{MSE_{(i)} \cdot c_{jj}}}$$

donde c_{jj} es el j -ésimo elemento de la diagonal de $(\mathbf{X}^\top \mathbf{X})^{-1}$.

Criterio: Una observación es influyente sobre $\hat{\beta}_j$ si $|DFBETAS_{j(i)}| > 2/\sqrt{n}$.

DFBETAS es más informativo que Cook o DFFITS porque indica **cuál coeficiente** es el más afectado por cada observación.

```
n <- nrow(mtcars)
p <- length(coef(modelo))

# Calcular todos los diagnósticos
cook_d <- cooks.distance(modelo)
dffits_val <- dffits(modelo)
dfbetas_val <- dfbetas(modelo)
```

```

# Umbrales
umbral_cook <- 1
umbral_dffits <- 2 * sqrt(p / n)
umbral_dfbetas <- 2 / sqrt(n)

# Función auxiliar para etiquetar sin solapamiento
etiquetar <- function(x, y, idx, labels) {
  if (length(idx) == 0) return(invisible(NULL))
  # Alternar posición (arriba/abajo) para evitar solapamiento
  posiciones <- ifelse(seq_along(idx) %% 2 == 1, 3, 1)
  text(x[idx], y[idx], labels = labels[idx], cex = 0.6, pos = posiciones, col = "tomato")
}

par(mfrow = c(2, 2), mar = c(5, 4.5, 3, 2))



# 1. Distancia de Cook
plot(1:n, cook_d, type = "h", lwd = 2, col = "steelblue",
     xlab = "Observación", ylab = expression(D[i]),
     main = "Distancia de Cook", las = 1, bty = "l")
abline(h = umbral_cook, col = "tomato", lty = 2, lwd = 1.5)
top_cook <- order(cook_d, decreasing = TRUE)[1:3]
etiquetar(1:n, cook_d, top_cook, rownames(mtcars))

# 2. DFFITS
plot(1:n, dffits_val, pch = 19, col = "steelblue", cex = 1.1,
     xlab = "Observación", ylab = "DFFITS",
     main = paste0("DFFITS (umbral = ", round(umbral_dffits, 3), ")"),
     las = 1, bty = "l")
abline(h = c(-umbral_dffits, umbral_dffits), col = "tomato", lty = 2, lwd = 1.5)
idx_dffits <- which(abs(dffits_val) > umbral_dffits)
etiquetar(1:n, dffits_val, idx_dffits, rownames(mtcars))

# 3. DFBETAS para wt
dfb_wt <- dfbetas_val[, "wt"]
plot(1:n, dfb_wt, pch = 19, col = "forestgreen", cex = 1.1,
     xlab = "Observación", ylab = expression(DFBETAS[wt]),
     main = paste0("DFBETAS para wt (umbral = ", round(umbral_dfbetas, 3), ")"),
     las = 1, bty = "l")
abline(h = c(-umbral_dfbetas, umbral_dfbetas), col = "tomato", lty = 2, lwd = 1.5)
idx_dfb_wt <- which(abs(dfb_wt) > umbral_dfbetas)
etiquetar(1:n, dfb_wt, idx_dfb_wt, rownames(mtcars))

# 4. DFBETAS para hp
dfb_hp <- dfbetas_val[, "hp"]
plot(1:n, dfb_hp, pch = 19, col = "darkorange", cex = 1.1,
     xlab = "Observación", ylab = expression(DFBETAS[hp]),
     main = paste0("DFBETAS para hp (umbral = ", round(umbral_dfbetas, 3), ")"),
     las = 1, bty = "l")
abline(h = c(-umbral_dfbetas, umbral_dfbetas), col = "tomato", lty = 2, lwd = 1.5)
idx_dfb_hp <- which(abs(dfb_hp) > umbral_dfbetas)
etiquetar(1:n, dfb_hp, idx_dfb_hp, rownames(mtcars))

```



Ejemplo en R: diagnósticos de influencia completos

```
cat("=== Resumen de diagnósticos de influencia ===\n\n")
```

```
## === Resumen de diagnósticos de influencia ===
```

```
cat("Distancia de Cook ( $D_i > 1$ ):\n")
```

```
## Distancia de Cook ( $D_i > 1$ ):
```

```
inf_cook <- which(cook_d > umbral_cook)
if (length(inf_cook) == 0) {
  cat(" Ninguna observación supera el umbral.\n")
  cat(" Las 3 más altas:", paste(names(sort(cook_d, decreasing = TRUE)[1:3]),
    collapse = ", "), "\n")
} else {
  print(round(cook_d[inf_cook], 4))
}
```

```
## Ninguna observación supera el umbral.
```

```
## Las 3 más altas: Chrysler Imperial, Maserati Bora, Toyota Corolla
```

```

cat("\nDFFITS (|DFFITS_i| >", round(umbral_dffits, 3), "):\n")

##
## DFFITS (|DFFITS_i| > 0.612 ):
inf_dffits <- which(abs(dffits_val) > umbral_dffits)
if (length(inf_dffits) == 0) {
  cat(" Ninguna observación supera el umbral.\n")
} else {
  print(data.frame(
    Observacion = names(inf_dffits),
    DFFITS = round(dffits_val[inf_dffits], 4)
  ))
}

##
## Observacion DFFITS
## Chrysler Imperial Chrysler Imperial 1.2317
## Fiat 128 Fiat 128 0.7492
## Toyota Corolla Toyota Corolla 0.8660
## Maserati Bora Maserati Bora 0.9075

cat("\nDFBETAS (|DFBETAS_j(i)| >", round(umbral_dfbetas, 3), "):\n")

##
## DFBETAS (|DFBETAS_j(i)| > 0.354 ):
inf_dfbetas <- which(abs(dfbetas_val) > umbral_dfbetas, arr.ind = TRUE)
if (nrow(inf_dfbetas) == 0) {
  cat(" Ninguna observación supera el umbral.\n")
} else {
  for (idx in 1:nrow(inf_dfbetas)) {
    obs <- rownames(dfbetas_val)[inf_dfbetas[idx, 1]]
    var_name <- colnames(dfbetas_val)[inf_dfbetas[idx, 2]]
    valor <- round(dfbetas_val[inf_dfbetas[idx, 1], inf_dfbetas[idx, 2]], 4)
    cat(sprintf(" %s influye sobre %s: DFBETAS = %.4f\n", obs, var_name, valor))
  }
}

## Chrysler Imperial influye sobre (Intercept): DFBETAS = -0.9241
## Fiat 128 influye sobre (Intercept): DFBETAS = 0.6052
## Toyota Corolla influye sobre (Intercept): DFBETAS = 0.8047
## Lotus Europa influye sobre (Intercept): DFBETAS = 0.4234
## Chrysler Imperial influye sobre wt: DFBETAS = 0.9356
## Toyota Corolla influye sobre wt: DFBETAS = -0.4115
## Lotus Europa influye sobre wt: DFBETAS = -0.4072
## Maserati Bora influye sobre wt: DFBETAS = -0.4999
## Maserati Bora influye sobre hp: DFBETAS = 0.8658

```

Visualización integrada: atípicas, balanceo e influencia El siguiente gráfico resume los tres conceptos en una sola visualización. Cada punto se ubica según su leverage (h_{ii}) y su residual estudentizado (r_i), y su tamaño es proporcional a la distancia de Cook:

```
par(mar = c(5, 4.5, 3, 1))
```

```
# Datos
```

```

h_vals <- hatvalues(modelo)
r_vals <- rstandard(modelo)
cook_vals <- cooks.distance(modelo)

# Escalar el tamaño de los puntos por Cook's distance
tam <- sqrt(cook_vals / max(cook_vals)) * 5 + 0.5


plot(h_vals, r_vals, pch = 19,
     col = ifelse(abs(r_vals) > 3, "red",
                  ifelse(h_vals > umbral_leverage, "darkorange", "steelblue")),
     cex = tam,
     xlab = expression(h[ii] ~ "(Leverage)"),
     ylab = expression(r[i] ~ "(Residual estudentizado)"),
     main = "Diagnóstico integrado: Atípicas, Balanceo e Influencia",
     las = 1, bty = "l",
     xlim = c(0, max(h_vals) * 1.15))

# Líneas de referencia
abline(h = c(-3, 3), col = "red", lty = 2, lwd = 1.5)
abline(v = umbral_leverage, col = "darkorange", lty = 2, lwd = 1.5)

# Etiquetar puntos notables
notables <- which(h_vals > umbral_leverage | abs(r_vals) > 2 |
                 cook_vals > quantile(cook_vals, 0.9))
if (length(notables) > 0) {
  text(h_vals[notables], r_vals[notables],
       labels = names(h_vals)[notables],
       cex = 0.65, pos = 4, col = "gray30")
}

legend("topright",
     legend = c("Normal", "Alto leverage", "Atípica ( $|r| > 3$ )",
                "Tamaño ~ Dist. Cook"),
     col = c("steelblue", "darkorange", "red", "gray50"),
     pch = c(19, 19, 19, 1),
     pt.cex = c(1.2, 1.2, 1.2, 2.5),
     bty = "n", cex = 0.85)

```



Nota importante sobre observaciones identificadas Las observaciones identificadas como atípicas, de balanceo o influenciales **deben ser investigadas**, no eliminadas automáticamente:

- Si se determina que son **errores de registro** o medición, pueden removerse del análisis.
- Si son **datos correctos** pero inusuales, se deben mantener. En este caso, se puede recurrir a **métodos estadísticos robustos** que no se vean afectados por estas observaciones (como regresión robusta con estimadores M o MM).

La eliminación de datos sin justificación es una mala práctica que puede sesgar los resultados.